

度的退化特征，并结合 ReLU² 智能体注意力（ReLU² Agent Attention, RAA）进行跨位置全局信息交互。其中，“MS”表示由小核 DSConv-S 与大核 DSConv-L 构成的多尺度卷积设计。

MS-AgentNet 的整体架构如图 5 所示。健康指标（Health Indicators, HIs）序列经滑动窗口分割后，首先通过线性嵌入层映射至 d 维特征空间；随后，嵌入特征进入 MS-AgentNet Block，并在 Block 内依次完成局部—全局特征融合、长尺度特征细化与非线性映射。最后，模型对输出特征进行层归一化、展平和线性读出，得到 SOH 估计值。

训练过程中，每个输入窗口以窗口后紧邻循环的真实 SOH 值作为监督标签。

从数学角度看，设第 l 个 MS-AgentNet Block 的输入为 $\mathbf{X}_l \in \mathbb{R}^{B \times N \times d}$ ，其中 B 为批量大小， N 为输入序列长度， d 为嵌入维度。其内部特征变换可表示为以下过程：

步骤 1：局部—全局融合。输入特征先由 SLFA 模块完成小核局部增强和智能体全局交互：

$$\mathbf{X}'_l = \text{SLFA}(\mathbf{X}_l). \quad (11)$$

步骤 2：长尺度特征细化。为提取较长时间尺度的退化特征，中间特征 $\mathbf{X}'_l$ 先经层归一化，再通过 DSConv-L 模块，所得特征经可学习系数 W_l 缩放后，以残差形式与 $\mathbf{X}'_l$ 相加：

$$\mathbf{X}''_l = \mathbf{X}'_l + W_l \text{DSConv-L}(\text{LN}(\mathbf{X}'_l)). \quad (12)$$

步骤 3：非线性映射。细化后的特征 $\mathbf{X}''_l$ 经层归一化后输入 FFN，并通过残差连接得到输出 $\mathbf{Y}_l$ ：

$$\mathbf{Y}_l = \mathbf{X}''_l + \text{FFN}(\text{LN}_0(\mathbf{X}''_l)). \quad (13)$$

并令该 Block 的输出为 $\mathbf{X}_{l+1} = \mathbf{Y}_l$ 。其中，SLFA($\cdot$)、DSConv-L($\cdot$) 和 FFN($\cdot$) 分别表示轻量级局部—全局融合注意力模块、大核深度可分离卷积模块和前馈神经网络； W_l 为可学习缩放系数，LN($\cdot$) 表示层归一化，LN₀($\cdot$) 表示不含可学习仿射参数的层归一化。




Fig. 5. Framework of MS-AgentNet. (a) Overall architecture; (b) core structure; (c) DSConv-L module.

3.2 所设计的多尺度深度可分离卷积模块

本节首先介绍 DSConv 的基本结构, 并将其与标准卷积进行计算量比较; 随后说明 DSConv-S 和 DSConv-L 的结构配置及其多尺度特性。




Fig. 6. The fundamental structures of convolutional modules: (a) standard convolution; (b) standard depthwise separable convolution; (c) DSConv-S module; and (d) DSConv-L module.

3.2.1 DSConv 基本结构与计算量比较

卷积运算通过滑动卷积核提取时间序列中的局部信息 [71]。标准卷积在所有输入通道上进行运算, 每个卷积核生成一个输出特征图, 对应一个输出通道。随着输入通道数、输出通道数和卷积核尺寸增加, 其参数量与计算开销迅速累积, 显著推高计算负载并延长训练时间。在小样本电池数据集上, 较大的参数量还可能增加模型的过拟合风险。其计算成本可表示为:

$$C_{\text{Conv}} = k \times k \times C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F. \quad (14)$$

其中, k 、 C_{in} 、 C_{out} 和 D_F 分别表示卷积核大小、输入通道数、输出通道数和特征图尺寸。

与标准卷积不同, 深度可分离卷积 (DSConv) 将卷积运算分解为深度卷积和逐点卷积两个阶段 [71]。其中, 深度卷积为每个输入通道单独配置卷积核, 在通道内完成局部特征提取; 随后, 1×1 逐点卷积融合不同通道的特征, 并将通道数调整为 C_{out} 。通过分离通道内特征提取与通道间特征融合, DSConv 减少了标准卷积中的密集跨通道运算。其计算成本可表示为:

$$C_{\text{DSConv}} = k \times k \times C_{\text{in}} \times D_F \times D_F + C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F. \quad (15)$$

进一步比较两类卷积的计算量, 可得二者之比为:

$$\begin{aligned} \frac{C_{\text{DSConv}}}{C_{\text{Conv}}} &= \frac{k \times k \times C_{\text{in}} \times D_F \times D_F + C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F}{k \times k \times C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F} \\ &= \frac{1}{C_{\text{out}}} + \frac{1}{k^2}. \end{aligned} \quad (16)$$

由式(16)可知, 在输入、输出通道配置一致的情况下, DSConv 的计算成本低于标准卷积, 为后续小核与大核卷积模块的构建提供了基础。