

摘要

高效准确的锂离子电池健康状态估计，对保障电池安全运行和支持资源受限电池管理系统的在线应用至关重要。然而，现有估计方法往往依赖跨电池稳定性有限的健康指标和资源开销较大的模型结构。为此，本文提出一种轻量化的 SOH 估计框架。首先，通过自适应构建与筛选，获得具有较强跨电池稳定性的健康指标，并减少特征冗余。随后，我们提出集成小核与大核深度可分离卷积的预测网络 MS-AgentNet，旨在解决传统 Transformer 注意力机制的二次计算开销。其中，小核卷积与 ReLU² 智能体注意力组成局部—全局融合注意力模块，在捕获局部退化特征与长程退化依赖的同时，将注意力复杂度由二次降至线性。大核卷积则用于提取长尺度退化特征，与小核卷积共同以较低参数开销融合多尺度、多通道特征。我们在四个涵盖不同化学体系和运行条件的公开电池数据集上，将所提模型与多种主流深度学习模型进行了比较。结果表明，MS-AgentNet 在各数据集上均取得最佳综合性能：在 CALCE CX2 数据集上，其平均绝对百分比误差较 CNN-LSTM 降低 75.29%。此外，其模型大小仅为 26.18 KB，进一步体现了其面向资源受限电池管理系统的轻量化优势。

关键词：锂离子电池；健康状态估计；线性复杂度局部—全局融合注意力；深度特征融合；轻量化深度学习

1. 引言

锂离子电池凭借高能量密度、长循环寿命和较低自放电率等优势，已广泛应用于电动汽车、航空航天、便携式电子设备和规模化储能系统 [1–4]。在长期服役过程中，充放电循环与复杂工况会引发固体电解质界面 (solid electrolyte interphase, SEI) 膜增厚、活性锂损失和电极结构衰退等老化过程 [5,6]，进而导致容量衰减和性能下降，并增加短路与热失控等安全风险 [7,8]。因此，准确监测电池健康状态对于保障电池安全运行和实现全寿命周期管理至关重要。

容量衰减是电池老化的直接表现，容量型健康状态 (state of health, SOH) 通常由容量保持率定义 [13,14]。但最大可用容量通常需要经过完整或近完整的充放电过程才能获得，难以在电池正常运行期间直接测量 [10,11]。因此，BMS 需利用可观测运行信号在线估计 SOH。受计算和存储资源限制，在线估计模型需保持较低的计算量和存储占用 [31]。

1.1 文献综述

现有锂离子电池健康状态 (SOH) 估计方法分为模型驱动和数据驱动两类 [10–12]。前者包括电化学模型和等效电路模型，后者包括传统机器学习和深度学习方法。

模型驱动方法使用数学方程或等效电路描述电池内部状态 [19]。电化学模型通过微分方程描述电池内部反应和老化过程，其中的变量和参数具有明确的物理含义。Li 等人 [21] 将化学—机械退化过程纳入单粒子模型。然而，求解这些方程需要较大的计算量，使在线 SOH 估计更具挑战性。同时，颗粒半径和扩散系数等微观参数难以获取 [20,22,23]。相比之下，等效电路模型 (ECM) 使用电阻和电容等元件模拟电池动态，计算量较低，模型参数也更容易确定 [19]。Chen 等人 [24] 采用递推最小二乘法获得 Thevenin 模型参数，再根据欧姆内阻与容量衰减的关系估计 SOH。然而，ECM 难以完整描述电池内部状态变化，其估计精度取决于电路结构和模型参数。这些参数还会随温度和充放电倍率变化，降低 ECM 在整个老化周期内的估计鲁棒性 [19]。

相较于模型驱动方法，数据驱动方法从历史运行数据中构造健康指标 (HIs)，并利用预测模型估计 SOH [11,14]，降低了对复杂物理模型和微观参数的依赖。早期研究主要采用支持向量机、随机森林和高斯过程回归等传统机器学习模型 [25]。Fei 等人 [26] 从前 100 个循环的电压、电流、温度、内阻和容量数据中构造 42 个特征，并通过特征筛选比较了六种机器学习模型的早期寿命预测结果。Li 等人 [27] 采用随机森林，根据局部充电数据估计电池容量。传统机器学习模型结构相对简单，但通常依赖人工构造的健康指标，其估计性能取决于输入特征能否稳定反映电池退化。

在健康指标方面，现有 HIs 主要由电压、电流、温度和容量等运行数据及其衍生曲线构造 [47–49]。直接将原始充放电曲线输入预测模型能够保留完整的运行信息，但高频曲线包含大量相近的连续采样点，容易增加输入维度和数据冗余 [14,48]。健康指标使用少量特征值概括运行曲线中的变化，为 SOH 估计提供更加紧凑的模型输入。

增量容量 (IC) 曲线、微分温度—电压 (DTV) 曲线和微分温度—容量 (DTC) 曲线能够显示电池老化引起的电压平台变化和热响应变化。Wen 等人 [50] 从 IC 曲线中提取峰值、峰位和峰形斜率，并将相关性最高的特征用于 SOH 估计。Dai 等人 [48] 从电压、电流、温度、IC 和 DTV 曲线中构造多类候选特征。这类微分特

征能够提供较细致的退化信息。离散求导具有高通特性，会放大采样噪声和相邻测量点之间的波动。微分曲线通常需要经过平滑处理和特征点识别，其提取结果也会受到采样精度和预处理方式的影响 [28,50]。

基于充电时间、局部放电容量和能量效率构造的健康指标提供了其他类型的退化信息。恒流充电时间 (CCCT) 可以由电压到达窗口边界的时间差得到，窗口放电容量和能量效率则可以由电压、电流和时间记录计算。Richardson 等人 [28] 从恒流充电阶段的均匀电压区间中提取时间特征，用于电池容量估计。Lin 等人 [63] 采用恒流充电时间估计电池 SOH，Tian 等人 [51] 则通过搜索充电电压区间提高所提取特征与容量之间的相关性。这些研究表明，充电时间能够用较少的数值反映电池退化，其表征能力与所选电压区间密切相关。

现有 CCCT 及部分充电时间特征通常从预设电压区间中提取，也有研究根据选定电池上的相关性逐步优化窗口 [28,31,51,63]。不同数据集具有不同的电压平台、充电协议和老化轨迹，其退化敏感电压区间也会发生变化。同一数据集中的不同电池还可能表现出不同的相关性。由单节电池确定的高相关窗口，未必能够在同组其他电池上保持相同水平。因此，CCCT 窗口需要针对具体数据集进行标定，并由多节开发电池共同约束。

不同类型的 HIs 分别描述充电时序、电压平台、热响应、局部容量和能量转换过程。Li 等人 [52] 从充放电电流、电压和 IC 曲线中构造多类候选指标，Gu 等人 [35] 则从容量、电流、电压、采样时间和温度等信息中选择模型输入。多源候选池扩大了可用退化信息的范围，也可能包含弱相关或重复特征。皮尔逊相关系数 (PCC) 常用于衡量候选 HIs 与 SOH 之间的线性相关程度 [35,50]，斯皮尔曼相关系数 (SCC) 则衡量两者之间的单调关系。仅使用 PCC 可能遗漏具有非线性单调关系的指标，仅根据单节电池进行筛选也可能保留跨电池稳定性较低的特征。候选指标之间的高度相关还会造成输入信息重复。健康指标筛选需要同时考察候选指标在多节开发电池上的 PCC 和 SCC，并依据指标间相关关系筛除冗余信息 [31,48,53–55]。

在预测模型方面，卷积神经网络 (CNN)、循环神经网络 (RNN) 和 Transformer 等深度学习方法已被用于电池 SOH 估计 [14]。CNN 利用卷积核提取局部特征。例如，Qian 等人 [29] 采用一维 CNN 根据充电曲线片段估计电池容量，而 Lee 等人 [30] 则将跨循环容量衰减序列重构为矩阵，并采用二维 CNN 估计 SOH。然而，传统 CNN 并不擅长处理长时间序列，因为每层卷积通常只在有限的局部感受野内聚合信息，相距较远的特征需要经过多层网络才能融合 [31]。RNN 则通过递推更新隐藏状态，使历史信息能够沿时间步持续传递；LSTM 和 GRU 进一步利用门控机制选择性保留和更新这些信息，从而捕捉长期依赖和时序动态 [14]。尽管如此，循环状态仍需逐步更新，各时间步难以并行计算，长序列训练和推理的吞吐量因而受到限制 [31]。针对上述局限，Vaswani 等人 [34] 提出了 Transformer。该模型避免循环，转而利用自注意力捕捉全局依赖关系，并支持序列位置的并行计算。例如，Park 和 Kim [38] 采用物理先验引导的 Transformer 估计电池长期 SOH，Chen 等人 [37] 则将视觉 Transformer 用于 SOH 估计。

为兼顾局部特征提取和长期依赖建模，研究者进一步将不同网络结构进行组合。CNN-LSTM、CNN-BiLSTM 和 CNN-GRU 结合了卷积与循环结构 [33,41,42]，BiGRU-Transformer、CNN-Transformer 和卷积 Transformer 则进一步引入了自注意力机制 [32,35,36]。例如，Xu 等人 [41] 采用 CNN 提取局部特征，再利用 LSTM 建模时间依赖；Gu 等人 [35] 将 CNN 与 Transformer 结合，以融合局部特征和长程依赖。这些混合结构补充了单一模型的能力，但额外模块也增加了参数数量和计算开销 [31]。同时，标准自注意力需要计算所有序列位置之间的两两关系，其时间和存储开销随序列长度呈二次增长 [39,40]。上述资源开销增加了模型在资源受限 BMS 中的在线应用难度 [31]。

1.2 挑战分析与贡献

据此，当前数据驱动锂离子电池 SOH 估计面临的主要挑战可归纳为以下三点。

(1) **健康指标构建缺乏跨电池稳定性。**从多传感器收集的原始数据包含多样化的退化相关特征；然而，许多现有方法仍依赖单一或有限的数据源。此外，CCCT 通常从预设电压区间中提取，其窗口调整和候选健康指标筛选主要依据选定电池上的 PCC 或 SCC。单独使用一种相关系数只能考察线性关系或单调关系。只比较候选指标与 SOH 之间的相关性，也不能识别指标之间的重复信息。不同电池上的相关性结果还可能发生变化，影响模型输入的稳定性。

(2) **单一结构难以兼顾短期变化和长期趋势。**随着循环推进，电池容量整体呈下降趋势，并伴随相邻循环的波动和局部容量恢复。CNN 主要提取相邻循环的局部变化，RNN 和 Transformer 主要捕捉跨循环的长期变化。模型侧重局部变化时，不同退化阶段之间的联系难以充分建立；模型侧重长期变化时，相邻循环的波动和局部容量恢复容易被弱化。单一结构获得的退化信息因此不够完整，影响 SOH 估计的准确性。

(3) **模型精度提升伴随计算开销增加。**许多现有深度学习模型通过增加网络深度或组合不同网络结构提高 SOH 估计精度。这些方法增加了模型参数和计算操作。循环结构需要按时间步依次计算，标准自注意力需要计算所有序列位置之间的两两关系，其时间和存储开销随序列长度呈二次增长。这些开销加重了资源受限 BMS 的运行负担，限制了在线 SOH 估计模型的部署。

为应对上述挑战，本文提出一种以 MS-AgentNet 为核心的锂离子电池 SOH 估计框架。该框架从健康指标构建和轻量模型设计两个层面展开，分别通过组级标定与筛选提高模型输入的跨电池稳定性，并以较低计算开销提取局部变化和长期趋势。本文进一步在四个公开数据集的独立评价电池上检验上述设计。主要贡献如下。

(1) **提出组级健康指标选择算法。**该算法以特征开发电池集合上的相关性结果为依据，利用 MS-CCCT 标定充电时间特征的电压窗口，再通过 PCC/SCC 双阈值与冗余约束筛选候选指标。统一的筛选规则为各数据集确定相应的健康指标组合，入选指标在独立评价电池上仍保持较强的线性和单调相关性。

(2) **构建轻量级局部—全局网络 MS-AgentNet。**核心的局部—全局融合注意力用于捕获电池退化序列中的短期变化和长期趋势，并将注意力计算复杂度从二次 $O(N^2)$ 降至线性 $O(N)$ 。模型同时引入大核深度可分离卷积，与局部卷积共同提取不同尺度的退化特征，并减少卷积参数。上述设计共同形成紧凑的模型结构，增强了对电池退化特征的表征能力。

(3) **开展多数据集综合验证。**在具有不同材料、容量和充放电协议的多个公开数据集上开展独立电池评价，并进行模块消融、复杂度分析和跨数据集迁移实验，以评估所提方法的估计精度、计算效率和泛化能力。结果表明，所提框架在 SOH 估计精度和计算效率方面均优于多种对比模型，目标域观测进一步降低了跨数据集迁移误差。

2. SOH 估计框架与数据基础

2.1 整体 SOH 估计框架

电池健康状态 (state of health, SOH) 是衡量电池退化程度的重要指标。尽管目前尚缺乏统一的 SOH 定义，但电池容量仍是最常用的表征方式之一 [13, 14]。本文从容量衰减维度表征电池健康状态，并将当前可用容量与额定容量之比定义为 SOH：

$$\text{SOH} = \frac{C_{\text{current}}}{C_{\text{rated}}} \times 100\%, \quad (1)$$

其中， C_{current} 和 C_{rated} 分别表示电池当前可用容量和额定容量。

本文所建立的 SOH 估计流程如图 1 所示，具体步骤如下。

(1) **数据获取。**选取不同材料体系和运行工况下的公开电池老化数据，获取循环过程中的电压、电流、时间和容量等信息，并提取相应充放电过程数据，为健康指标构建和 SOH 估计提供数据基础。

(2) **健康指标构建。**从电池充放电过程中提取候选健康指标，利用 MS-CCCT 标定 CCCT 电压窗口，并结合 PCC/SCC 双阈值与冗余约束筛选模型输入。随后，采用滑动窗口将健康指标时间序列划分为输入样本，窗口每次向前移动一个循环，并将窗口后紧邻循环的真实 SOH 作为对应标签。

(3) **模型训练。**将构建的健康指标序列输入所提出的 MS-AgentNet，利用训练电池进行模型参数学习，并根据预先指定的配置选择电池确定模型配置。配置确定后保持冻结，并直接在独立评价电池上进行测试，以考察模型的跨电池估计性能。

(4) **性能评价。**从估计精度、计算效率和模型稳定性等方面评价所提方法，并与多种 SOH 估计模型进行比较。

2.2 典型电池数据集

公开电池老化数据为 SOH 估计方法的复现与横向比较提供了重要基础。为评估所提方法在不同电池体系和运行条件下的估计性能，选取 Oxford、CALCE CS2、CALCE CX2 和 MIT/Severson 四组公开电池老化数据进行实验。这些数据由牛津大学电池智能实验室、马里兰大学先进生命周期工程中心以及 MIT、Stanford University 和 Toyota Research Institute 等研究机构发布，具有规范的实验协议和较为完整的数据记录。四组数据在电芯类型、材料体系、容量规格、测试温度和充放电协议等方面存在差异，可用于考察所提方法在不同退化条件下的适用性与估计性能。各数据集的主要实验信息汇总于 Table 1；Fig. 2(a)–(d) 展示了四组数据中所




Fig. 1. Flowchart of the developed SOH estimation approach.

选电池的容量衰减曲线，Fig. 2(e)–(h) 展示了各数据集中代表性电池在不同 SOH 水平下的充电电压曲线。

Table 1

Description of the four battery datasets.

Item	Oxford	CALCE CS2	CALCE CX2	MIT/Severson
Data source	Oxford [60]	CALCE [18, 61]	CALCE [18, 61]	MIT / Stanford / TRI [62]
Cell type	Pouch cell	Prismatic cell	Prismatic cell	18650 cylindrical cell
Cathode material	NCO-LCO	LCO	LCO	LFP
Selected cell series	Cell1–Cell8	CS2_36–CS2_38	CX2_36–CX2_38	b3c8, b3c13, b3c29
Cell number	8	3	3	3
Rated capacity (Ah)	0.74	1.10	1.35	1.10
Capacity failure threshold	70%	0.84 Ah (76.4%)	1.08 Ah (80%)	80%
Charge protocol (rate)	CC (2C)	CC-CV (0.5C, 4.2 V)	CC-CV (0.5C, 4.2 V)	Multi-step fast charge + CC-CV (3.6 V)
Discharge protocol (rate)	ARTEMIS drive cycle	CC (1C)	CC (1C)	CC (4C)
Cut-off voltage (V)	Charge to 4.2 Discharge to 2.7	Charge to 4.2 Discharge to 2.7	Charge to 4.2 Discharge to 2.7	Charge to 3.6 Discharge to 2.0
Cut-off current (A)	—	0.05	0.05	0.022 (C/50)
Temperature (°C)	40	24	24	30
Total cycle number	8200 / 7700 / 8100 / 5100 / 5000 / 5000 / 8100 / 8100	976 / 1043 / 1082	1971 / 1281 / 1961	828 / 816 / 858




Fig. 2. Capacity degradation and charge-voltage curves of the four battery datasets.

2.2.1 Oxford 锂离子电池数据集

Oxford 数据集由牛津大学电池智能实验室提供，包含 8 节 Kokam SLPB533459H4 锂离子软包电池 [28]。电池负极采用石墨材料，正极为 NCO-LCO 混合体系 [60]，标称容量为 0.74 Ah，老化实验在 40 °C 条件下进行。充电过程采用 CC-CV 协议充至 4.2 V，随后按照源自城市 ARTEMIS 工况的动态电流曲线放电至 2.7 V [28, 61]。选取 Cell1–Cell8 的循环老化数据进行实验。

2.2.2 CALCE 锂离子电池数据集

CALCE CS2 与 CX2 数据集均来源于马里兰大学先进生命周期工程中心 (CALCE) [18, 61]。两组电池均为采用 LCO 正极材料的方形锂离子电池，标称容量分别约为 1.1 Ah 和 1.35 Ah，老化实验在约 24 °C 条件下开展。依据下载的 CALCE 原始数据记录，两组电池均采用 CC-CV 充电协议，以 0.5C 恒流充电至 4.2 V，随后保持恒压直至充电电流降至 0.05 A；选用的 CS2_36–CS2_38 和 CX2_36–CX2_38 均以 1C 恒流方式放电至 2.7 V。

2.2.3 MIT/Severson 锂离子电池数据集

MIT/Severson 数据集由 MIT、Stanford University 和 Toyota Research Institute 联合发布 [62]，包含 A123 APR18650M1A 型 18650 圆柱锂离子电池。该系列采用 LFP/石墨体系，标称容量约为 1.1 Ah，老化实验在 30 °C 条件下进行。充电采用一步或两步快速充电策略，其中两步策略按照 $C_1(Q_1) - C_2$ 方式以不同恒流倍率充至 80% SOC，随后以 1C CC-CV 方式完成充电；放电过程采用 4C 恒流方式，截止电压为 2.0 V。选取 b3c8、b3c13 和 b3c29 三节电池，其中 b3c8 采用 5.3C(54%)-4C 充电策略，b3c13 和 b3c29 采用 5.6C(36%)-4.3C 充电策略。

2.3 特征工程

本节从充放电数据中构建多源候选健康指标，其中 CCCT 的电压窗口由 MS-CCCT 依据多节特征开发电池的相关性评价结果进行标定。窗口确定后，结合候选指标与 SOH 的关联程度及指标间的冗余关系，确定各数据集的模型输入。

2.3.1 健康指标提取

本文从充电时间、增量容量、温度微分及局部充放电区间等特征类型 [52, 63–65] 出发，由充放电数据构建包含 15 项健康指标的候选池。充电侧候选健康指标包括由充电电压-时间 (CVT)、增量容量 (IC)、微分温度-电压 (DTV) 和微分温度-容量 (DTC) 曲线提取的时长、幅值、特征位置和分布宽度，放电侧候选健康指标包括窗口放电容量和能量效率，各指标的分类与定义见 Table 2。

充电电压-时间曲线记录恒流充电阶段端电压随时间的变化，可由电压与时间采样直接获得。随着循环推进，CVT 曲线在时间轴上的位置逐渐变化 (Fig. 3(b))，说明同一电压区间内的充电时长包含与容量衰减相关的信息，因此可从中提取恒流充电时间作为候选健康指标 [63, 64]。据此定义 CCCT：

$$CCCT(V_l, V_h) = t(V_h) - t(V_l), \quad (2)$$

其中， $t(V_l)$ 、 $t(V_h)$ 分别表示充电电压达到窗口上下边界的时刻。CCCT 的电压窗口由 MS-CCCT 进行标定，标定后得到的窗口充电时间记为 HI1。

除充电时序特征外，容量随电压的变化同样蕴含退化信息。增量容量 (IC) 曲线是解析电池电化学退化的经典分析手段。该方法对容量关于电压求导，将平缓的充电电压平台转化为辨识度更高的特征峰，其位置与形状随老化发生变化 [50, 64]。IC、DTV 和 DTC 均通过采样序列的差分近似计算，微分运算容易放大采样噪声 [28, 50]。因此，在差分计算前对相应序列进行滑动平均处理，滤波窗口设为 200 个采样点。IC 的具体表达式为：

$$IC = \frac{dQ}{dV} \approx \frac{Q_{k+N} - Q_k}{V_{k+N} - V_k}, \quad (3)$$

其中， V_k 、 Q_k 为第 k 个采样点的端电压和充电容量， N 为两个采样点之间的间隔。不同循环下 IC 曲线的峰值、特征位置和分布宽度随老化发生变化 (Fig. 3(a))，本文分别提取峰值、峰值对应电压和半峰宽，并将其定义为 HI2、HI3 和 HI4。

温度是反映电池内部状态的另一重要维度。恒流充电过程中，电池表面温度变化通常较为缓慢，老化带来的微小热响应差异难以通过原始温度曲线直接识别。微分温度-电压 (DTV) 曲线由 Wu 等人 [65] 提出，通过计算充电过程中电池表面温度相对电压的变化率，将热响应映射至电压域，并形成随老化变化的峰谷特征曲线 [64, 65]。其定义如下：

$$DTV = \frac{dT}{dV} \approx \frac{T_{k+N} - T_k}{V_{k+N} - V_k}, \quad (4)$$

其中， V_k 、 T_k 为第 k 个采样点的端电压和电池表面温度， N 为两个采样点之间的间隔。

不同循环下 DTV 曲线的峰谷幅值与特征位置呈现相应变化 (Fig. 3(c))。本文从中提取峰值 (HI5)、峰值对应电压 (HI6)、谷值 (HI7)、谷值对应电压 (HI8) 和峰谷差 (HI9)，分别描述热响应的幅值、特征位置及波动范围 [64]。

与 DTV 在电压域刻画热响应不同，DTC 在充电容量域刻画热响应。DTC 以充电容量为自变量，描述温度变化率随容量的演化，其定义如下 [64]：

$$DTC = \frac{dT}{dQ} \approx \frac{T_{k+N} - T_k}{Q_{k+N} - Q_k}, \quad (5)$$

其中, T_k 、 Q_k 为第 k 个采样点的电池表面温度和充电容量, N 为两个采样点之间的间隔。Fig. 3(d) 所示 DTC 曲线同样表现出随循环变化的峰值、特征位置和分布宽度, 本文据此提取峰值、峰值对应容量和半峰宽, 并将其定义为 HI10、HI11 和 HI12。

放电侧从容量保持与能量转换两个角度补充退化信息。放电容量指端电压由上限 V_h 降至下限 V_l 时释放的电荷量。该电荷量可由放电电流对时间的积分获得:

$$Q_{\text{dch}}(V_h, V_l) = \frac{1}{3600} \int_{\tau(V_h)}^{\tau(V_l)} |I_{\text{dch}}(t)| dt, \quad (6)$$

其中, $\tau(V_h)$ 与 $\tau(V_l)$ 分别表示放电过程中端电压达到上下限的时刻, $|I_{\text{dch}}(t)|$ 为放电电流幅值, 时间 t 以 s 为单位, Q_{dch} 的单位为 Ah。若放电过程中端电压多次穿越同一电压边界, 则对该电压区间内的电流进行累计积分。本文进一步构造两个窗口放电容量候选指标, 分别计算端电压由 3.80 V 降至 3.40 V 以及由 3.20 V 降至 3.00 V 过程中释放的电荷量, 并记为 HI13 和 HI14 [31, 52]。

能量效率反映电池在充放电过程中的能量转换特性, 定义为单次循环放电能量与充电能量之比 [66]:

$$\eta = \frac{E_{\text{dch}}}{E_{\text{ch}}} = \frac{\int_0^{t_{\text{dch}}} V_{\text{dch}}(t) |I_{\text{dch}}(t)| dt}{\int_0^{t_{\text{ch}}} V_{\text{ch}}(t) |I_{\text{ch}}(t)| dt}, \quad (7)$$

其中, $V_{\text{ch}}(t)$ 、 $|I_{\text{ch}}(t)|$ 、 t_{ch} 与 $V_{\text{dch}}(t)$ 、 $|I_{\text{dch}}(t)|$ 、 t_{dch} 分别表示充电与放电阶段的端电压、电流幅值和持续时间, 充电与放电均取完整循环过程。该能量效率记为 HI15 (η)。

2.3.2 组级双相关 MS-CCCT

已有研究常从预设充电电压区间提取 CCCT 或局部充电特征 [28, 63], 也有研究通过电压区间优化或逐级细化窗口提高特征相关性 [31, 51]。然而, 不同电池体系的退化敏感电压区间存在差异, 固定窗口可能遗漏与 SOH 密切相关的局部退化信息, 从而影响健康指标的跨电池稳定性。对于每个数据集, 将训练电池和配置选择电池共同组成特征开发电池集合 $\mathcal{B}$, 用于 CCCT 电压窗口标定和健康指标筛选; 独立评价电池不属于该集合。本文在覆盖相应充电电压范围的搜索区间内构建多尺度扫描窗口, 并利用集合内各电池的 PCC 和 SCC 自适应标定最优 CCCT 区间。

为比较不同候选窗口的有效性, 需要量化窗口特征与 SOH 之间的相关性。本文同时采用皮尔逊相关系数 (PCC) 和斯皮尔曼相关系数 (SCC) 作为评价依据: PCC 衡量线性相关强度, SCC 衡量单调相关强度, 二者可分别反映线性退化趋势和单调非线性退化特征 [25, 53, 55]。第 i 个候选窗口在第 j 个特征开发电池上的 PCC $\gamma_{i,j}$ 和 SCC $\rho_{i,j}$ 定义为

$$\gamma_{i,j} = \frac{\sum_{k=1}^{n_j} (f_{i,j,k} - \bar{f}_{i,j})(y_{j,k} - \bar{y}_j)}{\sqrt{\sum_{k=1}^{n_j} (f_{i,j,k} - \bar{f}_{i,j})^2 \sum_{k=1}^{n_j} (y_{j,k} - \bar{y}_j)^2}}, \quad (8)$$

$$\rho_{i,j} = \frac{\sum_{k=1}^{n_j} (R(f_{i,j,k}) - \bar{R}(f_{i,j}))(R(y_{j,k}) - \bar{R}(y_j))}{\sqrt{\sum_{k=1}^{n_j} (R(f_{i,j,k}) - \bar{R}(f_{i,j}))^2 \sum_{k=1}^{n_j} (R(y_{j,k}) - \bar{R}(y_j))^2}}, \quad (9)$$

式中, $f_{i,j,k}$ 表示第 j 个特征开发电池上第 i 个候选窗口在第 k 个循环的特征值, $y_{j,k}$ 为对应循环的 SOH, n_j 为第 j 个特征开发电池的有效循环数。 $\bar{f}_{i,j}$ 与 $\bar{y}_j$ 分别表示该电池上特征值与 SOH 的均值。 $R(\cdot)$ 表示取秩操作, $\bar{R}(\cdot)$ 为对应秩序列的均值。 $|\gamma_{i,j}|$ 越接近 1, 说明线性关联越强; $|\rho_{i,j}|$ 越接近 1, 说明单调关联越强。

为评价候选窗口在特征开发电池集合中的共同适用性, 将第 i 个候选窗口的最小绝对 PCC 和最小绝对

SCC 分别记为 $mPCC_i = \min_{j \in \mathcal{B}} |\gamma_{i,j}|$ 和 $mSCC_i = \min_{j \in \mathcal{B}} |\rho_{i,j}|$ ，并以二者中的较小值定义组级稳健得分：

$$S_i = \min_{j \in \mathcal{B}} \{\min(|\gamma_{i,j}|, |\rho_{i,j}|)\}. \quad (10)$$

该得分由候选窗口在全部特征开发电池上的最低相关性决定。只有当窗口特征在各特征开发电池上均与 SOH 保持较强的线性和单调关联时，才能获得较高的 S_i 。

MS-CCCT 采用由粗到细的多尺度搜索方式确定 CCCT 窗口 [31]。各阶段均以 S_i 作为窗口比较依据，并将当前阶段得分最高的窗口作为下一阶段的搜索区域。

搜索过程分为三个阶段。R1 阶段以 0.40 V 窗宽和 0.20 V 步长进行粗粒度扫描，将 S_i 最高的窗口作为父区域。R2 阶段在父区域内以 0.20 V 窗宽和 0.05 V 步长细化窗口。R3 阶段进一步以 0.10 V 窗宽和 0.05 V 步长考察更窄窗口能否提升相关性。若细化窗口的最高 S_i 未超过父窗口，则停止细化并保留父窗口。按照这一搜索过程，四个数据集分别获得不同的 CCCT 窗口 (Table 3)，说明退化敏感区间随数据集而变化，需要根据特征开发电池进行标定；各窗口的组级稳健得分均超过 0.98，表明相应 CCCT 在全部特征开发电池上均与 SOH 保持较强的线性和单调关联。

2.3.3 健康指标筛选

在 MS-CCCT 确定 HI1 的 CCCT 电压窗口后，进一步对 15 项候选健康指标执行统一的准入与冗余剔除。本文继续采用前述 PCC 和 SCC，分别评价候选健康指标与 SOH 之间的线性和单调关联，并考察候选指标之间的相关关系。上述相关系数均在每节特征开发电池上分别计算。

以 Oxford 数据集为例，Fig. 4 给出了 Cell1 和 Cell2 上 SOH 与 15 项候选健康指标以及候选指标之间的 PCC 和 SCC，其中矩阵下三角列出带符号的相关系数，上三角以圆圈大小和颜色深浅表示相关系数的绝对值。同一候选指标在两节电池上的相关强度并不完全一致：HI5 (DTV 峰值) 在 Cell1 上的 $|PCC|$ 和 $|SCC|$ 分别为 0.949 和 0.966，在 Cell2 上则降至 0.898 和 0.902，而 HI1 在两节电池上均保持较高相关性；同时，部分候选指标之间也具有较强的 PCC 和 SCC。前一现象说明单节电池上的高相关性未必能够延续至同组其他电池，后一现象则表明候选池中存在高度相关的信息，因而健康指标筛选需要同时考察跨电池相关性与指标间冗余。

针对上述两类情况，本文构建 PCC/SCC 双阈值—冗余约束健康指标筛选算法。该算法包括候选准入和冗余剔除两个阶段：在候选准入阶段，分别以 θ_{mono} 和 θ_{lin} 约束候选指标在全部特征开发电池上的最小 SCC 和最小 PCC，只有同时满足两项条件的指标才能进入候选集合，并按照 $R_i = \max(mPCC_i, mSCC_i)$ 确定考察顺序；在冗余剔除阶段，依次计算候选指标与已入选指标之间的组平均绝对 PCC 和 SCC，当两项相关系数均达到 θ_{co} 时，将该候选指标判定为冗余。三个阈值在模型开发阶段预先设定，并在四个数据集的筛选过程中保持不变，完整流程见 Algorithm 1。

按照 Algorithm 1，Oxford 和 CS2 最终保留充电侧候选指标，其中二者均入选 HI1，CS2 进一步入选 HI2；CX2 入选窗口放电容量 HI13，MIT/Severson 入选窗口放电容量 HI14 和能量效率 HI15 (Table 4)。相同筛选规则在四个数据集上形成不同的健康指标组合，说明候选指标的有效性与具体电池数据有关。为考察这些指标在特征开发电池之外的稳定性，在保持其定义和参数不变的条件下，进一步计算各指标在独立评价电池上的 PCC 和 SCC (Table 5)。Oxford Cell3–Cell8 上 HI1 的 $|\gamma|$ 和 $|\rho|$ 均高于 0.997，其余三个数据集独立评价电池上的最低 $|\gamma|$ 和 $|\rho|$ 分别为 0.932937 和 0.974359，表明最终入选指标在各自数据集的未见电池上仍保持较强的线性和单调关联。

除跨电池稳定性外，所选指标相对于已有健康指标的相关水平也是评价其有效性的依据。以能够获得逐电池文献结果的 Oxford 数据集为例，将本文 HI1 与样本熵、DTV/IC 特征及充电电压曲线斜率进行比较 (Table 6)。HI1 在 Cell3–Cell8 上的 $|PCC|$ 为 0.997874–0.999337，且均高于所列文献在相应电池上的已报道值，表明 MS-CCCT 所确定的充电时间指标在 Oxford 独立评价电池上具有较强且稳定的 SOH 线性关联。

注：“—”表示原文未报告相应电池的相关系数。

3. 所提出的 MS-AgentNet 模型

本章介绍 MS-AgentNet 的总体架构，并阐述所设计的包含 DSConv-S 和 DSConv-L 在内的多尺度深度可分离卷积模块；在此基础上，详细说明所提出的轻量级局部—全局融合注意力 (Slim Local-Global Fusion Attention, SLFA) 模块。

Table 2

Definitions of the candidate HIs.

No.	Category	Health indicator
HI1	CVT	MS-CCCT 标定电压区间内的 恒流充电时间
HI2	IC	增量容量曲线的峰值
HI3		增量容量峰值对应的电压
HI4		增量容量特征峰的半峰宽
HI5	DTV	微分温度-电压曲线的峰值
HI6		微分温度-电压曲线 峰值对应的电压
HI7		微分温度-电压曲线的谷值
HI8		微分温度-电压曲线 谷值对应的电压
HI9		微分温度-电压曲线的峰谷差
HI10	DTC	微分温度-容量曲线的峰值
HI11		微分温度-容量曲线 峰值对应的容量
HI12		微分温度-容量特征峰的半峰宽
HI13	窗口 放电容量	电压范围 3.80–3.40 V 内的 放电容量
HI14		电压范围 3.20–3.00 V 内的 放电容量
HI15	能量效率	单次循环放电能量与充电能量之比




Fig. 3. Charge-side characteristic curves used for HI construction.

Table 3

Calibration results of the MS-CCCT window.

Dataset	MS-CCCT window (V)	$mPCC$	$mSCC$	S_i
Oxford	3.55–3.75	0.997322	0.994447	0.994447
CS2	3.80–4.00	0.990286	0.980124	0.980124
CX2	3.85–4.05	0.985921	0.990832	0.985921
MIT/Severson	2.970–3.170	0.995272	0.994419	0.994419




Fig. 4. Correlation matrix of candidate HIs on the Oxford dataset.

Table 4

Selected HIs and their correlations.

Dataset	Selected HI	Feature-development cell	$ \gamma $	$ \rho $
Oxford	HI1	Cell1	0.998759	0.998710
		Cell2	0.997322	0.994447
CS2	HI1	CS2_36	0.990838	0.986319
		CS2_37	0.990286	0.980124
	HI2	CS2_36	0.940029	0.989905
		CS2_37	0.938326	0.988319
CX2	HI13	CX2_36	0.999080	0.998532
		CX2_37	0.997987	0.996442
MIT/Severson	HI14	b3c8	0.972972	0.995614
		b3c13	0.970917	0.997651
	HI15	b3c8	0.979188	0.988926
		b3c13	0.994096	0.995717

Algorithm 1: PCC/SCC dual-threshold health-indicator selection with redundancy constraints

行号	内容
输入	候选健康指标集合 $\mathcal{F}$; 特征开发电池集合 $\mathcal{B}$; 各候选指标在特征开发电池上的特征序列及对应 SOH 序列; 阈值 $\theta_{\text{mono}} = 0.96$ 、 $\theta_{\text{lin}} = 0.92$ 、 $\theta_{\text{co}} = 0.95$
输出	最终入选健康指标集合 $\mathcal{S}$
1	初始化候选集合 $\mathcal{C} = \emptyset$, 最终入选集合 $\mathcal{S} = \emptyset$
2	For 每个候选指标 $f_i \in \mathcal{F}$ do
3	计算组内最小单调相关性: $mSCC_i = \min_j \rho_{i,j} $
4	计算组内最小线性相关性: $mPCC_i = \min_j \gamma_{i,j} $
5	If $mSCC_i \geq \theta_{\text{mono}}$ 且 $mPCC_i \geq \theta_{\text{lin}}$ then
6	将 f_i 加入候选集合 $\mathcal{C}$
7	End If
8	End For
9	按 $R_i = \max(mPCC_i, mSCC_i)$ 对 $\mathcal{C}$ 降序排序
10	For 排序后的每个候选指标 $f_i \in \mathcal{C}$ do
11	计算 f_i 与每个已入选指标 $f_s \in \mathcal{S}$ 的组平均交叉相关绝对值 $\Phi_{\text{PCC}}(i, s)$ 和 $\Phi_{\text{SCC}}(i, s)$
12	If 存在 $f_s \in \mathcal{S}$ 使 $\Phi_{\text{PCC}}(i, s) \geq \theta_{\text{co}}$ 且 $\Phi_{\text{SCC}}(i, s) \geq \theta_{\text{co}}$ then
13	判定 f_i 为冗余指标并跳过
14	Else
15	将 f_i 加入最终入选集合 $\mathcal{S}$
16	End If
17	End For
18	Return $\mathcal{S}$

Table 5

Correlations of selected HIs on independent cells.

Cell	Selected HI	$ \gamma $	$ \rho $
Cell3	HI1	0.999052	0.999672
Cell4	HI1	0.998933	0.999884
Cell5	HI1	0.997874	1.000000
Cell6	HI1	0.998257	0.999877
Cell7	HI1	0.999337	0.999606
Cell8	HI1	0.999259	0.999699
CS2_38	HI1	0.986076	0.974359
CS2_38	HI2	0.932937	0.986793
CX2_38	HI13	0.999576	0.999062
b3c29	HI14	0.973516	0.996569
b3c29	HI15	0.990303	0.992179

Table 6

Absolute PCC comparison on the Oxford dataset.

Cell	HI	Sample entropy [67]	PP_{DRV} [68]	P_{IC} [68]	DTV peak position FV_6 [69]	Slope of charging voltage curve [70]
Cell3	0.999052	0.9876	0.9393	0.9729	0.964	0.9980
Cell4	0.998933	0.9885	0.9102	0.9817	0.972	—
Cell5	0.997874	0.9133	0.9574	0.9034	—	—
Cell6	0.998257	0.9848	0.9299	0.9788	—	—
Cell7	0.999337	0.9896	0.9676	0.9748	0.983	0.9982
Cell8	0.999259	0.9908	0.9654	0.9713	0.981	0.9979

3.1 MS-AgentNet 总体架构与数据流

针对现有 SOH 估计模型在估计精度与计算效率之间难以兼顾的问题，本文提出一种轻量级多尺度智能体网络（Multi-Scale Agent Network, MS-AgentNet）。该模型采用小核与大核深度可分离卷积提取不同时间尺度的退化特征，并结合 ReLU² 智能体注意力（ReLU² Agent Attention, RAA）进行跨位置全局信息交互。其中，“MS”表示由小核 DSConv-S 与大核 DSConv-L 构成的多尺度卷积设计。

MS-AgentNet 的整体架构如图 3-1 所示。健康指标（Health Indicators, HIs）序列经滑动窗口分割后，首先通过线性嵌入层映射至 d 维特征空间；随后，嵌入特征进入 MS-AgentNet Block，并在 Block 内依次完成局部一全局特征融合、长尺度特征细化与非线性映射。最后，模型对输出特征进行层归一化、展平和线性读出，得到 SOH 估计值。




Fig. 5. Framework of MS-AgentNet. (a) Overall architecture of MS-AgentNet; (b) core structure of an MS-AgentNet Block; (c) DSConv-L module.

训练过程中，每个输入窗口以窗口后紧邻循环的真实 SOH 值作为监督标签。

从数学角度看，设第 l 个 MS-AgentNet Block 的输入为 $\mathbf{X}_l \in \mathbb{R}^{B \times N \times d}$ ，其中 B 为批量大小， N 为输入序列长度， d 为嵌入维度。其内部特征变换可表示为以下过程：

步骤 1：局部一全局融合。输入特征先由 SLFA 模块完成小核局部增强和智能体全局交互：

$$\mathbf{X}'_l = \text{SLFA}(\mathbf{X}_l). \quad (3-1)$$

步骤 2：长尺度特征细化。为提取较长时间尺度的退化特征，中间特征 $\mathbf{X}'_l$ 先经层归一化，再通过 DSConv-L 模块，所得特征经可学习系数 W_l 缩放后，以残差形式与 $\mathbf{X}'_l$ 相加：

$$\mathbf{X}''_l = \mathbf{X}'_l + W_l \text{DSConv-L}(\text{LN}(\mathbf{X}'_l)). \quad (3-2)$$

步骤 3：非线性映射。细化后的特征 $\mathbf{X}''_l$ 经层归一化后输入 FFN，并通过残差连接得到输出 $\mathbf{Y}_l$ ：

$$\mathbf{Y}_l = \mathbf{X}''_l + \text{FFN}(\text{LN}_0(\mathbf{X}''_l)). \quad (3-3)$$

并令该 Block 的输出为 $\mathbf{X}_{l+1} = \mathbf{Y}_l$ 。其中， $\text{SLFA}(\cdot)$ 、 $\text{DSConv-L}(\cdot)$ 和 $\text{FFN}(\cdot)$ 分别表示轻量级局部一全局融合注意力模块、大核深度可分离卷积模块和前馈神经网络； W_l 为可学习缩放系数， $\text{LN}(\cdot)$ 表示层归一化， $\text{LN}_0(\cdot)$ 表示不含可学习仿射参数的层归一化。

3.2 所设计的多尺度深度可分离卷积模块

本节首先介绍 DSConv 的基本结构, 并将其与标准卷积进行计算量比较; 随后说明 DSConv-S 和 DSConv-L 的结构配置及其多尺度特性。




Fig. 6. The fundamental structures of convolutional modules: (a) standard convolution; (b) standard depthwise separable convolution; (c) DSConv-S module; and (d) DSConv-L module.

3.2.1 DSConv 基本结构与计算量比较

卷积运算通过滑动卷积核提取时间序列中的局部信息 [71]。标准卷积在所有输入通道上进行运算, 每个卷积核生成一个输出特征图, 对应一个输出通道。随着输入通道数、输出通道数和卷积核尺寸增加, 其参数量与计算开销迅速累积, 显著推高计算负载并延长训练时间。在小样本电池数据集上, 较大的参数量还可能增加模型的过拟合风险。其计算成本可表示为:

$$C_{\text{Conv}} = k \times k \times C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F. \quad (3-4)$$

其中, k 、 C_{in} 、 C_{out} 和 D_F 分别表示卷积核大小、输入通道数、输出通道数和特征图尺寸。

与标准卷积不同, 深度可分离卷积 (DSConv) 将卷积运算分解为深度卷积和逐点卷积两个阶段 [71]。其中, 深度卷积为每个输入通道单独配置卷积核, 在通道内完成局部特征提取; 随后, 1×1 逐点卷积融合不同通道的特征, 并将通道数调整为 C_{out} 。通过分离通道内特征提取与通道间特征融合, DSConv 减少了标准卷积中的密集跨通道运算。其计算成本可表示为:

$$C_{\text{DSConv}} = k \times k \times C_{\text{in}} \times D_F \times D_F + C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F. \quad (3-5)$$

进一步比较两类卷积的计算量, 可得二者之比为:

$$\begin{aligned} \frac{C_{\text{DSConv}}}{C_{\text{Conv}}} &= \frac{k \times k \times C_{\text{in}} \times D_F \times D_F + C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F}{k \times k \times C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F} \\ &= \frac{1}{C_{\text{out}}} + \frac{1}{k^2}. \end{aligned} \quad (3-6)$$

由式 (3-6) 可知, 在输入、输出通道配置一致的情况下, DSConv 的计算成本低于标准卷积, 为后续小核与大核卷积模块的构建提供了基础。

3.2.2 DSConv-S: 双重作用的局部增强

小核 DSConv-S 采用紧凑的 1×5 深度卷积, 并嵌入 SLFA 模块、位于 RAA 全局交互之前, 以实现输入增强与局部分支保留两项作用:

1. **输入增强。** DSConv-S 提取输入特征中的局部邻域信息, 形成局部增强表示 $\mathbf{X}_S$ 。RAA 随后基于 $\mathbf{X}_S$ 构造查询、键和值, 并通过智能体聚合与广播完成跨位置交互。这一前置卷积为 RAA 引入局部性偏置, 增强其

在跨位置上下文聚合过程中对局部变化的表征。

2. **局部分支保留**。在 SLFA 中， $\mathbf{X}_S$ 同时传递至 RAA 分支和局部分支。局部分支对 $\mathbf{X}_S$ 进行层归一化后传递至融合端，并与 RAA 分支建立的跨位置上下文进行融合，形成局部特征与全局信息的互补表示。

DSConv-S 采用两倍通道扩展。输入首先经转置使特征维度对应卷积通道维度，再通过第一层 1×1 逐点卷积完成通道扩展。随后， 1×5 深度卷积在各通道内提取短邻域特征，并经 ReLU 激活；第二层 1×1 逐点卷积进一步融合通道信息并恢复输出维度。最后，输出经逆转置后与输入通过残差连接融合。上述过程表示为：

$$\mathbf{X}_S = \mathbf{X} + \mathcal{T}^{-1}[\text{PW}_{\downarrow}(\text{ReLU}(\text{DW}_5(\text{PW}_{\uparrow}(\mathcal{T}(\mathbf{X})))))] \quad (3-7)$$

其中， $\text{PW}_{\uparrow}$ 和 $\text{PW}_{\downarrow}$ 分别表示通道扩展和通道恢复的逐点卷积， DW_5 表示尺寸为 1×5 的深度卷积， $\mathcal{T}(\cdot)$ 与 $\mathcal{T}^{-1}(\cdot)$ 分别表示转置和逆转置操作。为便于后文表述，将上述过程简记为

$$\mathbf{X}_S = \text{DSConv-S}(\mathbf{X}).$$

计算分析。在两倍通道扩展条件下，DSConv-S 的计算成本主要来自两层 1×1 逐点卷积和一层 1×5 深度卷积，可表示为：

$$C_{\text{in}} \times 2C_{\text{out}} \times D_F \times D_F + 1 \times 5 \times 2C_{\text{out}} \times D_F \times D_F + 2C_{\text{out}} \times C_{\text{out}} \times D_F \times D_F,$$

其中， $2C_{\text{out}}$ 和 $D_F \times D_F$ 分别表示扩展后的通道数和特征图尺寸。

3.2.3 DSConv-L：后融合长尺度细化

大核 DSConv-L 作为独立的特征细化模块置于 SLFA 之后。凭借较大的感受野，DSConv-L 提取融合表示中较长时间尺度的退化特征，并完成融合细化。

DSConv-L 同样按照“通道扩展—卷积特征提取—通道恢复”的顺序组织，并采用三倍通道扩展和 1×31 深度卷积。其计算过程表示为：

$$\text{DSConv-L}(\mathbf{X}) = \mathcal{T}^{-1}[\text{PW}_{L,\text{out}}(\text{ReLU}(\text{DW}_{31}(\text{PW}_{L,\uparrow}(\mathcal{T}(\mathbf{X})))))] \quad (3-8)$$

其中， $\text{PW}_{L,\uparrow}$ 和 $\text{PW}_{L,\text{out}}$ 分别表示通道扩展和通道恢复的逐点卷积， DW_{31} 表示尺寸为 1×31 的大核深度卷积。

计算分析。在三倍通道扩展条件下，DSConv-L 的计算成本可表示为：

$$C_{\text{in}} \times 3C_{\text{out}} \times D_F \times D_F + 1 \times 31 \times 3C_{\text{out}} \times D_F \times D_F + 3C_{\text{out}} \times C_{\text{out}} \times D_F \times D_F,$$

其中， $3C_{\text{out}}$ 和 $D_F \times D_F$ 分别表示扩展后的通道数和特征图尺寸。

3.3 所提出的轻量级局部—全局融合注意力模块

本节给出多头自注意力的一般形式，简要比较 Softmax 注意力与线性注意力，并在此基础上介绍所提出的 SLFA 模块。该模块兼顾局部—全局特征建模与计算效率。

3.3.1 多头自注意力的一般形式

多头自注意力通过多个并行注意力头在不同表示子空间内计算特征之间的相关性 [34]。设输入特征为 $\mathbf{X} \in \mathbb{R}^{N \times d}$ ，第 i 个注意力头的查询、键和值表示为：

$$\mathbf{Q}_i = \mathbf{X}\mathbf{W}_i^Q, \quad \mathbf{K}_i = \mathbf{X}\mathbf{W}_i^K, \quad \mathbf{V}_i = \mathbf{X}\mathbf{W}_i^V. \quad (3-9)$$

其中， N 为序列长度， d 为输入特征维度， $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V \in \mathbb{R}^{d \times d_h}$ 为可学习投影矩阵， $i = 1, 2, \dots, h$ ， h 为注意力头数， $d_h = d/h$ 为单个注意力头的特征维度。

在采用非负相似度函数构造归一化注意力权重时，第 i 个注意力头在第 p 个位置的输出可表示为：




Fig. 7. 不同注意力机制的结构对比：（a）Softmax 注意力；（b）线性注意力；（c）智能体注意力；（d）所提出的 SLFA 模块。

$$\mathbf{O}_{i,p} = \frac{\sum_{j=1}^N \text{Sim}(\mathbf{Q}_{i,p}, \mathbf{K}_{i,j}) \mathbf{V}_{i,j}}{\sum_{j=1}^N \text{Sim}(\mathbf{Q}_{i,p}, \mathbf{K}_{i,j})}, \quad p = 1, 2, \dots, N. \quad (3-10)$$

其中， $\mathbf{Q}_{i,p}$ 表示第 i 个注意力头中第 p 个位置的查询， $\mathbf{K}_{i,j}$ 和 $\mathbf{V}_{i,j}$ 分别表示第 j 个位置的键和值， $\text{Sim}(\cdot, \cdot)$ 表示非负相似度函数 [40]。

所有位置的输出共同构成第 i 个注意力头的输出矩阵 $\mathbf{O}_i \in \mathbb{R}^{N \times d_h}$ ，各注意力头的输出随后沿特征维度拼接。不同注意力机制的主要区别在于相似度函数及其计算顺序。

3.3.2 Softmax 注意力与线性注意力

标准 Softmax 注意力通过查询与键的点积计算序列位置之间的相关性，并利用 Softmax 函数对相关性得分进行归一化 [34]。第 i 个注意力头的输出可表示为：

$$\mathbf{O}_i = \text{Softmax} \left(\frac{\mathbf{Q}_i \mathbf{K}_i^T}{\sqrt{d_h}} \right) \mathbf{V}_i. \quad (3-11)$$

Softmax 中的指数映射与归一化使相关性较高的查询—键对获得更大的注意力权重 [34]。然而， $\mathbf{Q}_i \mathbf{K}_i^T$ 需要计算所有查询与键之间的两两关系，并形成尺寸为 $N \times N$ 的注意力矩阵。因此，单个注意力头的计算复杂度为 $O(N^2 d_h)$ ，相关性矩阵的存储复杂度为 $O(N^2)$ ；随着序列长度增加，其计算与存储开销会显著增大 [34, 39]。

针对 Softmax 注意力的二次计算开销，线性注意力利用核函数 $\phi(\cdot)$ 映射查询和键，并借助矩阵乘法结合律重新组织计算顺序 [40]。第 i 个注意力头的输出可写为：

$$\mathbf{O}_i = \frac{\phi(\mathbf{Q}_i) [\phi(\mathbf{K}_i)^T \mathbf{V}_i]}{\phi(\mathbf{Q}_i) [\phi(\mathbf{K}_i)^T \mathbf{1}]} \quad (3-12)$$

其中， $\phi(\cdot)$ 表示非负特征映射，例如 $\phi(\mathbf{x}) = \text{ELU}(\mathbf{x}) + 1$ ； $\mathbf{1}$ 表示全 1 向量，用于计算对应的归一化项 [40]。

通过优先计算 $\phi(\mathbf{K}_i)^T \mathbf{V}_i$ ，线性注意力避免了完整 $N \times N$ 注意力矩阵的构造。当特征映射维度与 d_h 一致时，其计算复杂度为 $O(N d_h^2)$ ；当 d_h 固定时，该复杂度关于序列长度 N 为线性 [40]。

线性注意力以较低计算复杂度完成全局信息交互，但其计算过程未显式引入局部邻域特征 [31, 39, 40, 64]。因此，需要进一步协同建模跨位置交互与局部特征。

3.3.3 所提出的 SLFA 模块

为同时捕获局部邻域特征与跨位置交互，本文将 DSConv-S 与所构建的 ReLU² 智能体注意力 (ReLU² Agent Attention, RAA) 相结合，提出 SLFA 模块，其结构如图 3-3 (d) 所示。该模块采用局部分支与 RAA 分支的融合形式 [45]：DSConv-S 首先提取局部表示，RAA 随后以该表示为输入完成跨位置特征交互，两个分支的输出经加法融合。

(1) ReLU² 智能体注意力。

Agent Attention 以少量智能体作为信息中介，将序列位置之间的全局交互分解为上下文聚合与信息广播两个阶段 [46]：智能体首先从键和值中聚合序列上下文，各查询位置随后从智能体上下文中读取信息。标准 Agent Attention 在两个阶段均采用 Softmax 归一化，本文则采用 ReLU² 行归一化，以抑制非正相关性并突出高相关性位置，由此构建 RAA。

为降低查询、键和值生成过程中的参数开销，RAA 采用可学习通道缩放调节不同特征通道的相对贡献，并将缩放后的特征划分至各注意力头：

$$\mathbf{Q}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_q), \quad \mathbf{K}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_k), \quad \mathbf{V}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_v). \quad (3-13)$$

其中， $\mathbf{s}_q, \mathbf{s}_k, \mathbf{s}_v \in \mathbb{R}^d$ 为可学习通道缩放向量， $\odot$ 表示逐元素相乘， $\text{Split}_i(\cdot)$ 表示沿特征维度划分为 h 个 d_h 维子空间并取第 i 个子空间。

相较于标准查询、键和值线性投影约 $3d^2$ 的参数量，三组通道缩放向量仅包含 $3d$ 个参数，从而降低了查询、键和值生成过程中的参数开销。

RAA 设置 $n_a = 2$ 个可学习智能体，并以全局共享的静态矩阵 $\mathbf{A} \in \mathbb{R}^{n_a \times d}$ 表示。

沿特征维度将全局智能体矩阵 $\mathbf{A}$ 划分为 h 个子空间，第 i 个注意力头对应的智能体表示为 $\mathbf{A}_i = \text{Split}_i(\mathbf{A}) \in \mathbb{R}^{n_a \times d_h}$ 。聚合与广播阶段均采用 ReLU² 行归一化：

$$[\mathcal{R}_2(\mathbf{Z})]_{r,c} = \begin{cases} \frac{\text{ReLU}(\mathbf{Z}_{r,c})^2}{\sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2}, & \sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2 > 0, \\ \frac{1}{M}, & \sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2 = 0. \end{cases} \quad (3-14)$$

其中， M 表示每一行参与归一化的元素数量：在智能体聚合阶段， $M = N$ ；在信息广播阶段， $M = n_a$ 。ReLU 截断非正相关性得分，平方操作进一步扩大正相关性得分之间的差异，使归一化权重更加突出高相关性位置。当某一行不存在正相关性得分时， $\mathcal{R}_2(\cdot)$ 返回均匀分布，以保持归一化结果的有效性。

在智能体聚合阶段， $\mathbf{A}_i$ 作为查询，从序列的键和值中汇集上下文：

$$\Phi_{k,i} = \mathcal{R}_2\left(\frac{\mathbf{A}_i \mathbf{K}_i^T}{\sqrt{d_h}}\right), \quad \mathbf{V}_{A,i} = \Phi_{k,i} \mathbf{V}_i. \quad (3-15)$$

其中， $\Phi_{k,i} \in \mathbb{R}^{n_a \times N}$ 表示智能体对各序列位置的聚合权重， $\mathbf{V}_{A,i} \in \mathbb{R}^{n_a \times d_h}$ 表示聚合得到的智能体上下文。

在信息广播阶段，各查询位置根据自身特征从智能体上下文中读取信息：

$$\Phi_{q,i} = \mathcal{R}_2\left(\frac{\mathbf{Q}_i \mathbf{A}_i^T}{\sqrt{d_h}}\right), \quad \mathbf{O}_i = \Phi_{q,i} \mathbf{V}_{A,i}. \quad (3-16)$$

其中， $\Phi_{q,i} \in \mathbb{R}^{N \times n_a}$ 表示各查询位置对智能体的广播权重， $\mathbf{O}_i \in \mathbb{R}^{N \times d_h}$ 为第 i 个注意力头的输出。由于广播权重沿智能体维度逐行归一化，不同查询位置能够形成各自的智能体权重分配。

由式 (3-15) 和式 (3-16) 可知，从等效映射角度看，第 i 个注意力头中智能体介导的序列交互可表示为 $\Phi_{q,i} \Phi_{k,i} \in \mathbb{R}^{N \times N}$ ，其秩不超过智能体数量 n_a 。

各注意力头的输出沿特征维度拼接，并通过可学习输出缩放向量 $\mathbf{s}_o$ 调节通道响应，随后与输入特征进行残差相加：

$$\text{RAA}(\mathbf{X}) = \mathbf{X} + \text{Concat}(\mathbf{O}_1, \dots, \mathbf{O}_h) \odot \mathbf{s}_o. \quad (3-17)$$

其中， $\text{Concat}(\cdot)$ 表示沿特征维度拼接各注意力头的输出， $\mathbf{s}_o \in \mathbb{R}^d$ 为可学习输出缩放向量。式 (3-17) 通过残差连接融合输入特征与多头智能体交互结果。

RAA 在聚合与广播阶段分别生成 $n_a \times N$ 和 $N \times n_a$ 相关性矩阵。由此，单个注意力头的计算复杂度为 $O(Nn_ad_h)$ ， h 个注意力头的总计算复杂度为 $O(hNn_a d_h)$ ，相关性权重的存储规模为 $O(hNn_a)$ 。当 h 和 n_a 固定时，计算量与存储量均随序列长度 N 线性增长。

(2) 局部—全局特征融合。

输入特征 $\mathbf{X}$ 首先经 DSConv-S 得到局部表示 $\mathbf{X}_S = \text{DSConv-S}(\mathbf{X})$ ，随后分别进入局部分支和 RAA 分支。局部分支对 $\mathbf{X}_S$ 进行层归一化，RAA 分支通过智能体聚合与信息广播建立跨位置特征交互。SLFA 的融合输出 $\mathbf{X}_F$ 计算如下：

$$\mathbf{X}_F = \text{LN}(\mathbf{X}_S) + W_a \text{Dropout}(\text{RAA}(\mathbf{X}_S)). \quad (3-18)$$

其中， $\mathbf{X}_F$ 表示 SLFA 的融合输出， $\text{LN}(\mathbf{X}_S)$ 为局部分支的归一化表示， $\text{RAA}(\mathbf{X}_S)$ 为 RAA 分支输出； $\text{Dropout}(\cdot)$ 用于训练阶段的正则化 [75]， W_a 为调节 RAA 分支贡献的可学习缩放系数。

这种加性连接保留了 DSConv-S 提取的局部退化特征，并融合 RAA 建立的跨位置上下文，在形成局部—全局联合表示的同时，保持关于序列长度 N 的线性计算复杂度。

4. 实验结果与分析

本节在四个公开电池数据集上对所提出的 MS-AgentNet 进行系统评估，并与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种基线模型进行比较。各数据集分别设置训练电池、配置选择电池和独立评价电池：Oxford 采用 Cell1、Cell2 和 Cell3-Cell8；CALCE CS2 采用 CS2_36、CS2_37 和 CS2_38；CALCE CX2 采用 CX2_36、CX2_37 和 CX2_38；MIT/Severson 采用 b3c8、b3c13 和 b3c29。上述各组电池依次承担三类角色，模型开发完成后不再进行额外调优。

在报告 SOH 估计精度的基础上，进一步考察模型的稳定性、跨电池泛化性能与跨数据集迁移能力，并通过消融研究和复杂度比较，分析其性能提升的结构来源与轻量化特性。

4.1 评价指标

采用 SOH 估计研究中常用的平均绝对误差 (MAE)、平均绝对百分比误差 (MAPE)、均方根误差 (RMSE) 和决定系数 (R^2) 评价模型性能 [76]。

MAE 表示全部评价样本中预测 SOH 与真实 SOH 之间绝对误差的平均值，用于反映模型的整体误差水平。该指标不会进一步放大单个较大偏差，能够较为直观地衡量总体估计精度。

MAPE 通过真实 SOH 对绝对误差进行归一化，并以百分比形式表示预测精度，便于比较不同数据集上的估计性能。当真实 SOH 接近零时，MAPE 可能被显著放大，需结合 MAE 和 RMSE 进行综合评价。

RMSE 表示预测 SOH 与真实 SOH 之间均方误差的平方根。与 MAE 相比，RMSE 对较大的预测偏差赋予更高权重，可以进一步反映模型对较大误差的控制能力。

R^2 衡量模型对真实 SOH 变化的拟合程度，其值越接近 1，表明模型对整体退化趋势的拟合效果越好。

上述四项指标的数学定义如下：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (11)$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (12)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (14)$$

其中， y_i 和 $\hat{y}_i$ 分别表示第 i 个样本的真实 SOH 和预测 SOH， $\bar{y}$ 表示评价样本中真实 SOH 的平均值， n 表示评价样本总数。

4.2 模型训练鲁棒性与超参数分析

4.2.1 智能体矩阵初始化与收敛性分析

为评估 MS-AgentNet 的训练稳定性，本文利用训练日志中提取的定量指标，分析智能体矩阵的初始化策略和模型的收敛行为。

初始化策略。RAA 将智能体表示为与输入无关的静态可学习矩阵 $\mathbf{A} \in \mathbb{R}^{n_a \times d}$ ，该矩阵直接参与全局特征聚合，智能体数量固定为 $n_a = 2$ 。矩阵参数采用均值为 0、标准差为 0.02 的普通正态分布初始化：

$$A_{ij} \sim \mathcal{N}(0, 0.02^2) \quad (15)$$

其中， A_{ij} 表示第 i 个智能体在第 j 个特征维度上的参数。该设置为不同智能体提供小尺度随机初值。

在 Oxford 数据集上比较普通正态、截断正态和 Xavier 均匀初始化。三种策略均使用 Cell1 训练，并以 Cell2 评价配置选择性能，具体结果见 Table 7。

Table 7

Initialization strategy comparison on the Oxford dataset.

Initialization	Threshold epoch median (range)	Late mean loss median	Late loss std. median	R^2 mean $\pm$ std.	RMSE mean $\pm$ std.	MAE mean $\pm$ std.
Normal $\mathcal{N}(0, 0.02^2)$	18 (14–22)	9.5535×10^{-4}	2.6246×10^{-4}	0.98606 ± 0.00411	0.00784 ± 0.00116	0.00490 ± 0.00054
Truncated normal ($\pm 2\sigma$)	18 (13–22)	9.4815×10^{-4}	2.6516×10^{-4}	0.98645 ± 0.00371	0.00774 ± 0.00103	0.00485 ± 0.00048
Xavier uniform	18 (14–22)	9.5526×10^{-4}	2.6340×10^{-4}	0.98527 ± 0.00462	0.00805 ± 0.00126	0.00499 ± 0.00058

Note: The three strategies are evaluated under five matched random seeds. Standard deviations are population standard deviations.

三种策略的阈值轮次中位数均为 18，后期损失标准差中位数为 $2.62 \times 10^{-4} \sim 2.65 \times 10^{-4}$ ，Cell2 上的平均 R^2 为 $0.98527 \sim 0.98645$ 。三种策略获得了相近的训练和估计结果，本文沿用普通正态初始化作为默认设置。

收敛特性。为量化收敛速度，定义相对收敛阈值，即训练损失首次下降至首轮损失 10% 以下的训练轮次。最后 20 个训练轮次的损失均值和标准差用于表征后期收敛阶段的损失水平和波动。

Table 8

Convergence characteristics of MS-AgentNet.

数据集	10% 阈值轮次中位数	阈值轮次范围	后期平均损失中位数	后期损失标准差中位数
Oxford	26	18–35	8.14×10^{-4}	2.38×10^{-4}
MIT	7	6–8	5.84×10^{-5}	4.84×10^{-6}

Note: Statistics are calculated from runs using five different random seeds. The threshold-epoch range is reported as the minimum–maximum.

Oxford 和 MIT 数据集上的阈值轮次中位数分别为 26 和 7，后期损失标准差中位数分别为 2.38×10^{-4} 和 4.84×10^{-6} ，各次训练均达到所定义的相对收敛阈值。

4.2.2 超参数搜索与配置选择

为确定 MS-AgentNet 的模型配置，本文以 CS2_37 作为配置选择电池，对学习率、网络深度 L 、嵌入维度 d 和全连接层维度进行网格搜索，搜索范围见 Table 9。

Table 9

Hyperparameter search space of MS-AgentNet.

超参数	搜索空间
学习率	0.001, 0.01
网络深度 L	1, 2, 4, 8
嵌入维度 d	16, 32, 64, 128
全连接层维度	16, 32, 64, 128

Fig. 8展示了 MS-AgentNet 在不同网络深度 L 和嵌入维度 d 下的验证结果。对于每组 (L, d) ，图中数值表

示该组合在不同学习率和全连接层维度下取得的最高 R^2 ，用于比较结构深度和表示维度对模型验证性能的影响。




Fig. 8. Validation results of MS-AgentNet under different hyperparameter settings.

从整体分布来看，不同结构参数组合的验证性能差异较小。较为紧凑的特征空间已经能够有效表征电池退化动态，扩大网络深度和嵌入维度未带来稳定的性能增益。后续实验据此统一采用 $d = 16$ 、 $L = 1$ 的基础结构。

4.3 SOH 估计精度与跨电池泛化性能比较

4.3.1 Oxford 数据集上的估计精度分析

为比较不同序列建模结构的 SOH 估计性能，本文选取 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种基线模型与 MS-AgentNet 进行对比，五种模型的层配置如 Table 10 所示。本节评价对象为 Oxford Cell3-Cell8 独立评价电池。

Fig. 9 和 Table 11 展示了 MS-AgentNet、CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 在 Oxford 数据集上的 SOH 估计结果和误差。


如图 9 所示，五种模型均能够跟踪 Oxford 电池的总容量衰减趋势，但在局部变化区间和预测误差分布上存在差异。在 Cell3-Cell6 上，MS-AgentNet 的误差分布整体较为集中。Table 11 的五次独立实验平均结果显示，该模型在这四颗电池上的 R^2 、MAE、MAPE 和 RMSE 均为最优。

值得注意的是，Cell4 的局部偏离和 Cell6 后段的快速下降使不同模型表现出不同程度的跟踪偏差。局部放大结果显示，MS-AgentNet 在上述变化区间与真实 SOH 保持了较好的贴合，并在两颗电池上均取得最优的四项评价指标。其中，Cell4 的 MAE 和 RMSE 分别为 0.00814 和 0.00873，Cell6 分别为 0.00593 和 0.00842。


Table 10

Layer configurations of different deep learning models.


MS-AgentNet	CNN-Transformer	Transformer	CNN-LSTM	LSTM
Input	Input	Input	Input	Input
Embedding layer (16)	Embedding layer (16)	Embedding layer (16)	Conv1D + ReLU	Linear layer (16)
SLFA module	Positional encoder	Positional encoder	MaxPooling1D	$5 \times$ LSTM layer (16)
DSConv-L module	Softmax attention	Softmax attention	$3 \times$ Conv1D + ReLU	Linear layer
Add & Norm	$2 \times$ Conv1D + ReLU	Add & Norm	$3 \times$ LSTM layer (16)	
FFN	MLP	MLP	Linear layer	
Add & Norm	Transformer decoder	Add & Norm		
Linear layer	Linear layer	Transformer decoder		
		Linear layer		




(a) Cell3




(b) Cell4




(c) Cell5



(d) Cell6



(e) Cell7



(f) Cell8

Fig. 9. SOH estimation results of different models on the Oxford dataset.

Table 11

SOH estimation errors of different models on the Oxford dataset.

Cell	Method	R^2	MAE	MAPE	RMSE
Cell3	MS-AgentNet	0.99668	0.00280	0.00333	0.00351
	CNN-Transformer	0.99523	0.00335	0.00396	0.00420
	CNN-LSTM	0.99501	0.00343	0.00404	0.00429
	Transformer	0.99472	0.00362	0.00423	0.00440
	LSTM	0.99529	0.00327	0.00390	0.00418
Cell4	MS-AgentNet	0.97217	0.00814	0.00960	0.00873
	CNN-Transformer	0.96942	0.00819	0.00969	0.00914
	CNN-LSTM	0.96712	0.00871	0.01026	0.00949
	Transformer	0.96931	0.00820	0.00966	0.00916
	LSTM	0.96267	0.00937	0.01103	0.01011
Cell5	MS-AgentNet	0.99291	0.00302	0.00343	0.00353
	CNN-Transformer	0.99002	0.00344	0.00389	0.00417
	CNN-LSTM	0.98912	0.00351	0.00397	0.00434
	Transformer	0.98727	0.00391	0.00437	0.00468
	LSTM	0.99036	0.00355	0.00400	0.00412
Cell6	MS-AgentNet	0.96968	0.00593	0.00705	0.00842
	CNN-Transformer	0.96442	0.00646	0.00764	0.00911
	CNN-LSTM	0.96226	0.00650	0.00771	0.00939
	Transformer	0.96402	0.00696	0.00815	0.00917
	LSTM	0.95868	0.00626	0.00747	0.00983
Cell7	MS-AgentNet	0.97412	0.00802	0.00923	0.00829
	CNN-Transformer	0.97781	0.00731	0.00841	0.00766
	CNN-LSTM	0.97081	0.00841	0.00964	0.00880
	Transformer	0.97750	0.00719	0.00830	0.00769
	LSTM	0.96768	0.00886	0.01016	0.00926
Cell8	MS-AgentNet	0.99407	0.00389	0.00444	0.00472
	CNN-Transformer	0.99434	0.00384	0.00442	0.00462
	CNN-LSTM	0.99207	0.00445	0.00508	0.00548
	Transformer	0.99528	0.00326	0.00377	0.00422
	LSTM	0.99115	0.00474	0.00539	0.00579
Average	MS-AgentNet	0.98327	0.00530	0.00618	0.00620
	CNN-Transformer	0.98187	0.00543	0.00633	0.00649
	CNN-LSTM	0.97940	0.00584	0.00678	0.00696
	Transformer	0.98135	0.00552	0.00641	0.00655
	LSTM	0.97764	0.00601	0.00699	0.00722

Note: Results are averaged over five independent runs. The best results are shown in bold.

对于退化轨迹相对平滑的 Cell3 和 Cell5，各模型均能够较好地跟踪总体变化。对于 Cell7 和 Cell8，各模型均能够跟踪整体容量衰减趋势，但预测偏差的方向有所不同。Cell7 中，各模型的预测曲线整体低于真实 SOH，表现出较为一致的低估偏差；Cell8 中，预测曲线在真实 SOH 两侧波动，未呈现固定的偏差方向。

从六颗独立评价电池的平均结果来看，MS-AgentNet 取得了 0.98327 的平均 R^2 ，其平均 MAE、RMSE 和 MAPE 分别为 0.00530、0.00620 和 0.00618，均在五种模型中排名第一。与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 相比，其平均 MAE 分别降低了 2.39%、9.15%、4.03% 和 11.78%，平均 RMSE 分别降低了 4.41%、10.96%、5.41% 和 14.07%，平均 MAPE 分别降低了 2.43%、8.91%、3.65% 和 11.65%。上述结果表明，MS-AgentNet 在不同退化形态的 Oxford 独立评价电池上保持了较好的整体估计精度。

4.3.2 CALCE 和 MIT 数据集上的跨电池泛化分析

在 Oxford 结果的基础上，将比较范围扩展至 CALCE CS2、CALCE CX2 和 MIT/Severson 数据集，并分别以 CS2_38、CX2_38 和 b3c29 作为独立评价电池，比较五种模型的估计性能。

Fig. 10展示了五种模型在三个数据集的配置选择电池和独立评价电池上的 SOH 估计曲线与误差分布。Table 12汇总了 CS2_38、CX2_38 和 b3c29 三颗独立评价电池的定量结果。




Fig. 10. SOH estimation results of different models on the CALCE and MIT/Severson datasets.

如图Fig. 10中的CX2_38子图所示，该电池在长期容量衰减过程中经历了多次阶段性转折，并在寿命后段表现出明显的加速衰减。局部放大区域显示，进入加速衰减阶段后，不同模型的预测偏差逐渐扩大，MS-AgentNet 仍能保持与真实 SOH 的较好贴合。Table 12显示，MS-AgentNet 的 R^2 、MAE、MAPE 和 RMSE 分别为 0.9947、0.0106、0.037673 和 0.0193；与 Transformer 相比，其 MAE、MAPE 和 RMSE 分别降低了 23.18%、51.80% 和 20.59%，在非线性转折和后段加速衰减过程中保持了较低的预测误差。

对于退化轨迹较为连续的 CS2_38 和 b3c29，五种模型均能够跟踪总体容量衰减趋势。局部放大结果显示，MS-AgentNet 在 CS2_38 上的预测误差整体接近零值，其 R^2 、MAE、MAPE 和 RMSE 分别为 0.9798、0.0120、0.015984 和 0.0174。在 b3c29 上，各模型能够跟踪后段逐渐加快的容量衰减过程，MS-AgentNet 取得了 0.9972 的 R^2 ，其 MAE、MAPE 和 RMSE 分别为 0.0018、0.001960 和 0.0022。

从三颗独立评价电池的平均结果来看，MS-AgentNet 取得了 0.9906 的 R^2 ，其平均 MAE、MAPE 和 RMSE

Table 12

SOH estimation errors of different models on the CALCE and MIT/Severson datasets.

Dataset	Method	R^2	MAE	MAPE	RMSE
CALCE CS2 (CS2_38)	MS-AgentNet	0.9798	0.0120	0.015984	0.0174
	CNN-Transformer	0.9779	0.0126	0.016928	0.0182
	CNN-LSTM	0.9778	0.0125	0.016680	0.0183
	Transformer	0.9787	0.0122	0.016434	0.0179
	LSTM	0.9776	0.0128	0.017085	0.0184
CALCE CX2 (CX2_38)	MS-AgentNet	0.9947	0.0106	0.037673	0.0193
	CNN-Transformer	0.9895	0.0154	0.093595	0.0269
	CNN-LSTM	0.9785	0.0207	0.152435	0.0387
	Transformer	0.9916	0.0138	0.078160	0.0243
	LSTM	0.9804	0.0201	0.145055	0.0370
MIT/Severson (b3c29)	MS-AgentNet	0.9972	0.0018	0.001960	0.0022
	CNN-Transformer	0.9960	0.0021	0.002302	0.0025
	CNN-LSTM	0.9879	0.0035	0.003808	0.0044
	Transformer	0.9971	0.0018	0.001976	0.0022
	LSTM	0.9952	0.0025	0.002667	0.0028
Average	MS-AgentNet	0.9906	0.0081	0.018539	0.0129
	CNN-Transformer	0.9878	0.0100	0.037608	0.0159
	CNN-LSTM	0.9814	0.0122	0.057641	0.0204
	Transformer	0.9891	0.0093	0.032190	0.0148
	LSTM	0.9844	0.0118	0.054936	0.0194

Note: Results are averaged over five independent runs. Average denotes the macro-average over the three independent evaluation cells. The best results are determined using unrounded values and are shown in bold.

分别为 0.0081、0.018539 和 0.0129，综合性能排名第一。与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 相比，其平均 MAE 分别降低了 18.89%、33.50%、12.06% 和 30.95%，平均 RMSE 分别降低了 18.57%、36.64%、12.43% 和 33.27%，平均 MAPE 分别降低了 50.70%、67.84%、42.41% 和 66.25%。

综合不同退化场景的实验结果，MS-AgentNet 在非线性加速衰减和平滑退化过程中均保持了较低的预测误差。该模型在 LCO 与 LFP 材料体系、常规 CC-CV 与多步快充协议以及不同容量衰减形态下均取得了较低的跨电池估计误差，体现出较好的模型适用性、预测鲁棒性和跨电池泛化能力。

4.4 跨数据集迁移实验

当训练电芯与评价电芯来自不同数据集时，化学体系、运行协议和退化分布差异可能引起域偏移 [52,59]。为评价 MS-AgentNet 在不同电池数据域之间的迁移能力，本文设置源域直接测试和少样本适应两类实验。

源域直接测试 (source-only) 仅使用源域参考电芯训练，冻结全部模型参数后直接在目标域评价电芯上测试。少样本适应在此基础上冻结特征提取模块，并使用目标域参考电芯前 30% 的循环数据微调读出层 [52,58]。

CALCE CS2、CALCE CX2 和 Oxford 分别作为独立数据域，其参考电芯为 CS2_36、CX2_36 和 Oxford Cell1，用于源域训练或目标域少样本适应；CS2_38、CX2_38 和 Oxford Cell3 作为目标域评价电芯，仅用于测试。CALCE CS2 与 CALCE CX2 均属于 LCO 化学体系，Oxford 采用 NCO-LCO 混合化学体系，迁移方向同时覆盖同化学体系和跨化学体系任务。

为使源域模型能够直接接收目标域输入，各迁移方向均采用 $CCCT[3.8, 4.0]$ 和 $Q_{dch}[3.8, 3.4]/C_{rated}$ 两项输入健康指标。

4.4.1 不同源域—目标域组合下的迁移结果

源域直接测试结果见 Table 13。

在源域直接测试条件下，CS2→CX2 和 CX2→CS2 的 R^2 分别为 0.8421 和 0.7847，MAE 分别为 0.0697 和 0.0388，表明模型在两个 CALCE 数据域之间保留了较好的退化趋势表征。涉及 Oxford 的四个迁移方向中，MAE 为 0.1530~0.6346， R^2 均低于 0，直接迁移结果表现出明显的的数据域组合与方向差异。

为考察目标域观测能否缩小上述跨域误差，进一步使用目标域参考电芯前 30% 的循环数据适配读出层，结果见 Table 14。

Table 13

Direct cross-dataset transfer results.

Source domain (training cell)	Metric	CS2	CX2	Oxford
CALCE CS2 (CS2_36)	R^2	—	0.8421	-60.5701
	MAE	—	0.0697	0.4761
	MAPE	—	0.3974	0.5573
	RMSE	—	0.1051	0.4778
CALCE CX2 (CX2_36)	R^2	0.7847	—	-108.6169
	MAE	0.0388	—	0.6346
	MAPE	0.0557	—	0.7423
	RMSE	0.0568	—	0.6375
Oxford (Cell1)	R^2	-1.5309	-1.4786	—
	MAE	0.1530	0.3528	—
	MAPE	0.2196	1.5040	—
	RMSE	0.1950	0.4164	—

Note: Results are averaged over three independent runs.

Table 14

Transfer results after 30% target-domain adaptation.

Source domain (training cell)	Metric	CS2	CX2	Oxford
CALCE CS2 (CS2_36)	R^2	—	0.9566	-0.2679
	MAE	—	0.0377	0.0590
	MAPE	—	0.1830	0.0722
	RMSE	—	0.0533	0.0685
CALCE CX2 (CX2_36)	R^2	0.8806	—	-1.6085
	MAE	0.0303	—	0.0835
	MAPE	0.0406	—	0.1024
	RMSE	0.0422	—	0.0982
Oxford (Cell1)	R^2	-1.1030	-0.4809	—
	MAE	0.1327	0.2427	—
	MAPE	0.1935	1.2100	—
	RMSE	0.1777	0.3218	—

Note: Results are averaged over three independent runs.

适配后，六个迁移方向的 MAE、MAPE 和 RMSE 均有所降低。在两个 CALCE 数据域之间，CS2→CX2 和 CX2→CS2 的 MAE 分别由 0.0697 和 0.0388 降低至 0.0377 和 0.0303。涉及 Oxford 的四个方向也获得不同程度的改善，其中两个 CALCE→Oxford 方向的 MAE 分别由 0.4761 和 0.6346 降低至 0.0590 和 0.0835；以 Oxford 为源域迁移至两个 CALCE 数据域时，MAE 分别降低至 0.1327 和 0.2427。

R^2 结果进一步显示，四个涉及 Oxford 的迁移方向在 30% 适配条件下均低于 0，表明当前目标域观测尚不足以充分表征其退化变化。后续将 Oxford 固定为目标域，进一步比较不同适配比例下的迁移性能。

4.4.2 目标域适配数据比例对迁移性能的影响

分别以 CS2_36 和 CX2_36 作为源域，使用 Oxford Cell1 的前置循环数据进行读出层适配，并将适配比例依次设置为 10%、30%、50% 和 70%，结果见 Table 15。

Table 15

Transfer results under different adaptation ratios.

Source domain (training cell)	Metric	10%	30%	50%	70%
CALCE CS2 (CS2_36)	R^2	-1.3934	-0.2679	0.5094	0.7650
	MAE	0.0831	0.0590	0.0366	0.0252
	MAPE	0.1015	0.0722	0.0445	0.0305
	RMSE	0.0942	0.0685	0.0426	0.0293
CALCE CX2 (CX2_36)	R^2	-3.2217	-1.6085	-0.3836	-0.1268
	MAE	0.1095	0.0835	0.0614	0.0559
	MAPE	0.1339	0.1024	0.0747	0.0677
	RMSE	0.1251	0.0982	0.0716	0.0646

Note: Results are averaged over three independent runs.

随着适配比例由 10% 增至 70%，两种源域设置下的 MAE、MAPE 和 RMSE 均持续下降。以 CS2 为源域时，MAE 由 0.0831 降至 0.0252， R^2 由 -1.3934 提高至 0.7650，并在 50% 适配比例下由负转正；以 CX2 为源域时，MAE 由 0.1095 降至 0.0559， R^2 由 -3.2217 提高至 70% 适配比例下的 -0.1268。四种适配比例下，CS2 源域的 R^2 均高于 CX2 源域的对应该结果。

进一步比较相邻适配比例，CS2 和 CX2 源域从 30% 增至 50% 时，MAE 分别降低 0.0224 和 0.0221；从 50% 增至 70% 时，降幅分别缩小至 0.0114 和 0.0055。目标域数据增加持续降低了估计误差，MAE 的改善幅度在较高适配比例下逐渐趋缓。两种源域设置表现出不同的 R^2 水平和转正情况，表明跨域适配结果同时受到目标域数据比例和源域选择的影响。

4.5 模块消融与模型复杂度分析

为进一步验证 MS-AgentNet 的有效性和效率，在主对比实验基础上开展消融研究与复杂度分析。消融研究通过移除或组合关键模块，考察各模块对预测性能的作用；复杂度分析则从计算量、参数量和存储占用等方面评估模型开销。

4.5.1 模块消融分析

高效注意力通过压缩信息交互降低标准注意力的计算开销 [39,40,43,44]，但这一过程可能削弱局部细粒度退化信息的表达 [31]；直接叠加标准卷积虽然能够增强局部特征建模，却会增加参数量和计算负担 [31,71]。为兼顾局部信息保留与计算效率，MS-AgentNet 结合多尺度 DSConv 与 RAA，分别完成局部特征提取和跨位置信息交互。为考察两类模块的单独作用及组合效果，消融实验设置 M1-M4 四种变体。其中，M1 仅保留基础骨干网络，M2 在 M1 基础上加入多尺度 DSConv，M3 在 M1 基础上加入 RAA，M4 则同时集成多尺度 DSConv 与 RAA。各变体遵循本章开篇的数据边界和统一的实验设置，仅按 Table 16 改变基础骨干网络、多尺度 DSConv 与 RAA 的组合，并在 CS2、CX2、MIT 和 Oxford 四个数据集的独立评价电池上进行评价。

如 Table 16 所示，与 M1 相比，加入多尺度 DSConv 后，M2 在 CX2 和 Oxford 数据集上的平均误差分别由 0.0500 和 0.0071 降低至 0.0494 和 0.0065，但在 CS2 和 MIT 数据集上未取得更低的平均误差。这表明，单独加入多尺度 DSConv 的效果因数据集而异。

加入 RAA 后，M3 在 CS2、CX2 和 Oxford 数据集上的平均误差分别由 0.0157、0.0500 和 0.0071 降低至

Table 16

Ablation results on different datasets.

Dataset	Model	Backbone	Multi-scale DSConv	RAA	MAE	RMSE	MAPE	Average	Reduction
CS2	M1	✓	—	—	0.0123	0.0183	0.0166	0.0157	3.74%
	M2	✓	✓	—	0.0130	0.0184	0.0171	0.0162	6.49%
	M3	✓	—	✓	0.0119	0.0178	0.0161	0.0152	0.62%
	M4	✓	✓	✓	0.0120	0.0174	0.0160	0.0151	—
	(Proposed)	✓	✓	✓	0.0120	0.0174	0.0160	0.0151	—
CX2	M1	✓	—	—	0.0170	0.0294	0.1035	0.0500	54.94%
	M2	✓	✓	—	0.0164	0.0284	0.1033	0.0494	54.40%
	M3	✓	—	✓	0.0156	0.0270	0.0899	0.0442	49.05%
	M4	✓	✓	✓	0.0106	0.0193	0.0377	0.0225	—
	(Proposed)	✓	✓	✓	0.0106	0.0193	0.0377	0.0225	—
MIT	M1	✓	—	—	0.0019	0.0022	0.0020	0.0020	2.43%
	M2	✓	✓	—	0.0021	0.0025	0.0023	0.0023	14.16%
	M3	✓	—	✓	0.0024	0.0028	0.0026	0.0026	23.91%
	M4	✓	✓	✓	0.0018	0.0022	0.0020	0.0020	—
	(Proposed)	✓	✓	✓	0.0018	0.0022	0.0020	0.0020	—
Oxford	M1	✓	—	—	0.0063	0.0076	0.0073	0.0071	16.52%
	M2	✓	✓	—	0.0058	0.0070	0.0067	0.0065	9.50%
	M3	✓	—	✓	0.0054	0.0063	0.0062	0.0060	1.52%
	M4	✓	✓	✓	0.0053	0.0062	0.0062	0.0059	—
	(Proposed)	✓	✓	✓	0.0053	0.0062	0.0062	0.0059	—

Note: Reduction denotes the relative decrease in average error achieved by M4 compared with the corresponding ablation variant (M1–M3).

0.0152、0.0442 和 0.0060，但在 MIT 数据集上未优于 M1。与多尺度 DSConv 相似，单独加入 RAA 并未在所有数据集上取得一致改善。

当多尺度 DSConv 与 RAA 同时集成后，完整模型 M4 在四个数据集上的综合平均误差均达到最优水平。以 CX2 数据集为例，平均误差由 M1 的 0.0500 降低至 0.0225，相对降低 54.94%；在 Oxford 数据集上，平均误差由 0.0071 降低至 0.0059，相对降低 16.52%。在 CS2 和 MIT 数据集上，M4 相对 M1 的平均误差也分别降低 3.74% 和 2.43%。需要指出的是，CS2 上 M3 的 MAE 略低于 M4，但 M4 在 RMSE、MAPE 和综合平均误差上取得更优结果。

总体来看，单独加入多尺度 DSConv 或 RAA 的效果具有一定的数据集差异，而两类模块组合后取得了更优的综合结果。

为进一步考察多尺度 DSConv 中两个卷积尺度的作用，在保持 RAA 启用的条件下设置 S0、S5、S31 和 SFull 四种尺度变体。其中，S0 仅保留 RAA，与 Table 16 中的 M3 对应；S5 在 S0 基础上加入核长度为 5 的 DSConv-S，S31 加入核长度为 31 的 DSConv-L；SFull 同时使用 DSConv-S、DSConv-L 与 RAA，与 M4 对应。各尺度变体采用相同的实验设置，结果如 Table 17 所示。

如 Table 17 所示，不同卷积尺度在各数据集上的作用有所差异。在 CX2 数据集上，S31 的平均误差由 S0 的 0.0442 降低至 0.0348，而 S5 未优于 S0；在 MIT 数据集上，S5 的平均误差略低于 S0 和 S31。在 CS2 和 Oxford 数据集上，两个单尺度变体的平均误差均未低于 S0。

当两个卷积尺度与 RAA 同时使用时，SFull 在四个数据集上均取得最低综合平均误差。由此可见，在 RAA 启用的条件下，单一卷积尺度的效果随数据集而变化，而双尺度结构取得了更优的综合结果。

4.5.2 模型复杂度分析

预测精度用于衡量 SOH 估计结果的可靠性，计算与存储开销则反映模型运行所需的资源条件 [77]。本文选取 MS-AgentNet、CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 五类代表性模型，从理论计算量、实际训练耗时、可训练参数量和权重存储占用四个方面评价 MS-AgentNet 的轻量化特性。其中，FLOPs 反映单次前向传播的计算需求，训练时间表征统一实验环境下的训练效率，参数量与存储占用则用于衡量模型规模及其存储负担。

FLOPs 通过 THOP 库的 `profile` 函数统计，训练时间采用 Python 的 `time` 模块记录，可训练参数量通过 `torchsummary` 库的 `summary` 函数计算，模型权重文件大小通过 `os.path.getsize` 函数获取。所有指标均在

Table 17

Effects of different convolution scales.

Dataset	Model	$K = 5$	$K = 31$	RAA	MAE	RMSE	MAPE	Average
CS2	S0	—	—	✓	0.0119	0.0178	0.0161	0.0152
	S5	✓	—	✓	0.0128	0.0184	0.0170	0.0161
	S31	—	✓	✓	0.0124	0.0179	0.0166	0.0156
	SFull	✓	✓	✓	0.0120	0.0174	0.0160	0.0151
CX2	S0	—	—	✓	0.0156	0.0270	0.0899	0.0442
	S5	✓	—	✓	0.0162	0.0285	0.1036	0.0494
	S31	—	✓	✓	0.0135	0.0232	0.0677	0.0348
	SFull	✓	✓	✓	0.0106	0.0193	0.0377	0.0225
MIT	S0	—	—	✓	0.0024	0.0028	0.0026	0.0026
	S5	✓	—	✓	0.0023	0.0027	0.0025	0.0025
	S31	—	✓	✓	0.0025	0.0028	0.0026	0.0026
	SFull	✓	✓	✓	0.0018	0.0022	0.0020	0.0020
Oxford	S0	—	—	✓	0.0054	0.0063	0.0062	0.0060
	S5	✓	—	✓	0.0056	0.0066	0.0065	0.0062
	S31	—	✓	✓	0.0055	0.0065	0.0064	0.0061
	SFull	✓	✓	✓	0.0053	0.0062	0.0062	0.0059

相同实验环境下测量。

为在相同输入数据和训练条件下比较不同模型结构的复杂度，本次统计统一设置训练轮次为 1000、学习率为 0.01、批次大小为 128、丢弃率为 0.1。基于 Transformer 的模型统一设置嵌入维度为 16、前馈维度为 16、注意力头数为 4，并采用单层编码器结构；基于 LSTM 的模型采用四层网络结构和隐藏维度 16。五类模型均使用 CS2 训练电池 CS2_36 中的 HI1 (3.80–4.00 V CCCT) 与 HI2 (IC 峰值)，输入序列长度为 5，单样本输入形状统一为 (1, 5, 2)。

在结构设置上，CNN-Transformer 的卷积模块位于多头自注意力模块之后，由两个一维卷积层和一个最大池化层组成，对应的核大小依次为 3、2 和 3，步长依次为 1、2 和 1，并采用 ReLU 激活函数 [31]。MS-AgentNet 则采用多尺度深度可分离卷积。五类模型的复杂度统计结果如 Table 18 所示。

Table 18

Comprehensive performance of models under the same configuration.

Models	Training hyperparameters			Model hyperparameters			Performance indicators			
	e	lr	b	d_e	d_d	n	FLOPs (Million)	Training time (s)	Parameters	Storage size (KB)
MS-AgentNet	1000	0.01	128	16	16	4	0.045760	122.979	4643	26.18
Transformer	1000	0.01	128	16	16	4	0.049760	104.274	4673	27.84
CNN-Transformer	1000	0.01	128	16	16	4	0.053024	123.487	6241	34.94
CNN-LSTM	1000	0.01	128	—	16	4	0.067520	70.021	15912	67.59
LSTM	1000	0.01	128	—	16	4	0.092512	64.327	8769	39.17

如 Table 18 所示，MS-AgentNet 在 FLOPs、参数量和存储占用三个指标上均取得最低值，其 FLOPs 为 0.045760 M，参数量为 4,643，权重文件存储占用为 26.18 KB。与计算量最高的 LSTM 相比，MS-AgentNet 的 FLOPs 降低 50.5%，参数量和存储占用分别降低 47.1% 和 33.1%。与参数量最高的 CNN-LSTM 相比，其参数量和存储需求分别降低约 70.8% 和 61.3%。该结果说明，MS-AgentNet 无需增加模型规模即可完成局部特征提取与跨位置信息聚合，从而有效控制计算量和参数开销。

训练时间方面，MS-AgentNet 并非五类模型中最快，LSTM 和 CNN-LSTM 的实测训练时间均低于 MS-AgentNet。该结果说明，实际训练耗时并不完全取决于理论计算量，还会受到算子实现和硬件执行效率的影响。然而，两类循环模型在 FLOPs、参数量和存储占用方面未能同时取得优势。相比之下，MS-AgentNet 的训练耗时与注意力类模型处于相近水平，同时保持了更小的模型规模和存储需求。

当模型适应不同电池类型或退化模式时，通常需要调整表示维度或隐藏维度，以匹配不同的数据复杂度。模型宽度不仅影响特征表示能力，也直接决定参数规模和权重存储需求。因此，为进一步评价不同模型容量下的存储开销，本文将 MS-AgentNet、CNN-Transformer、Transformer、CNN-LSTM 和 LSTM 的表示维度或隐藏维度分别设置为 16、32、64 和 128，并保持 Table 18 中的其余模型设置不变。




Fig. 11. Storage sizes of different models.

如Fig. 11(a)所示, 五种模型的存储开销均随表示维度或隐藏维度增加而上升, 但 MS-AgentNet 在四种测试维度下始终保持最低的存储占用。当维度增加至 128 时, CNN-LSTM 和 LSTM 的存储大小分别增至 1900.34 KB 和 2070.98 KB, 而 MS-AgentNet 仅为 713.12 KB; 与该维度下存储开销最接近的 Transformer 相比, MS-AgentNet 仍降低了 32.2%。上述结果表明, 随着模型宽度增加, MS-AgentNet 仍能够保持相对紧凑的模型规模。

如Fig. 11(b)所示, MS-AgentNet 的存储分布整体低于其他四种模型, 其箱体和须线覆盖的数值范围也相对较小。相比之下, CNN-LSTM 和 LSTM 的存储分布随隐藏维度增加表现出更明显的扩张。该结果进一步表明, MS-AgentNet 不仅在统一配置下具有较低存储开销, 而且在不同模型宽度下保持了较稳定的轻量化优势。

结合前文多数据集对比结果可知, MS-AgentNet 在保持较低模型复杂度的同时, 仍取得了具有竞争力的预测性能。统一配置下的复杂度结果及不同模型宽度下的补充比较进一步表明, MS-AgentNet 并非依赖扩大模型规模获得精度提升, 其存储优势也不局限于单一容量设置。因此, 所提模型在预测性能与资源开销之间取得了较好的平衡, 具备应用于资源受限电池管理系统的潜力。

5. 结论

本文提出了一种面向资源受限电池管理系统的轻量化锂离子电池 SOH 估计框架, 以缓解健康指标跨电池稳定性不足以及预测精度与计算效率难以兼顾的问题。研究从系统性健康指标构建和轻量化网络设计两个方面展开。所提出的 MS-CCCT 基于多节特征开发电池的 PCC 与 SCC, 对恒流充电电压窗口进行组级多尺度自适应标定; 在此基础上, 采用 PCC/SCC 双阈值准入与双相关冗余约束确定模型输入。在保持特征定义与参数不变的条件下, 最终入选指标在相应独立评价电池上仍与 SOH 保持较强的线性和单调关联。在序列建模方面, MS-AgentNet 将 ReLU² 智能体注意力与小核和大核深度可分离卷积相结合, 以协同表征局部退化变化、跨位置全局信息和长尺度退化趋势。在智能体数量固定时, RAA 利用少量可学习静态智能体完成信息聚合与广播, 将注意力相关性交互的理论复杂度由 $O(N^2d)$ 降低至 $O(Nn_ad)$ 。

在 Oxford、CALCE CS2、CALCE CX2 和 MIT/Severson 四个公开电池数据集上的实验结果表明, 与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种基线模型相比, MS-AgentNet 在四个数据集的独立评价结果中均取得了最佳综合表现。具体而言, 在 CALCE CX2 数据集上, 其平均绝对百分比误差相比 CNN-Transformer 降低了 59.75%。复杂度比较中, MS-AgentNet 在统一配置下仅包含 4,643 个可训练参数, 权重文件存储占用为 26.18 KB, 二者在五种模型中均为最低; 不同模型宽度下的补充比较也显示, 其存储优势不依赖单一容量设置。消融实验与卷积尺度补充实验显示, 多尺度深度可分离卷积与 RAA 的互补融合能够提升模型在不同退化场景下的综合表现。总体来看, 所提框架在 SOH 估计精度与资源开销之间取得了良好平衡, 并

在各数据集的独立评价电池上表现出较好的域内跨电池泛化能力，具备应用于资源受限电池管理系统的潜力。

尽管取得了上述结果，所提框架仍依赖可辨识的充放电数据片段，且其跨数据集适应能力会受到数据域差异、源域选择和目标域数据量的影响。未来将重点研究面向不完整充电和动态运行片段的健康指标构建方法及轻量化域适应策略，并在更多电池体系、实际车辆运行数据和嵌入式硬件平台上开展验证，以进一步提升该框架的工程适用性与部署可靠性。

参考文献

- [1] Scrosati B, Garche J. Lithium batteries: Status, prospects and future. *Journal of Power Sources* 2010;195(9):2419–2430. <https://doi.org/10.1016/j.jpowsour.2009.11.048>.
- [2] Kim T, Song W, Son D-Y, Ono LK, Qi Y. Lithium-ion batteries: Outlook on present, future, and hybridized technologies. *Journal of Materials Chemistry A* 2019;7(7):2942–2964. <https://doi.org/10.1039/C8TA10513H>.
- [3] Krause FC, Ruiz JP, Jones SC, Brandon EJ, Darcy EC, Iannello CJ, Bugga RV. Performance of commercial Li-ion cells for future NASA missions and aerospace applications. *Journal of The Electrochemical Society* 2021;168(4):040504. <https://doi.org/10.1149/1945-7111/abf05f>.
- [4] Xiong R, Kim J, Shen W, et al. Key technologies for electric vehicles. *Green Energy and Intelligent Transportation* 2022;1(2):100041. <https://doi.org/10.1016/j.geits.2022.100041>.
- [5] Barré A, Deguilhem B, Grolleau S, Gérard M, Suard F, Riu D. A review on lithium-ion battery ageing mechanisms and estimations for automotive applications. *Journal of Power Sources* 2013;241:680–689. <https://doi.org/10.1016/j.jpowsour.2013.05.040>.
- [6] Ma S, Jiang M, Tao P, Song C, Wu J, Wang J, Deng T, Shang W. Temperature effect and thermal impact in lithium-ion batteries: A review. *Progress in Natural Science: Materials International* 2018;28(6):653–666. <https://doi.org/10.1016/j.pnsc.2018.11.002>.
- [7] Wang C-J, Zhu Y-L, Gao F, Bu X-Y, Chen H-S, Quan T, Xu Y-B, Jiao Q-J. Internal short circuit and thermal runaway evolution mechanism of fresh and retired Li-ion batteries with LiFePO₄ cathode during overcharge. *Applied Energy* 2022;328:120224. <https://doi.org/10.1016/j.apenergy.2022.120224>.
- [8] Feng L, Jiang L, Liu J, Wang Z, Wei Z, Wang Q. Dynamic overcharge investigations of lithium ion batteries with different state of health. *Journal of Power Sources* 2021;507:230262. <https://doi.org/10.1016/j.jpowsour.2021.230262>.
- [9] Xia Y, Chen G, Zhou Q, Shi X, Shi F. Failure behaviours of 100% SOC lithium-ion battery modules under different impact loading conditions. *Engineering Failure Analysis* 2017;82:149–160. <https://doi.org/10.1016/j.engfailanal.2017.09.003>.
- [10] Che Y, Hu X, Lin X, Guo J, Teodorescu R. Health prognostics for lithium-ion batteries: Mechanisms, methods, and prospects. *Energy & Environmental Science* 2023;16:338–371. <https://doi.org/10.1039/D2EE03019E>.
- [11] Ge M-F, Liu Y, Jiang X, Liu J. A review on state of health estimations and remaining useful life prognostics of lithium-ion batteries. *Measurement* 2021;174:109057. <https://doi.org/10.1016/j.measurement.2021.109057>.
- [12] Tian H, Qin P, Li K, Zhao Z. A review of the state of health for lithium-ion batteries: Research status and suggestions. *Journal of Cleaner Production* 2020;261:120813. <https://doi.org/10.1016/j.jclepro.2020.120813>.
- [13] Lu J, Xiong R, Tian J, et al. Deep learning to estimate lithium-ion battery state of health without additional degradation experiments. *Nature Communications* 2023;14:2760. <https://doi.org/10.1038/s41467-023-38458-w>.
- [14] Luo K, Chen X, Zheng H, Shi Z. A review of deep learning approach to predicting the state of health and state of charge of lithium-ion batteries. *Journal of Energy Chemistry* 2022;74:159–173. <https://doi.org/10.1016/j.jechem.2022.06.049>.
- [15] Song K, Hu D, Tong Y, Yue X. Remaining life prediction of lithium-ion batteries based on health management: A review. *Journal of Energy Storage* 2023;57:106193. <https://doi.org/10.1016/j.est.2022.106193>.
- [16] Khaleghi S, Hosen M, Karimi D, et al. Developing an online data-driven approach for prognostics and health management of lithium-ion batteries. *Applied Energy* 2022;308:118348. <https://doi.org/10.1016/j.apenergy.2021.118348>.
- [17] Hu X, Xu L, Lin X, Pecht M. Battery lifetime prognostics. *Joule* 2020;4:310–346. <https://doi.org/10.1016/j.joule.2019.11.018>.
- [18] He W, Williard N, Osterman M, Pecht M. Prognostics of lithium-ion batteries based on Dempster–Shafer theory and the Bayesian Monte Carlo method. *Journal of Power Sources* 2011;196(23):10314–10321. <https://doi.org/10.1016/j.jpowsour.2011.08.040>.

- [19] Wang Y, Tian J, Sun Z, Wang L, Xu R, Li M, Chen Z. A comprehensive review of battery modeling and state estimation approaches for advanced battery management systems. *Renewable and Sustainable Energy Reviews* 2020;131:110015. <https://doi.org/10.1016/j.rser.2020.110015>.
- [20] Deng Z, Yang L, Deng H, Cai Y, Li D. Polynomial approximation pseudo-two-dimensional battery model for online application in embedded battery management system. *Energy* 2018;142:838–850. <https://doi.org/10.1016/j.energy.2017.10.097>.
- [21] Li J, Adewuyi K, Lotfi N, Landers RG, Park J. A single particle model with chemical/mechanical degradation physics for lithium ion battery state of health (SOH) estimation. *Applied Energy* 2018;212:1178–1190. <https://doi.org/10.1016/j.apenergy.2018.01.011>.
- [22] Wang D, Zhang Q, Huang H, Yang B, Dong H, Zhang J. An electrochemical–thermal model of lithium-ion battery and state of health estimation. *Journal of Energy Storage* 2022;47:103528. <https://doi.org/10.1016/j.est.2021.103528>.
- [23] Rechkemmer SK, Zang X, Zhang W, Sawodny O. Empirical Li-ion aging model derived from single particle model. *Journal of Energy Storage* 2019;21:773–786. <https://doi.org/10.1016/j.est.2019.01.005>.
- [24] Chen L, Lü Z, Lin W, Li J, Pan H. A new state-of-health estimation method for lithium-ion batteries through the intrinsic relationship between ohmic internal resistance and capacity. *Measurement* 2018;116:586–595. <https://doi.org/10.1016/j.measurement.2017.11.016>.
- [25] Roman D, Saxena S, Robu V, Flynn D, Pecht M. Machine learning pipeline for battery state of health estimation. *arXiv* 2021. <https://doi.org/10.48550/arXiv.2102.00837>.
- [26] Fei Z, Yang F, Tsui K-L, Li L, Zhang Z. Early prediction of battery lifetime via a machine learning based framework. *Energy* 2021;225:120205. <https://doi.org/10.1016/j.energy.2021.120205>.
- [27] Li Y, Zou C, Berecibar M, Nanini-Maury E, Chan JC-W, van den Bossche P, Van Mierlo J, Omar N. Random forest regression for online capacity estimation of lithium-ion batteries. *Applied Energy* 2018;232:197–210. <https://doi.org/10.1016/j.apenergy.2018.09.182>.
- [28] Richardson RR, Birkel CR, Osborne MA, Howey DA. Gaussian process regression for in situ capacity estimation of lithium-ion batteries. *IEEE Transactions on Industrial Informatics* 2018;15:127–138. <https://doi.org/10.1109/TII.2018.2794997>.
- [29] Qian C, Xu B, Chang L, Sun B, Feng Q, Yang D, Ren Y, Wang Z. Convolutional neural network based capacity estimation using random segments of the charging curves for lithium-ion batteries. *Energy* 2021;227:120333. <https://doi.org/10.1016/j.energy.2021.120333>.
- [30] Lee G, Kwon D, Lee C. A convolutional neural network model for SOH estimation of Li-ion batteries with physical interpretability. *Mechanical Systems and Signal Processing* 2023;188:110004. <https://doi.org/10.1016/j.ymssp.2022.110004>.
- [31] Li X, Zhao M, Zhong S, Li J, Fu S, Yan Z. BMSFormer: An efficient deep learning model for online state-of-health estimation of lithium-ion batteries under high-frequency early SOC data with strong correlated single health indicator. *Energy* 2024;313:134030. <https://doi.org/10.1016/j.energy.2024.134030>.
- [32] Jia C, Tian Y, Shi Y, Jia J, Wen J, Zeng J. State of health prediction of lithium-ion batteries based on bidirectional gated recurrent unit and transformer. *Energy* 2023;285:129401. <https://doi.org/10.1016/j.energy.2023.129401>.
- [33] Zheng Y, Hu J, Chen J, Deng H, Hu W. State of health estimation for lithium battery random charging process based on CNN-GRU method. *Energy Reports* 2023;9:1–10. <https://doi.org/10.1016/j.egy.2022.12.093>.
- [34] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, Kaiser L, Polosukhin I. Attention Is All You Need. In: *Advances in Neural Information Processing Systems*, vol. 30; 2017. <https://doi.org/10.48550/arXiv.1706.03762>.
- [35] Gu X, See KW, Li P, Shan K, Wang Y, Zhao L, Lim KC, Zhang N. A novel state-of-health estimation for the lithium-ion battery using a convolutional neural network and transformer model. *Energy* 2023;262:125501. <https://doi.org/10.1016/j.energy.2022.125501>.
- [36] Bai T, Wang H. Convolutional transformer-based multiview information perception framework for lithium-ion battery state-of-health estimation. *IEEE Transactions on Instrumentation and Measurement* 2023;72:1–12. <https://doi.org/10.1109/TIM.2023.3300451>.
- [37] Chen L, Xie S, Lopes AM, Bao X. A vision transformer-based deep neural network for state of health estimation of lithium-ion batteries. *International Journal of Electrical Power & Energy Systems* 2023;152:109233. <https://doi.org/10.1016/j.ijepes.2023.109233>.
- [38] Park SH, Kim SH. Physics-Informed Transformer Using Degradation-Sensitive Indicators for Long-Term State-of-Health Estimation of Lithium-Ion Batteries. *Batteries* 2026;12(2):48.

- [39] Tay Y, Dehghani M, Bahri D, Metzler D. Efficient Transformers: A survey. *ACM Computing Surveys* 2022;55(6). <https://doi.org/10.1145/3530811>.
- [40] Katharopoulos A, Vyas A, Pappas N, Fleuret F. Transformers are RNNs: Fast autoregressive Transformers with linear attention. In: *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119; 2020. p. 5156–5165. <https://doi.org/10.48550/arXiv.2006.16236>.
- [41] Xu H, Wu L, Xiong S, Li W, Garg A, Gao L. An improved CNN-LSTM model-based state-of-health estimation approach for lithium-ion batteries. *Energy* 2023;276:127585. <https://doi.org/10.1016/j.energy.2023.127585>.
- [42] Tian Y, Wen J, Yang Y, Shi Y, Zeng J. State-of-Health Prediction of Lithium-Ion Batteries Based on CNN-BiLSTM-AM. *Batteries* 2022;8(10):155. <https://doi.org/10.3390/batteries8100155>.
- [43] Liu S, Yu H, Liao C, Li J, Lin W, Liu AX, Dustdar S. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting. In: *Proceedings of the International Conference on Learning Representations*; 2022.
- [44] Zheng L, Wang C, Kong L. Linear complexity randomized self-attention mechanism. In: *Proceedings of the 39th International Conference on Machine Learning*, PMLR 162; 2022. p. 27011–27041.
- [45] Wang H, Li H, He Z, Chen X, Liu H, Chen C. A linear-complexity deep learning framework for efficient battery state of health estimation in resource-constrained systems. *Engineering Applications of Artificial Intelligence* 2026;181:115420. <https://doi.org/10.1016/j.engappai.2026.115420>.
- [46] Han D, Ye T, Han Y, Xia Z, Pan S, Wan P, Song S, Huang G. Agent Attention: On the integration of Softmax and linear attention. In: *Computer Vision—ECCV 2024, Lecture Notes in Computer Science*, vol. 15108, Springer, Cham; 2025. p. 124–140. https://doi.org/10.1007/978-3-031-72973-7_8.
- [47] Lin C, Xu J, Hou J, et al. A fast data-driven battery capacity estimation method under non-constant current charging and variable temperature. *Energy Storage Materials* 2023;63:102967. <https://doi.org/10.1016/j.ensm.2023.102967>.
- [48] Dai H, Wang J, Huang Y, Lai Y, Zhu L. Lightweight state-of-health estimation of lithium-ion batteries based on statistical feature optimization. *Renewable Energy* 2024;222:119907. <https://doi.org/10.1016/j.renene.2023.119907>.
- [49] Wu J, Liu Z, Zhang Y, Lei D, Zhang B, Cao W. Data-driven state of health estimation for lithium-ion battery based on voltage variation curves. *Journal of Energy Storage* 2023;73:109191. <https://doi.org/10.1016/j.est.2023.109191>.
- [50] Wen J, Chen X, Li X, Li Y. SOH prediction of lithium battery based on IC curve feature and BP neural network. *Energy* 2022;261:125234. <https://doi.org/10.1016/j.energy.2022.125234>.
- [51] Tian Y, Dong Q, Tian J, Li X, Li G, Mehran K. Capacity estimation of lithium-ion batteries based on optimized charging voltage section and virtual sample generation. *Applied Energy* 2023;332:120516. <https://doi.org/10.1016/j.apenergy.2022.120516>.
- [52] Li X, Zhao M, Zhong S, Li J, Cui Z, Fu S, Yan Z. Deep transfer learning enabled online state-of-health estimation of lithium-ion batteries under small samples across different cathode materials, ambient temperature and charge-discharge protocols. *Journal of Power Sources* 2025;650:237503. <https://doi.org/10.1016/j.jpowsour.2025.237503>.
- [53] Tang Q, He T, Huang J, Zhu W. A novel state of health estimation method for lithium-ion battery based on multi-feature extraction and fusion model with bidirectional feature extraction. *Journal of Energy Storage* 2026;141:119415.
- [54] Gong Y, Lu X, Su Z, Huang Z, Quan Y, Zhang Z, Ouyang T. Correlation-aware fusion model for robust SOH estimation in lithium-ion batteries. *Journal of Energy Storage* 2026;149:120018.
- [55] Lin M, Ke L, Wang W, Meng J, Guan Y, Wu J. Health prognosis via feature optimization and convolutional neural network for lithium-ion batteries. *Engineering Applications of Artificial Intelligence* 2024;133:108666. <https://doi.org/10.1016/j.engappai.2024.108666>.
- [56] Ambrose C, McLachlan GJ. Selection bias in gene extraction on the basis of microarray gene-expression data. *Proceedings of the National Academy of Sciences of the United States of America* 2002;99(10):6562–6566. <https://doi.org/10.1073/pnas.102102699>.
- [57] Kaufman S, Rosset S, Perlich C, Stitelman O. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data* 2012;6(4):15. <https://doi.org/10.1145/2382577.2382579>.
- [58] Huang K, Yao K, Guo Y, Lv Z. State of health estimation of lithium-ion batteries based on fine-tuning or rebuilding transfer learning strategies combined with new features mining. *Energy* 2023;282:128739. <https://doi.org/10.1016/j.energy.2023.128739>.
- [59] Wang R, Song C, Gao M, Zhao J, Xu Z. Model-data fusion domain adaptation for battery state of health estimation with fewer data and simplified feature extractor. *Journal of Energy Storage* 2023;60:106686. <https://doi.org/10.1016/j.est.2023.106686>.

- [60] Birkel CR, Roberts MR, McTurk E, Bruce PG, Howey DA. Degradation diagnostics for lithium-ion cells. *Journal of Power Sources* 2017;341:373–386. <https://doi.org/10.1016/j.jpowsour.2016.12.011>.
- [61] dos Reis G, Strange C, Yadav M, Li S. Lithium-ion battery data and where to find it. *Energy and AI* 2021;5:100081. <https://doi.org/10.1016/j.egyai.2021.100081>.
- [62] Severson KA, Attia PM, Jin N, et al. Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy* 2019;4(5):383–391. <https://doi.org/10.1038/s41560-019-0356-8>.
- [63] Lin C, Xu J, Shi M, Mei X. Constant current charging time based fast state-of-health estimation for lithium-ion batteries. *Energy* 2022;247:123556. <https://doi.org/10.1016/j.energy.2022.123556>.
- [64] Li D, Xing Y, Li X. Joint state of health and remaining useful life assessment of lithium-ion batteries using a novel attention mechanism-based deep learning model and multi-source optimized health indicators. *Journal of Energy Storage* 2026;161:121823.
- [65] Wu B, Yufit V, Merla Y, Martinez-Botas RF, Brandon NP, Offer GJ. Differential thermal voltammetry for tracking of degradation in lithium-ion batteries. *Journal of Power Sources* 2015;273:495–501. <https://doi.org/10.1016/j.jpowsour.2014.09.127>.
- [66] Lin Z, Li D, Zou Y. Energy efficiency of lithium-ion batteries: Influential factors and long-term degradation. *Journal of Energy Storage* 2023;74:109386. <https://doi.org/10.1016/j.est.2023.109386>.
- [67] Bai J, Huang J, Luo K, Yang F, Xian Y. A feature reuse based multi-model fusion method for state of health estimation of lithium-ion batteries. *Journal of Energy Storage* 2023;70:107965. <https://doi.org/10.1016/j.est.2023.107965>.
- [68] Zhang Y, Zhang D, Wu T. Method for estimating the state of health of lithium-ion batteries based on differential thermal voltammetry and sparrow search algorithm-Elman neural network. *Energy Engineering* 2025;122(1):203–220. <https://doi.org/10.32604/ee.2024.056244>.
- [69] Zou B, Wang H, Zhang T, et al. A deep learning approach for state-of-health estimation of lithium-ion batteries based on differential thermal voltammetry and attention mechanism. *Frontiers in Energy Research* 2023;11:1178151. <https://doi.org/10.3389/fenrg.2023.1178151>.
- [70] Feng H, Zhang L. A heterogeneous learner fusion method with supplementary feature for lithium-ion batteries state of health estimation. *Journal of Energy Storage* 2024;92:111896. <https://doi.org/10.1016/j.est.2024.111896>.
- [71] Chollet F. Xception: Deep learning with depthwise separable convolutions. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*; 2017. p. 1800–1807. <https://doi.org/10.1109/CVPR.2017.195>.
- [72] Sandler M, Howard A, Zhu M, Zhmoginov A, Chen L-C. MobileNetV2: Inverted residuals and linear bottlenecks. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*; 2018. p. 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474>.
- [73] Zhang X, Zhou X, Lin M, Sun J. ShuffleNet: An extremely efficient convolutional neural network for mobile devices. *arXiv* 2017. <https://doi.org/10.48550/arXiv.1707.01083>.
- [74] Ma N, Zhang X, Zheng H-T, Sun J. ShuffleNet V2: Practical guidelines for efficient CNN architecture design. In: *Computer Vision—ECCV 2018, Lecture Notes in Computer Science*, vol. 11218, Springer, Cham; 2018. p. 116–131. https://doi.org/10.1007/978-3-030-01264-9_8.
- [75] Srivastava N, Hinton G, Krizhevsky A, Sutskever I, Salakhutdinov R. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research* 2014;15(56):1929–1958.
- [76] Chicco D, Warrens MJ, Jurman G. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science* 2021;7:e623. <https://doi.org/10.7717/peerj-cs.623>.
- [77] Li P, Zhang Z, Grosu R, Deng Z, Hou J, Rong Y, Wu R. An end-to-end neural network framework for state-of-health estimation and remaining useful life prediction of electric vehicle lithium batteries. *Renewable and Sustainable Energy Reviews* 2022;156:111843. <https://doi.org/10.1016/j.rser.2021.111843>.