

摘要

高效准确的锂离子电池健康状态估计，对保障电池安全运行和支持资源受限电池管理系统的在线应用至关重要。然而，现有估计方法往往依赖跨电池稳定性有限的健康指标和资源开销较大的模型结构。为此，本文提出一种轻量化的 SOH 估计框架。首先，提出组级健康指标选择算法，从多源候选指标中选取跨电池稳健的健康指标，并减少特征冗余。随后，我们提出集成小核与大核深度可分离卷积的预测网络 MS-AgentNet，旨在解决传统 Transformer 注意力机制的二次计算开销。其中，小核卷积与 ReLU² 智能体注意力组成局部-全局融合注意力模块，在捕获局部退化特征与长程退化依赖的同时，将注意力复杂度由二次降至线性。大核卷积则用于提取长尺度退化特征，与小核卷积共同以较低参数开销融合多尺度和多通道特征，增强特征多样性。我们在四个涵盖不同化学体系和运行条件的公开电池数据集上，将所提模型与多种主流深度学习模型进行了比较。实验结果表明，MS-AgentNet 总体上取得了更优的综合性能，同时保持了较低的计算与存储开销，进一步体现了其面向资源受限电池管理系统的轻量化优势。

关键词：锂离子电池；健康状态估计；线性复杂度；深度特征融合；轻量化深度学习

1. 引言

锂离子电池凭借高能量密度、长循环寿命和低自放电率等优势，已广泛应用于电动汽车、便携式电子设备和规模化储能等领域 [1–4]，是支撑新能源交通、智能终端和能源存储行业发展的重要储能技术。尽管如此，电池在长期运行中仍存在不可忽视的安全风险。充放电循环与复杂工况会引发固体电解质界面（solid electrolyte interphase, SEI）膜增厚、活性锂损失和电极结构衰退等老化现象 [5,6]，进而导致容量衰减和性能下降，严重时 will 诱发短路、热失控等故障 [7,8]。因此，精确估计锂离子电池的健康状态对于保障电池的安全性、可靠性和运行性能至关重要。

容量衰减是电池老化最直观的特征，健康状态（state of health, SOH）通常采用容量保持率定义 [13,14]。但电池最大可用容量的精确测算需要完整或近似完整的充放电循环，难以满足在线监测需求 [10,11]。因此，从可观测运行信号中间接估计 SOH 已成为在线健康监测的关键途径。然而，复杂工况增加了退化信息稳定提取的难度，而电池管理系统（battery management system, BMS）严格的计算与存储限制又制约了模型复杂度，使在线 SOH 估计面临退化信息提取与模型计算效率的双重挑战 [31]。

1.1 文献综述

近期的健康状态估计方法主要分为模型驱动和数据驱动两类 [10–12]。前者包括电化学模型和等效电路模型，后者包括传统机器学习和深度学习方法。

模型驱动方法通过数学方程或等效电路模拟电池内部的电化学机制 [19]。其中，电化学模型以微分方程表示电池的反应与退化过程。例如，Li 等人 [21] 基于单粒子模型（SPM），构建了同时考虑化学退化与机械损伤的 SOH 估计框架。虽然这类模型具有较好的物理可解释性和估计精度，但求解复杂方程需要较多计算资源，颗粒半径、扩散系数等参数也难以获取，限制了其在资源受限 BMS 中的在线应用 [20,22,23]。相比之下，等效电路模型（ECM）将复杂的电化学过程简化为由电阻、电容等元件组成的电路，以模拟电池充放电动态特性 [19]。例如，Chen 等人 [24] 采用递推最小二乘法辨识 Thevenin 模型参数，并根据欧姆内阻与容量衰减的关系估计 SOH。这种简化降低了模型的计算开销，但也使其难以全面刻画电池内部状态的变化。与电化学模型相比，ECM 的估计精度可能较低，且依赖于所选电路结构与模型参数。此外，ECM 参数对温度和充放电倍率等工况高度敏感，使其难以在整个老化周期内保持良好的估计鲁棒性 [19]。

相较于模型驱动方法，数据驱动方法无需建立详细的电化学模型或深入分析电池内部的反应及老化机制 [11,14]。这类方法利用历史运行数据训练模型，将提取的健康指标映射为 SOH 估计值。早期研究主要采用传统机器学习模型进行电池状态估计与寿命预测 [25]。例如，Fei 等人 [26] 从前 100 个循环的充放电数据中构造 42 个特征，经筛选后输入弹性网络、高斯过程回归（GPR）、支持向量机（SVM）、随机森林（RF）、梯度提升回归树（GBRT）和神经网络（NN）六种模型，比较其早期寿命预测表现。Li 等人 [27] 则利用局部充电过程中的电压和容量数据，通过随机森林实现在线容量估计。然而，当面对来自在线监测和历史循环的非线性、波动性数据时，传统机器学习模型因其结构限制而难以提供高性能。

随着深度学习的快速发展，研究者进一步采用多层神经网络，利用其较强的非线性表征能力捕捉复杂的电池退化模式，以提高估计精度 [14]。卷积神经网络（CNN）、循环神经网络（RNN）和 Transformer 是其中常用的模型。CNN 利用卷积核提取局部特征，并通过池化操作降低特征维度。例如，Qian 等人 [29] 将随机选

取的充电曲线片段输入一维 CNN，用于电池容量估计。结果表明，该方法在随机片段输入条件下取得了较低的容量估计误差。Lee 等人 [30] 则将跨循环的容量衰减序列转换为二维图像，并采用二维 CNN 估计 SOH。

然而，传统 CNN 的单层卷积受局部感受野限制，相距较远的特征通常需要经过多层卷积才能融合 [31]。为建立这些远距离联系，RNN 通过隐藏状态将历史信息传递到后续时间步；其变体长短期记忆网络（LSTM）和门控循环单元（GRU）进一步利用门控机制选择性地保留和更新历史信息，以捕捉长期依赖 [14]。为同时利用局部特征与历史信息，研究者将 CNN 与循环网络相结合。例如，Xu 等人 [41] 将 CNN 提取的特征输入 LSTM，利用 LSTM 的时序记忆能力估计 SOH。Tian 等人 [42] 在 CNN 与 BiLSTM 的组合中进一步引入注意力机制，构建了 CNN-BiLSTM-AM 预测模型。Zheng 等人 [33] 则采用 CNN-GRU，根据随机充电过程中的电压、电流和温度曲线片段估计 SOH。尽管如此，这类模型中的隐藏状态仍需按时间步串行更新，限制了训练和推理过程中的并行计算 [31]。

为解决这一问题，Vaswani 等人 [34] 提出了 Transformer。该模型避免循环递推，利用自注意力直接建立不同序列位置之间的联系，在捕捉长程依赖的同时支持并行计算。例如，Park 和 Kim [38] 采用物理先验引导的 Transformer 估计电池长期 SOH；Chen 等人 [37] 则在视觉 Transformer 中加入维度变换层等结构，使其适用于电池 SOH 估计。研究者还将 Transformer 与卷积或循环网络相结合，以提高预测精度。Gu 等人 [35] 采用 CNN 提取局部特征，并结合 Transformer 捕捉长程依赖。Jia 等人 [32] 将 BiGRU 与 Transformer 结合，实验表明该模型在所用电池数据上具有较好的预测精度、鲁棒性和泛化表现。Bai 和 Wang [36] 则提出卷积 Transformer 框架，从电压和电流信号中提取局部细节，并通过自注意力建立局部特征之间的全局联系。然而，现有方法多通过集成其他模块或模型提高 Transformer 的预测精度，这种性能提升往往以增加参数数量和计算开销为代价 [31]。与此同时，标准自注意力的计算瓶颈依然存在：它需要计算所有序列位置之间的两两关系，时间和存储复杂度随序列长度 N 呈二次增长，即 $O(N^2)$ [39,40]。这些计算与存储需求增加了模型在资源受限 BMS 中的在线应用难度 [31]。

除了预测模型，健康指标的提取与选择对 SOH 估计的准确性同样至关重要。这些指标主要从电池循环过程中的电压、电流、温度、时间和内阻等运行数据及其衍生曲线中提取 [47–50]。其中，部分内阻指标需要通过阻抗谱测试获得，测试过程耗时且依赖专用仪器 [64]。温度指标虽然包含电池退化信息，但也会受到环境温度 and 充放电倍率的影响，其不同工况下的稳定性受到限制 [64]。增量容量曲线能够反映电池老化引起的电压平台变化，但计算该曲线需要进行微分运算，容易放大采样噪声。为获得可靠的曲线特征，通常需要进行平滑处理 [28,50]。例如，Wen 等人 [50] 从平滑后的增量容量曲线中提取峰值、峰位和峰形斜率等候选特征，并根据相关性分析选择峰值作为 BP 神经网络输入。

相比之下，时间类健康指标无需微分处理，提取过程更为简单。其中，恒流充电时间（CCCT）可由所选电压区间两端对应时刻的差值获得。Richardson 等人 [28] 利用恒流充电曲线中不同电压区间的时间特征估计电池容量，Lin 等人 [63] 则将 CCCT 作为随机森林的输入，估计电池 SOH。由于时间特征与容量之间的相关性会受到所选电压区间影响，相关研究通常需要进一步确定合适的特征提取区间。Tian 等人 [51] 通过优化充电电压区间，提高所提取健康指标与容量之间的相关性。在充电时间特征的区间选择中，Li 等人 [31] 逐步缩小电压窗口，并利用组内多节电池的皮尔逊相关系数（PCC）评价候选区间，以从更短的充电片段中提取与 SOH 高度相关的时间特征。

不同运行数据及其衍生曲线能够从不同方面反映电池退化。为更充分地利用这些信息，一些研究从多种运行信号中构建候选健康指标，并进一步优化模型输入。例如，Dai 等人 [48] 从电压、电流、温度以及增量容量、差分热伏安曲线中提取健康指标，并计算这些指标在各循环下的均值、中位数等统计特征，随后通过比较不同统计特征组合的估计误差确定用于 SOH 估计的输入。Lin 等人 [55] 从电学、热学和电化学等角度构建多类特征，采用主成分分析进行降维，并利用模拟退火算法优化保留的特征维数，从而减少冗余并改善 SOH 估计表现。

单一健康指标所反映的退化信息相对有限，多源特征能够从不同方面补充电池退化的描述。然而，增加候选指标并不必然提高估计精度，表征能力较弱、跨电池表现不稳定或相互重复的指标，可能限制多源信息的有效利用，并增加模型的学习负担。因此，有必要设计相应的健康指标筛选算法，将 SOH 相关性、跨电池表现与冗余关系纳入统一的评价与筛选过程，保留具有稳定表征能力的指标，减少弱相关和重复信息的输入，以帮助模型更有效地学习电池退化规律。

现有 SOH 估计方法之间的比较总结于 Table 1。具体而言，重点考察各方法是否充分利用电池运行数据中

的退化信息，是否采用有效的健康指标提取与选择策略，是否通过针对性的模型设计兼顾估计性能与计算效率，以及是否开展模型复杂度评价。在健康指标方面，不同电池在材料体系和运行条件上存在差异，所选指标能否在不同电池间保持稳定的退化表征能力仍需进一步关注。在模型方面，除估计性能外，模型复杂度同样直接关系到实际部署。近年来，深度模型架构发展的一个显著趋势是通过增加网络深度、扩大模型规模或引入更复杂的特征交互结构来增强表征能力。这些设计有助于提升模型对复杂退化规律的建模能力，但通常也伴随着更高的参数量、计算开销和存储需求。因此，面向计算能力、存储空间和实时性受到限制的 BMS，SOH 估计模型需要在保持有效表征能力的同时控制模型规模与资源开销，进一步向紧凑化和高效化方向发展。

Table 1
Comparison of existing SOH estimation methods.

参考	考虑的源数据			健康指标选择方法（作者设计）	评估模型（是否为原创）	效率考量
	电流	电压	温度			
[78]	✓	✓	✗	PCC (✗)	PINN (✓)	✗
[31]	✗	✓	✗	PCC (✓)	BMSFormer (✓)	✓
[32]	✗	✓	✓	PCC + SCC (✗)	BiGRU-Transformer (✗)	✗
[37]	✓	✓	✗	PCC (✗)	Transformer (✗)	✗
[79]	✓	✓	✗	LC (✗)	Gaussian filter (✗)	✗
[27]	✗	✓	✗	LC (✗)	Random Forest Regression (✗)	✗
[35]	✓	✓	✓	PCC (✗)	CNN-Transformer (✗)	✓
[55]	✓	✓	✓	SA-PCA (✓)	CNN (✗)	✓
[80]	✗	✓	✗	PCC (✗)	Bi-LSTM (✗)	✗
[81]	✗	✓	✗	PCC + SCC (✗)	LSSVM-AdaBoost (✗)	✗
[82]	✗	✓	✗	PCC (✗)	LSTM (✗)	✗
[83]	✓	✓	✓	PCC (✗)	LSTM (✗)	✗
[84]	✓	✓	✓	PCC + SCC (✓)	Extreme Learning Machine (✗)	✗
[63]	✗	✓	✗	CCCT 窗口搜索 (✓)	Random Forest Regression (✗)	✓
[48]	✓	✓	✓	统计特征组合优化 (✓)	NGO-Dualkernel-GPR (✓)	✗
[51]	✓	✓	✗	QPSO 区间优化 (✓)	LSTM-BP (✗)	✗
本文	✓	✓	✓	组级健康指标选择算法 (✓)	MS-AgentNet (✓)	✓

1.2 挑战分析与贡献

现有方法面临的主要挑战可归纳为以下三点。

(1) **健康指标的跨电池稳定性问题。**从多传感器收集的原始数据包含多样化的退化相关特征。候选健康指标与 SOH 之间的关联可能随电池个体而变化，在一节电池上表现良好的指标，在其他电池上未必保持相同的表征能力。PCC 和斯皮尔曼相关系数 (SCC) 分别用于评价线性关联与单调关联，仅采用其中一种，难以同时考察这两方面的表现。此外，即使多个指标均与 SOH 具有较强关联，它们之间仍可能包含重复信息。因此，模型输入的确定需要结合不同电池上的相关性表现与指标间的冗余关系，减少选择结果对单节电池表现的依赖。

(2) **局部与长期退化信息的融合问题。**随着循环推进，电池容量整体呈下降趋势，并伴随相邻循环的波动和局部容量恢复。局部特征能够反映短期变化，但对长期衰减趋势的把握还需要建立跨循环联系；在聚合跨循环信息时，也需要保留局部退化细节，避免短期变化被弱化。因此，模型不仅需要提取不同时间尺度的退化特征，还需要使局部变化与长期趋势相互补充，以提高 SOH 估计的准确性。

(3) **计算复杂度限制。**许多现有深度学习模型通过增加网络深度或组合不同网络结构提高 SOH 估计精度。这些方法增加了模型参数和计算操作。循环结构需要按时间步依次计算，标准自注意力需要计算所有序列位置之间的两两关系，其时间和存储开销随序列长度呈二次增长。这些开销加重了资源受限 BMS 的运行负担，限制了在线 SOH 估计模型的部署。

为应对上述挑战，本文提出一种以 MS-AgentNet 为核心的锂离子电池 SOH 估计框架。该框架从健康指标构建和轻量模型设计两个层面展开，分别通过组级标定与筛选提高模型输入的跨电池稳定性，并以较低计算开销提取局部变化和长期趋势，主要贡献如下。

(1) **提出组级健康指标选择算法。**该算法以特征开发电池集合上的相关性结果为依据，综合评价多类

候选健康指标与 SOH 的关联及指标间的冗余。利用 MS-CCCT 标定其中充电时间特征的电压窗口，再通过 PCC/SCC 双阈值与冗余约束筛选候选指标。统一的筛选规则为各数据集确定相应的健康指标组合，入选指标在同一数据集的其他电池上仍保持较强的线性和单调相关性。

(2) **构建轻量级局部—全局网络 MS-AgentNet**。设计轻量级局部—全局融合注意力模块 (SLFA)，将小核深度可分离卷积与 ReLU² 智能体注意力相结合，以较低参数开销融合局部退化特征与长期依赖。所构建的注意力机制将计算复杂度由 $O(N^2)$ 降低至 $O(N)$ 。模型进一步引入大核深度可分离卷积，与小核卷积共同提取不同时间尺度的退化特征。上述设计将局部特征提取与全局信息交互整合于紧凑的网络结构中，在提高 SOH 估计精度的同时降低了计算与存储开销。

(3) **开展多数据集综合验证**。在具有不同材料、容量和充放电协议的多个公开数据集上开展实验，并结合模块消融与复杂度分析，综合评估所提方法的估计精度、计算效率及跨电池泛化能力。进一步通过跨数据集迁移实验考察模型的跨域适应能力。结果表明，所提模型在保持较高 SOH 估计精度的同时，具有较低的计算量和存储开销。

2. 方法基础与数据准备

2.1 健康状态估计框架概述

为统一后续实验中的计算口径，SOH 按容量保持率进行计算，即电池当前可用容量与额定容量之比 [13, 14]:

$$\text{SOH} = \frac{C_{\text{current}}}{C_{\text{rated}}} \times 100\%, \quad (1)$$

其中， C_{current} 和 C_{rated} 分别表示电池当前可用容量和额定容量。

所提出的健康状态估计框架如图 1 所示。

(1) **数据获取**。选取不同材料体系和运行工况下的公开电池老化数据，获取充放电过程中的电压、电流、温度、时间和容量等循环记录。

(2) **系统化特征工程**。基于上述数据构建多源候选健康指标池，采用所提出的组级健康指标选择算法确定模型输入。随后，采用滑动窗口划分健康指标时间序列，将各窗口与其下一循环的 SOH 配对，形成输入样本及对应标签。

(3) **模型训练**。将筛选后的健康指标样本输入 MS-AgentNet，在训练电池上完成模型参数学习，并根据配置电池上的估计表现确定模型配置。

(4) **性能评价**。将训练后的模型直接用于相应数据集的其他电池，比较不同模型的 SOH 估计精度、跨电池泛化性能及计算与存储开销。进一步通过消融实验分析关键模块的作用，并通过跨数据集迁移实验考察模型的跨域适应能力。

2.2 典型电池数据集

为考察所提方法在不同电池体系和运行条件下的泛化能力，选取 Oxford、CALCE CS2、CALCE CX2 和 MIT/Severson 四组公开电池老化数据开展实验。这些数据集涵盖软包、方形和圆柱形电池，在材料体系、标称容量及运行条件等方面存在明显差异，可为模型在不同电池退化场景下的评估提供具有多样性的实验数据。各数据集的主要特性汇总于 Table 2。Fig. 2(a)–(d) 展示了所选电池的容量衰减曲线，Fig. 2(e)–(h) 给出了各数据集中代表性电池在不同 SOH 水平下的充电电压曲线。各数据集的具体情况如下。

(1) Oxford 数据集

Oxford 数据集由牛津大学电池智能实验室提供，包含 8 节 Kokam SLPB533459H4 锂离子软包电池的老化数据，每节电池的标称容量为 0.74 Ah [28]。该类电池的正极材料为镍钴酸锂 (NCO) 和钴酸锂 (LCO) 的混合物，负极材料为石墨 [60]。老化实验在 40 °C 的恒温环境下进行。电池采用恒流–恒压方式充电至 4.2 V，随后按照源自城市 ARTEMIS 工况的动态电流曲线进行放电，直至电压降至 2.7 V [28, 61]。实验纳入 Cell1–Cell8 共 8 节电池的循环老化记录。

(2) CALCE 数据集

CALCE 数据集由马里兰大学先进生命周期工程中心提供，包括 CS2 和 CX2 两组方形锂离子电池的老化数据 [18, 61]。两组电池均采用钴酸锂 (LCO) 作为正极材料，其中 CS2 电池的标称容量为 1.1 Ah，CX2 电池




Fig. 1. Flowchart of the developed SOH estimation approach.

Table 2

Description of the four battery datasets.

Data Sources	Oxford [60]	CALCE CS2 [18,61]	CALCE CX2 [18,61]	MIT/Severson [62]
Manufacturer	Kokam	LG Chem	LG Chem	A123 Systems
Cell types	Pouch	Prismatic	Prismatic	18650 cylindrical
Cathode material	NCO-LCO	LCO	LCO	LFP
Rated capacity (Ah)	0.74	1.10	1.35	1.10
Capacity failure threshold	70%	0.84 Ah (76.4%)	1.08 Ah (80%)	80%
Charge protocol (rate)	CC (2C)	CC-CV (0.5C, 4.2 V)	CC-CV (0.5C, 4.2 V)	Two-step fast charge + CC-CV (1C, 3.6 V)
Discharge protocol (rate)	variance	CC (1C)	CC (1C)	CC (4C)
Cut-off voltage (V)	charge to 4.2 discharge to 2.7	charge to 4.2 discharge to 2.7	charge to 4.2 discharge to 2.7	charge to 3.6 discharge to 2.0
Cut-off current (A)	—	charge to 0.05	charge to 0.05	charge to 0.022 (C/50)
Experiment temperature (°C)	40	24	24	30




Fig. 2. Four battery datasets: (a)–(d) capacity degradation curves of Oxford, CALCE CS2, CALCE CX2, and MIT/Severson cells, respectively; (e)–(h) charging voltage curves of the four datasets in the same order.

的标称容量为 1.35 Ah。老化实验均在室温条件下开展，电池采用恒流-恒压方式充电至 4.2 V。CS2 和 CX2 均以 1C 恒流放电至 2.7 V。实验覆盖 CS2_36-CS2_38 和 CX2_36-CX2_38 共 6 节电池的循环老化记录。

(3) MIT/Severson 数据集

MIT/Severson 数据集由麻省理工学院、斯坦福大学和丰田研究院联合发布 [62]。该数据集采用 A123 APR18650M1A 型 18650 圆柱形锂离子电池，每节电池的标称容量约为 1.1 Ah，正极材料为磷酸铁锂 (LFP)，负极材料为石墨。老化实验在 30 °C 的恒温环境下开展。实验纳入 b3c8、b3c13 和 b3c29 三节电池。三节电池均采用两步快速充电策略，其中 b3c8 采用 5.3C (54% SOC) - 4C 策略，b3c13 和 b3c29 采用 5.6C (36% SOC) - 4.3C 策略。达到 80% SOC 后，电池以 1C 恒流充电至 3.6 V，随后转入恒压充电。放电过程采用 4C 恒流方式，截止电压为 2.0 V。

2.3 特征工程

本节围绕 SOH 估计模型的输入构建展开。一方面，基于充放电数据建立多源候选健康指标池；另一方面，提出组级健康指标选择方法，利用 MS-CCCT 标定 CCCT 电压窗口，并结合特征开发电池集合上的 PCC/SCC 评价结果实现双阈值准入与冗余剔除，确定各数据集对应的模型输入。

2.3.1 健康指标提取

利用电池循环采集的电压、电流、温度、时间与容量数据，构建充电电压-时间（CVT）、增量容量（IC）、微分温度-电压（DTV）和微分温度-容量（DTC）特征曲线，如图Fig. 3(a)–(d)所示。根据曲线随老化的变化特性，提取时长、幅值、特征位置和分布宽度等特征，同时计算窗口放电容量与充放电能量效率，形成包含 15 项候选健康指标的指标池 [52,63–65]。各指标的定义与分类见Table 3。

Table 3
Definitions of the candidate HIs.

No.	Category	Health indicator
HI1	CVT	MS-CCCT 标定电压区间内的恒流充电时间
HI2	IC	增量容量曲线的峰值
HI3	IC	增量容量峰值对应的电压
HI4	IC	增量容量特征峰的半峰宽
HI5	DTV	微分温度-电压曲线的峰值
HI6	DTV	微分温度-电压曲线峰值对应的电压
HI7	DTV	微分温度-电压曲线的谷值
HI8	DTV	微分温度-电压曲线谷值对应的电压
HI9	DTV	微分温度-电压曲线的峰谷差
HI10	DTC	微分温度-容量曲线的峰值
HI11	DTC	微分温度-容量曲线峰值对应的容量
HI12	DTC	微分温度-容量特征峰的半峰宽
HI13	窗口放电容量	电压范围 3.80–3.40 V 内的放电容量
HI14	窗口放电容量	电压范围 3.20–3.00 V 内的放电容量
HI15	能量效率	单次循环放电能量与充电能量之比




Fig. 3. Charge-side characteristic curves used for HI construction.

充电电压-时间 (CVT) 曲线记录恒流充电阶段端电压随时间的变化, 可由电压与时间采样直接获取。随循环推进, CVT 曲线沿时间轴逐渐偏移 (Fig. 3(a))。容量衰减伴随电池极化增强, 使电池通过固定电压区间的充电时长发生变化, 因此该时长可用于表征电池老化 [63,64]。据此定义 CCCT:

$$CCCT(V_1, V_2) = t(V_2) - t(V_1), \quad (2)$$

式中, $t(V_1)$ 、 $t(V_2)$ 分别为充电电压达到 V_1 、 V_2 的时刻。CCCT 的电压区间由 MS-CCCT 标定, 标定所得充电时长特征记为 HI1。

除充电时序特征外, 容量随电压的变化同样包含电池退化信息。增量容量 (IC) 曲线是解析电池电化学退化的经典分析手段。该方法对容量关于电压求导, 将平缓的充电电压平台转化为辨识度更高的特征峰, 其位置与形状会随电池老化发生变化 [50,64]。IC 的具体表达式为:

$$IC = \frac{dQ}{dV} \approx \frac{Q_{k+N} - Q_k}{V_{k+N} - V_k}, \quad (3)$$

式中, V_k 和 Q_k 分别为第 k 个采样点的端电压和充电容量, N 为两个采样点之间的间隔。不同循环下, IC 曲线的峰值、特征位置和分布宽度随老化发生变化, 如图 3(b) 所示。由此提取 IC 曲线的峰值、峰值对应电压和半峰宽, 并分别定义为 HI2、HI3 和 HI4。

温度是反映电池内部状态的另一重要维度。恒流充电过程中, 电池表面温度变化通常较为缓慢, 老化带来的微小热响应差异难以通过原始温度曲线直接识别。为识别这类差异, Wu 等人 [65] 提出微分温度-电压 (DTV) 分析方法。该方法通过计算充电过程中电池表面温度相对电压的变化率, 将热响应映射至电压域, 形成随老化变化的峰谷特征曲线 [64,65]。其定义如下:

$$DTV = \frac{dT}{dV} \approx \frac{T_{k+N} - T_k}{V_{k+N} - V_k}, \quad (4)$$

其中, V_k 和 T_k 分别为第 k 个采样点的端电压和电池表面温度, N 为两个采样点之间的间隔。为减小差分噪声的影响, 对所得 DTV 曲线采用窗口大小为 200 个采样点的移动平均进行平滑处理 [64]。不同循环下, DTV 曲线的峰谷幅值与特征位置随老化发生变化, 如图 3(c) 所示。据此提取峰值 (HI5)、峰值对应电压 (HI6)、谷值 (HI7)、谷值对应电压 (HI8) 和峰谷差 (HI9), 分别描述热响应的幅值、特征位置及波动范围 [64]。

与 DTV 在电压域刻画热响应不同, DTC 在充电容量域刻画热响应。DTC 以充电容量为自变量, 描述温度变化率随容量的演化, 其定义如下 [64]:

$$DTC = \frac{dT}{dQ} \approx \frac{T_{k+N} - T_k}{Q_{k+N} - Q_k}, \quad (5)$$

其中, T_k 、 Q_k 为第 k 个采样点的电池表面温度和充电容量, N 为两个采样点之间的间隔。对所得 DTC 曲线同样采用窗口大小为 200 个采样点的移动平均进行平滑处理 [64]。Fig. 3(d) 所示 DTC 曲线同样表现出随循环变化的峰值、特征位置和分布宽度, 本文据此提取峰值、峰值对应容量和半峰宽, 并将其定义为 HI10、HI11 和 HI12。

窗口放电容量由指定电压区间内的放电电流累积积分得到, 其定义如下:

$$Q_{dch}(V_h, V_l) = \frac{1}{3600} \int_{\{t: V_l \leq V_{dch}(t) \leq V_h\}} |I_{dch}(t)| dt, \quad (6)$$

其中, $V_{dch}(t)$ 和 $I_{dch}(t)$ 分别为放电电压和电流, 积分范围为电压位于 $[V_l, V_h]$ 内的放电时间片段。时间以 s 为单位, Q_{dch} 的单位为 Ah。本文进一步构造两个窗口放电容量候选指标, 分别计算端电压由 3.80 V 降至 3.40 V 以及由 3.20 V 降至 3.00 V 过程中释放的电荷量, 并记为 HI13 和 HI14 [31,52]。

能量效率反映电池在充放电过程中的能量转换特性, 定义为单次循环放电能量与充电能量之比 [66]:

$$\eta = \frac{E_{dch}}{E_{ch}} = \frac{\int_0^{t_{dch}} V_{dch}(t) |I_{dch}(t)| dt}{\int_0^{t_{ch}} V_{ch}(t) |I_{ch}(t)| dt}, \quad (7)$$

其中, $V_{\text{ch}}(t)$ 、 $|I_{\text{ch}}(t)|$ 、 t_{ch} 与 $V_{\text{dch}}(t)$ 、 $|I_{\text{dch}}(t)|$ 、 t_{dch} 分别表示充电与放电阶段的端电压、电流幅值和持续时间, 充电与放电均取完整循环过程。该能量效率记为 HI15 (η)。

2.3.2 组级双相关 MS-CCCT

已有研究从局部充电电压区间提取时间特征 [28], 也有研究通过区间搜索或逐级细化确定相应的特征提取窗口 [31, 51, 63]。然而, 不同电池体系的退化敏感电压区间存在差异, 固定窗口可能遗漏与 SOH 密切相关的局部退化信息, 从而影响健康指标的跨电池稳定性。对于每个数据集, 采用两节电池组成特征开发集合 $\mathcal{B}$, 用于 CCCT 电压窗口标定和健康指标筛选。本文采用 MS-CCCT 进行多尺度窗口搜索, 在集合 $\mathcal{B}$ 内各电池上评价候选窗口所提取的 CCCT 与 SOH 之间的相关性, 并依据组级得分选择窗口。

为比较不同候选窗口的有效性, 需要量化窗口特征与 SOH 之间的相关性。本文同时采用皮尔逊相关系数 (PCC) 和斯皮尔曼相关系数 (SCC) 作为评价依据: PCC 衡量线性相关强度, SCC 衡量单调相关强度, 二者可分别反映线性退化趋势和单调非线性退化特征 [25, 53, 55]。第 i 个候选窗口在第 j 个特征开发电池上的 PCC $\gamma_{i,j}$ 和 SCC $\rho_{i,j}$ 定义为

$$\gamma_{i,j} = \frac{\sum_{k=1}^{n_j} (f_{i,j,k} - \bar{f}_{i,j})(y_{j,k} - \bar{y}_j)}{\sqrt{\sum_{k=1}^{n_j} (f_{i,j,k} - \bar{f}_{i,j})^2 \sum_{k=1}^{n_j} (y_{j,k} - \bar{y}_j)^2}}, \quad (8)$$

$$\rho_{i,j} = \frac{\sum_{k=1}^{n_j} (R(f_{i,j,k}) - \bar{R}(f_{i,j}))(R(y_{j,k}) - \bar{R}(y_j))}{\sqrt{\sum_{k=1}^{n_j} (R(f_{i,j,k}) - \bar{R}(f_{i,j}))^2 \sum_{k=1}^{n_j} (R(y_{j,k}) - \bar{R}(y_j))^2}}, \quad (9)$$

式中, $f_{i,j,k}$ 表示第 j 个特征开发电池上第 i 个候选窗口在第 k 个循环的特征值, $y_{j,k}$ 为对应循环的 SOH, n_j 为第 j 个特征开发电池的有效循环数。 $\bar{f}_{i,j}$ 与 $\bar{y}_j$ 分别表示该电池上特征值与 SOH 的均值。 $R(\cdot)$ 表示取秩操作, $\bar{R}(\cdot)$ 为对应秩序列的均值。 $|\gamma_{i,j}|$ 越接近 1, 说明线性关联越强; $|\rho_{i,j}|$ 越接近 1, 说明单调关联越强。

为评价候选窗口在特征开发电池集合中的共同适用性, 将第 i 个候选窗口的最小绝对 PCC 和最小绝对 SCC 分别记为 $mPCC_i = \min_{j \in \mathcal{B}} |\gamma_{i,j}|$ 和 $mSCC_i = \min_{j \in \mathcal{B}} |\rho_{i,j}|$, 并以二者中的较小值定义组级稳健得分:

$$S_i = \min_{j \in \mathcal{B}} \{\min(|\gamma_{i,j}|, |\rho_{i,j}|)\}. \quad (10)$$

该得分由候选窗口在全部特征开发电池上的最低相关性决定。只有当窗口特征在各特征开发电池上均与 SOH 保持较强的线性或单调关联时, 才能获得较高的 S_i 。

MS-CCCT 采用由粗到细的三阶段搜索 [31], 各阶段均以 S_i 评价候选窗口。不同数据集依据相应的充电电压范围设置初始搜索区间。R1 阶段以 0.40 V 窗宽和 0.20 V 步长进行粗定位, 选取得分最高的窗口作为下一阶段的搜索区域; R2 阶段在该区域内以 0.20 V 窗宽和 0.05 V 步长搜索, 确定正式窗口; R3 阶段进一步采用 0.10 V 窗宽和 0.05 V 步长细化搜索。若 R3 的最高得分超过 R2 窗口, 则采用该更窄窗口, 否则保留 R2 窗口。由此确定的 CCCT 与其余候选健康指标共同进入后续筛选, 具体标定结果将在第四章给出。

2.3.3 健康指标筛选

在 MS-CCCT 确定 HI1 的 CCCT 电压窗口后, 进一步对候选健康指标执行统一的准入与冗余剔除。本文继续采用前述 PCC 和 SCC, 分别评价候选健康指标与 SOH 之间的线性和单调关联, 并考察候选指标之间的相关关系。上述相关系数均在每节特征开发电池上分别计算。

以 Oxford 数据集为例, Fig. 4 给出了 Cell1 和 Cell2 上 SOH 与 15 项候选健康指标以及候选指标之间的 PCC 和 SCC, 其中矩阵下三角列出带符号的相关系数, 上三角以圆圈大小和颜色深浅表示相关系数的绝对值。同一候选指标在两节电池上的相关强度并不完全一致: HI5 (DTV 峰值) 在 Cell1 上的 $|PCC|$ 和 $|SCC|$ 分别为 0.949 和 0.966, 在 Cell2 上则降至 0.898 和 0.902, 而 HI1 在两节电池上均保持较高相关性; 同时, 部分候选指标之间也具有较强的 PCC 和 SCC。前一现象说明单节电池上的高相关性未必能够延续至同组其他电池,

后一现象则表明候选池中存在高度相关的信息，因而健康指标筛选需要同时考察跨电池相关性与指标间冗余。

为此，指标筛选分为候选准入和冗余剔除两个阶段：在候选准入阶段，分别以 θ_{mono} 和 θ_{lin} 约束候选指标在全部特征开发电池上的最小绝对 SCC 和最小绝对 PCC，只有同时满足两项条件的指标才能进入候选集合，并按照 $R_i = \max(mPCC_i, mSCC_i)$ 确定考察顺序；在冗余剔除阶段，依次计算候选指标与已入选指标之间的组平均绝对 PCC 和 SCC，当两项相关系数均达到 θ_{co} 时，将该候选指标判定为冗余。三个阈值在模型开发阶段预先设定，并在四个数据集的筛选过程中保持不变，筛选流程见 [Algorithm 1](#)。

Algorithm 1: Screening procedure for candidate health indicators

行号	内容
输入	候选健康指标集合 $\mathcal{F}$ ；特征开发电池集合 $\mathcal{B}$ ；各候选指标在特征开发电池上的特征序列及对应 SOH 序列；阈值 $\theta_{\text{mono}} = 0.96$ 、 $\theta_{\text{lin}} = 0.92$ 、 $\theta_{\text{co}} = 0.95$
输出	最终入选健康指标集合 $\mathcal{S}$
1	初始化候选集合 $\mathcal{C} = \emptyset$ ，最终入选集合 $\mathcal{S} = \emptyset$
2	For 每个候选指标 $f_i \in \mathcal{F}$ do
3	计算组内最小单调相关性： $mSCC_i = \min_j \rho_{i,j} $
4	计算组内最小线性相关性： $mPCC_i = \min_j \gamma_{i,j} $
5	If $mSCC_i \geq \theta_{\text{mono}}$ 且 $mPCC_i \geq \theta_{\text{lin}}$ then
6	将 f_i 加入候选集合 $\mathcal{C}$
7	End If
8	End For
9	按 $R_i = \max(mPCC_i, mSCC_i)$ 对 $\mathcal{C}$ 降序排序
10	For 排序后的每个候选指标 $f_i \in \mathcal{C}$ do
11	计算 f_i 与每个已入选指标 $f_s \in \mathcal{S}$ 的组平均绝对 PCC 和 SCC，分别记为 $\Phi_{\text{PCC}}(i, s)$ 和 $\Phi_{\text{SCC}}(i, s)$
12	If 存在 $f_s \in \mathcal{S}$ 使 $\Phi_{\text{PCC}}(i, s) \geq \theta_{\text{co}}$ 且 $\Phi_{\text{SCC}}(i, s) \geq \theta_{\text{co}}$ then
13	判定 f_i 为冗余指标并跳过
14	Else
15	将 f_i 加入最终入选集合 $\mathcal{S}$
16	End If
17	End For
18	Return $\mathcal{S}$

按照上述准入与冗余剔除过程，可从候选指标中确定各数据集对应的健康指标组合。具体筛选结果及其跨电池表现将在第四章进行分析。




Fig. 4. Correlation matrices of candidate HIs and SOH on the Oxford dataset.

3. 所提出的 MS-AgentNet 模型

本章介绍 MS-AgentNet 的总体架构,并阐述所设计的包含 DSConv-S 和 DSConv-L 在内的多尺度深度可分离卷积模块;在此基础上,详细说明所提出的轻量级局部-全局融合注意力 (Slim Local-Global Fusion Attention, SLFA) 模块。

3.1 MS-AgentNet 总体架构与数据流

针对现有 SOH 估计模型在估计精度与计算效率之间难以兼顾的问题,本文提出一种轻量级多尺度智能体网络 (Multi-Scale Agent Network, MS-AgentNet)。该模型采用小核与大核深度可分离卷积提取不同时间尺度的退化特征,并结合 ReLU² 智能体注意力 (ReLU² Agent Attention, RAA) 进行跨位置全局信息交互。其中,“MS”表示由小核 DSConv-S 与大核 DSConv-L 构成的多尺度卷积设计。

MS-AgentNet 的整体架构如图 5 所示。健康指标 (Health Indicators, HIs) 序列经滑动窗口分割后,首先通过线性嵌入层映射至 d 维特征空间;随后,嵌入特征进入 MS-AgentNet Block,并在 Block 内依次完成局部-全局特征融合、长尺度特征细化与非线性映射。最后,模型对输出特征进行层归一化、展平和线性读出,得到 SOH 估计值。

训练过程中,每个输入窗口以窗口后紧邻循环的真实 SOH 值作为监督标签。

从数学角度看，设第 l 个 MS-AgentNet Block 的输入为 $\mathbf{X}_l \in \mathbb{R}^{B \times N \times d}$ ，其中 B 为批量大小， N 为输入序列长度， d 为嵌入维度。其内部特征变换可表示为以下过程：

步骤 1：局部一全局融合。输入特征先由 SLFA 模块完成小核局部增强和智能体全局交互：

$$\mathbf{X}'_l = \text{SLFA}(\mathbf{X}_l). \quad (11)$$

步骤 2：长尺度特征细化。为提取较长时间尺度的退化特征，中间特征 $\mathbf{X}'_l$ 先经层归一化，再通过 DSConv-L 模块，所得特征经可学习系数 W_l 缩放后，以残差形式与 $\mathbf{X}'_l$ 相加：

$$\mathbf{X}''_l = \mathbf{X}'_l + W_l \text{DSConv-L}(\text{LN}(\mathbf{X}'_l)). \quad (12)$$

步骤 3：非线性映射。细化后的特征 $\mathbf{X}''_l$ 经层归一化后输入 FFN，并通过残差连接得到输出 $\mathbf{Y}_l$ ：

$$\mathbf{Y}_l = \mathbf{X}''_l + \text{FFN}(\text{LN}_0(\mathbf{X}''_l)). \quad (13)$$

并令该 Block 的输出为 $\mathbf{X}_{l+1} = \mathbf{Y}_l$ 。其中，SLFA($\cdot$)、DSConv-L($\cdot$) 和 FFN($\cdot$) 分别表示轻量级局部一全局融合注意力模块、大核深度可分离卷积模块和前馈神经网络； W_l 为可学习缩放系数，LN($\cdot$) 表示层归一化，LN₀($\cdot$) 表示不含可学习仿射参数的层归一化。




Fig. 5. Framework of MS-AgentNet. (a) Overall architecture; (b) core structure; (c) DSConv-L module.

3.2 所设计的多尺度深度可分离卷积模块

本节首先介绍 DSConv 的基本结构，并将其与标准卷积进行计算量比较；随后说明 DSConv-S 和 DSConv-L 的结构配置及其多尺度特性。

3.2.1 DSConv 基本结构与计算量比较

卷积运算通过滑动卷积核提取时间序列中的局部信息 [71]。标准卷积在所有输入通道上进行运算，每个卷积核生成一个输出特征图，对应一个输出通道。随着输入通道数、输出通道数和卷积核尺寸增加，其参数量与计算开销迅速累积，显著推高计算负载并延长训练时间。在小样本电池数据集上，较大的参数量还可能增加模型的过拟合风险。其计算成本可表示为：

$$C_{\text{Conv}} = k \times k \times C_{\text{in}} \times C_{\text{out}} \times D_F \times D_F. \quad (14)$$

其中， k 、 C_{in} 、 C_{out} 和 D_F 分别表示卷积核大小、输入通道数、输出通道数和特征图尺寸。

与标准卷积不同，深度可分离卷积（DSConv）将卷积运算分解为深度卷积和逐点卷积两个阶段 [71]。其




Fig. 6. The fundamental structures of convolutional modules: (a) standard convolution; (b) standard depthwise separable convolution; (c) DSConv-S module; and (d) DSConv-L module.

中，深度卷积为每个输入通道单独配置卷积核，在通道内完成局部特征提取；随后， 1×1 逐点卷积融合不同通道的特征，并将通道数调整为 C_{out} 。通过分离通道内特征提取与通道间特征融合，DSConv 减少了标准卷积中的密集跨通道运算。其计算成本可表示为：

$$C_{DSConv} = k \times k \times C_{in} \times D_F \times D_F + C_{in} \times C_{out} \times D_F \times D_F. \quad (15)$$

进一步比较两类卷积的计算量，可得二者之比为：

$$\begin{aligned} \frac{C_{DSConv}}{C_{Conv}} &= \frac{k \times k \times C_{in} \times D_F \times D_F + C_{in} \times C_{out} \times D_F \times D_F}{k \times k \times C_{in} \times C_{out} \times D_F \times D_F} \\ &= \frac{1}{C_{out}} + \frac{1}{k^2}. \end{aligned} \quad (16)$$

由式(16)可知，在输入、输出通道配置一致的情况下，DSConv 的计算成本低于标准卷积，为后续小核与大核卷积模块的构建提供了基础。

3.2.2 DSConv-S：双重作用的局部增强

小核 DSConv-S 采用紧凑的 1×5 深度卷积，并嵌入 SLFA 模块、位于 RAA 全局交互之前，以实现输入增强与局部分支保留两项作用：

1. **输入增强**。DSConv-S 提取输入特征中的局部邻域信息，形成局部增强表示 $\mathbf{X}_S$ 。RAA 随后基于 $\mathbf{X}_S$ 构造查询、键和值，并通过智能体聚合与广播完成跨位置交互。这一前置卷积为 RAA 引入局部性偏置，增强其在跨位置上下文聚合过程中对局部变化的表征。

2. **局部分支保留**。在 SLFA 中， $\mathbf{X}_S$ 同时传递至 RAA 分支和局部分支。局部分支对 $\mathbf{X}_S$ 进行层归一化后传递至融合端，并与 RAA 分支建立的跨位置上下文进行融合，形成局部特征与全局信息的互补表示。

DSConv-S 采用两倍通道扩展。输入首先经转置使特征维度对应卷积通道维度，再通过第一层 1×1 逐点卷积完成通道扩展。随后， 1×5 深度卷积在各通道内提取短邻域特征，并经 ReLU 激活；第二层 1×1 逐点卷积进一步融合通道信息并恢复输出维度。最后，输出经逆转置后与输入通过残差连接融合。上述过程表示为：

$$\mathbf{X}_S = \mathbf{X} + \mathcal{T}^{-1}[\text{PW}_{\downarrow}(\text{ReLU}(\text{DW}_5(\text{PW}_{\uparrow}(\mathcal{T}(\mathbf{X})))))]. \quad (17)$$

其中， $\text{PW}_{\uparrow}$ 和 $\text{PW}_{\downarrow}$ 分别表示通道扩展和通道恢复的逐点卷积， DW_5 表示尺寸为 1×5 的深度卷积， $\mathcal{T}(\cdot)$ 与 $\mathcal{T}^{-1}(\cdot)$ 分别表示转置和逆转置操作。为便于后文表述，将上述过程简记为

$$\mathbf{X}_S = \text{DSConv-S}(\mathbf{X}).$$

计算分析。在两倍通道扩展条件下，DSConv-S 的计算成本主要来自两层 1×1 逐点卷积和一层 1×5 深度卷积，可表示为：

$$C_{\text{in}} \times 2C_{\text{out}} \times D_F \times D_F + 1 \times 5 \times 2C_{\text{out}} \times D_F \times D_F + 2C_{\text{out}} \times C_{\text{out}} \times D_F \times D_F,$$

其中， $2C_{\text{out}}$ 和 $D_F \times D_F$ 分别表示扩展后的通道数和特征图尺寸。

3.2.3 DSConv-L：后融合长尺度细化

DSConv-L 置于 SLFA 之后，利用大核卷积从融合后的特征中提取较长时间尺度的退化信息。

DSConv-L 同样按照“通道扩展—卷积特征提取—通道恢复”的顺序组织，并采用三倍通道扩展和 1×31 深度卷积。其计算过程表示为：

$$\text{DSConv-L}(\mathbf{X}) = \mathcal{T}^{-1}[\text{PW}_{L,\text{out}}(\text{ReLU}(\text{DW}_{31}(\text{PW}_{L,\uparrow}(\mathcal{T}(\mathbf{X})))))]. \quad (18)$$

其中， $\text{PW}_{L,\uparrow}$ 和 $\text{PW}_{L,\text{out}}$ 分别表示通道扩展和通道恢复的逐点卷积， DW_{31} 表示尺寸为 1×31 的大核深度卷积。

计算分析。在三倍通道扩展条件下，DSConv-L 的计算成本可表示为：

$$C_{\text{in}} \times 3C_{\text{out}} \times D_F \times D_F + 1 \times 31 \times 3C_{\text{out}} \times D_F \times D_F + 3C_{\text{out}} \times C_{\text{out}} \times D_F \times D_F,$$

其中， $3C_{\text{out}}$ 和 $D_F \times D_F$ 分别表示扩展后的通道数和特征图尺寸。

3.3 所提出的轻量级局部—全局融合注意力模块

本节给出多头自注意力的一般形式，简要比较 Softmax 注意力与线性注意力，并在此基础上介绍所提出的 SLFA 模块。该模块兼顾局部—全局特征建模与计算效率。




Fig. 7. Comparison of (a) Softmax attention, (b) linear attention, (c) Agent Attention, and (d) the proposed SLFA module.

3.3.1 多头自注意力的一般形式

多头自注意力通过多个并行注意力头在不同表示子空间内计算特征之间的相关性 [34]。设输入特征为 $\mathbf{X} \in \mathbb{R}^{N \times d}$ ，第 i 个注意力头的查询、键和值表示为：

$$\mathbf{Q}_i = \mathbf{X}\mathbf{W}_i^Q, \quad \mathbf{K}_i = \mathbf{X}\mathbf{W}_i^K, \quad \mathbf{V}_i = \mathbf{X}\mathbf{W}_i^V. \quad (19)$$

其中， N 为序列长度， d 为输入特征维度， $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V \in \mathbb{R}^{d \times d_h}$ 为可学习投影矩阵， $i = 1, 2, \dots, h$ ， h 为注意力头数， $d_h = d/h$ 为单个注意力头的特征维度。

在采用非负相似度函数构造归一化注意力权重时，第 i 个注意力头在第 p 个位置的输出可表示为：

$$\mathbf{O}_{i,p} = \frac{\sum_{j=1}^N \text{Sim}(\mathbf{Q}_{i,p}, \mathbf{K}_{i,j}) \mathbf{V}_{i,j}}{\sum_{j=1}^N \text{Sim}(\mathbf{Q}_{i,p}, \mathbf{K}_{i,j})}, \quad p = 1, 2, \dots, N. \quad (20)$$

其中, $\mathbf{Q}_{i,p}$ 表示第 i 个注意力头中第 p 个位置的查询, $\mathbf{K}_{i,j}$ 和 $\mathbf{V}_{i,j}$ 分别表示第 j 个位置的键和值, $\text{Sim}(\cdot, \cdot)$ 表示非负相似度函数 [40]。

所有位置的输出共同构成第 i 个注意力头的输出矩阵 $\mathbf{O}_i \in \mathbb{R}^{N \times d_h}$, 各注意力头的输出随后沿特征维度拼接。不同注意力机制的主要区别在于相似度函数及其计算顺序。

3.3.2 Softmax 注意力与线性注意力

标准 Softmax 注意力通过查询与键的点积计算序列位置之间的相关性, 并利用 Softmax 函数对相关性得分进行归一化 [34]。第 i 个注意力头的输出可表示为:

$$\mathbf{O}_i = \text{Softmax} \left(\frac{\mathbf{Q}_i \mathbf{K}_i^T}{\sqrt{d_h}} \right) \mathbf{V}_i. \quad (21)$$

Softmax 中的指数映射与归一化使相关性较高的查询—键对获得更大的注意力权重 [34]。然而, $\mathbf{Q}_i \mathbf{K}_i^T$ 需要计算所有查询与键之间的两两关系, 并形成尺寸为 $N \times N$ 的注意力矩阵。因此, 单个注意力头的计算复杂度为 $O(N^2 d_h)$, 相关性矩阵的存储复杂度为 $O(N^2)$; 随着序列长度增加, 其计算与存储开销会显著增大 [34, 39]。

针对 Softmax 注意力的二次计算开销, 线性注意力利用核函数 $\phi(\cdot)$ 映射查询和键, 并借助矩阵乘法结合律重新组织计算顺序 [40]。第 i 个注意力头的输出可写为:

$$\mathbf{O}_i = \frac{\phi(\mathbf{Q}_i) [\phi(\mathbf{K}_i)^T \mathbf{V}_i]}{\phi(\mathbf{Q}_i) [\phi(\mathbf{K}_i)^T \mathbf{1}]}. \quad (22)$$

其中, $\phi(\cdot)$ 表示非负特征映射, 例如 $\phi(\mathbf{x}) = \text{ELU}(\mathbf{x}) + 1$; $\mathbf{1}$ 表示全 1 向量, 用于计算对应的归一化项 [40]。

通过优先计算 $\phi(\mathbf{K}_i)^T \mathbf{V}_i$, 线性注意力避免了完整 $N \times N$ 注意力矩阵的构造。当特征映射维度与 d_h 一致时, 其计算复杂度为 $O(N d_h^2)$; 当 d_h 固定时, 该复杂度关于序列长度 N 为线性 [40]。

线性注意力以较低计算复杂度完成全局信息交互, 但其计算过程未显式引入局部邻域特征 [31, 39, 40, 64]。因此, 需要进一步协同建模跨位置交互与局部特征。

3.3.3 所提出的 SLFA 模块

为同时捕获局部邻域特征与跨位置交互, 本文将 DSConv-S 与所构建的 ReLU² 智能体注意力 (ReLU² Agent Attention, RAA) 相结合, 提出 SLFA 模块, 其结构如图 7(d) 所示。该模块采用局部分支与 RAA 分支的融合形式: DSConv-S 首先提取局部表示, RAA 随后以该表示为输入完成跨位置特征交互, 两个分支的输出经加法融合。

(1) ReLU² 智能体注意力。

Agent Attention 以少量智能体作为信息中介, 将序列位置之间的全局交互分解为上下文聚合与信息广播两个阶段 [46]: 智能体首先从键和值中聚合序列上下文, 各查询位置随后从智能体上下文中读取信息。

为降低查询、键和值生成过程中的参数开销, RAA 采用可学习通道缩放调节不同特征通道的相对贡献, 并将缩放后的特征划分至各注意力头:

$$\mathbf{Q}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_q), \quad \mathbf{K}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_k), \quad \mathbf{V}_i = \text{Split}_i(\mathbf{X} \odot \mathbf{s}_v). \quad (23)$$

其中, $\mathbf{s}_q, \mathbf{s}_k, \mathbf{s}_v \in \mathbb{R}^d$ 为可学习通道缩放向量, $\odot$ 表示逐元素相乘, $\text{Split}_i(\cdot)$ 表示沿特征维度划分为 h 个 d_h 维子空间并取第 i 个子空间。

相较于标准查询、键和值线性投影约 $3d^2$ 的参数量, 三组通道缩放向量仅包含 $3d$ 个参数, 从而降低了查询、键和值生成过程中的参数开销。

RAA 设置 $n_a = 2$ 个可学习智能体, 以矩阵 $\mathbf{A} \in \mathbb{R}^{n_a \times d}$ 表示, 其参数通过训练学习, 并在不同输入样本间共享。

沿特征维度将全局智能体矩阵 $\mathbf{A}$ 划分为 h 个子空间，第 i 个注意力头对应的智能体表示为 $\mathbf{A}_i = \text{Split}_i(\mathbf{A}) \in \mathbb{R}^{n_a \times d_h}$ 。

在信息广播阶段，查询需要根据自身与两个智能体的匹配关系分配上下文权重。标准 Agent Attention 在聚合与广播阶段均采用 Softmax 归一化。当一行得分按共同正比例缩小时，正得分之间的相对比例虽然保持不变，权重却趋于均匀，使对应查询对两个智能体上下文的读取趋向等权混合。为在这种尺度变化下保留正相关匹配的区别，RAA 在两个阶段采用 ReLU² 行归一化：

$$[\mathcal{R}_2(\mathbf{Z})]_{r,c} = \begin{cases} \frac{\text{ReLU}(\mathbf{Z}_{r,c})^2}{\sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2}, & \sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2 > 0, \\ \frac{1}{M}, & \sum_{j=1}^M \text{ReLU}(\mathbf{Z}_{r,j})^2 = 0. \end{cases} \quad (24)$$

其中， M 表示每一行参与归一化的元素数量：在智能体聚合阶段， $M = N$ ；在信息广播阶段， $M = n_a$ 。ReLU 截断非正相关性得分。对于含有正得分的行，共同正尺度的平方在分子与分母中相互抵消，因此整体得分按共同正比例变化时，权重分配保持不变。平方操作进一步增大较大与较小正得分的权重比，使归一化权重更加突出较高的正相关性得分。当某一行不存在正相关性得分时， $\mathcal{R}_2(\cdot)$ 返回均匀分布，以保持归一化结果的有效性。

在智能体聚合阶段， $\mathbf{A}_i$ 作为查询，从序列的键和值中汇集上下文：

$$\Phi_{k,i} = \mathcal{R}_2\left(\frac{\mathbf{A}_i \mathbf{K}_i^T}{\sqrt{d_h}}\right), \quad \mathbf{V}_{A,i} = \Phi_{k,i} \mathbf{V}_i. \quad (25)$$

其中， $\Phi_{k,i} \in \mathbb{R}^{n_a \times N}$ 表示智能体对各序列位置的聚合权重， $\mathbf{V}_{A,i} \in \mathbb{R}^{n_a \times d_h}$ 表示聚合得到的智能体上下文。

在信息广播阶段，各查询位置根据自身特征从智能体上下文中读取信息：

$$\Phi_{q,i} = \mathcal{R}_2\left(\frac{\mathbf{Q}_i \mathbf{A}_i^T}{\sqrt{d_h}}\right), \quad \mathbf{O}_i = \Phi_{q,i} \mathbf{V}_{A,i}. \quad (26)$$

其中， $\Phi_{q,i} \in \mathbb{R}^{N \times n_a}$ 表示各查询位置对智能体的广播权重， $\mathbf{O}_i \in \mathbb{R}^{N \times d_h}$ 为第 i 个注意力头的输出。各查询与智能体的匹配得分经 ReLU² 行归一化得到广播权重，用于对两个智能体上下文进行加权组合，形成相应的全局交互表示。

由式(25)和式(26)可知，从等效映射角度看，第 i 个注意力头中智能体介导的序列交互可表示为 $\Phi_{q,i} \Phi_{k,i} \in \mathbb{R}^{N \times N}$ ，其秩不超过智能体数量 n_a 。

各注意力头的输出沿特征维度拼接，并通过可学习输出缩放向量 $\mathbf{s}_o$ 调节通道响应，随后与输入特征进行残差相加：

$$\text{RAA}(\mathbf{X}) = \mathbf{X} + \text{Concat}(\mathbf{O}_1, \dots, \mathbf{O}_h) \odot \mathbf{s}_o. \quad (27)$$

其中， $\text{Concat}(\cdot)$ 表示沿特征维度拼接各注意力头的输出， $\mathbf{s}_o \in \mathbb{R}^d$ 为可学习输出缩放向量。

RAA 在聚合与广播阶段分别生成 $n_a \times N$ 和 $N \times n_a$ 相关性矩阵。由此，单个注意力头的计算复杂度为 $O(Nn_a d_h)$ ， h 个注意力头的总计算复杂度为 $O(Nn_a d)$ ，相关性权重的存储规模为 $O(hNn_a)$ 。当 h 和 n_a 固定时，计算量与存储量均随序列长度 N 线性增长。

(2) 局部—全局特征融合。

输入特征 $\mathbf{X}$ 首先经 DSConv-S 得到局部表示 $\mathbf{X}_S = \text{DSConv-S}(\mathbf{X})$ ，随后分别进入局部分支和 RAA 分支。局部分支对 $\mathbf{X}_S$ 进行层归一化，RAA 分支通过智能体聚合与信息广播建立跨位置特征交互。SLFA 的融合输出 $\mathbf{X}_F$ 计算如下：

$$\mathbf{X}_F = \text{LN}(\mathbf{X}_S) + W_a \text{Dropout}(\text{RAA}(\mathbf{X}_S)). \quad (28)$$

其中， $\mathbf{X}_F$ 表示 SLFA 的融合输出， $\text{LN}(\mathbf{X}_S)$ 为局部分支的归一化表示， $\text{RAA}(\mathbf{X}_S)$ 为 RAA 分支输出； $\text{Dropout}(\cdot)$ 用于训练阶段的正则化 [75]， W_a 为调节 RAA 分支贡献的可学习缩放系数。

这种加性连接保留了 DSConv-S 提取的局部退化特征，并融合 RAA 建立的跨位置上下文，在形成局部—全局联合表示的同时，保持关于序列长度 N 的线性计算复杂度。

4. 实验结果与分析

本节在四个公开电池数据集上对所提出的 MS-AgentNet 进行系统评估，并与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种基线模型进行比较。各数据集均采用跨电池设置完成模型开发与性能评价。

在报告 SOH 估计精度的基础上，首先比较不同健康指标输入对 SOH 估计结果的影响，随后考察模型的训练稳定性与跨数据集迁移能力，并通过模块消融和复杂度比较，分析关键模块的作用及模型的计算与存储开销。

4.1 评价指标

采用 SOH 估计研究中常用的平均绝对误差 (MAE)、平均绝对百分比误差 (MAPE)、均方根误差 (RMSE) 和决定系数 (R^2) 评价模型性能 [76]。

MAE 表示全部评价样本中预测 SOH 与真实 SOH 之间绝对误差的平均值，用于反映模型的整体误差水平。该指标不会进一步放大单个较大偏差，能够较为直观地衡量总体估计精度。

MAPE 通过真实 SOH 对绝对误差进行归一化，便于比较不同数据集上的估计性能。当真实 SOH 接近零时，MAPE 可能被显著放大，需结合 MAE 和 RMSE 进行综合评价。

RMSE 表示预测 SOH 与真实 SOH 之间均方误差的平方根。与 MAE 相比，RMSE 对较大的预测偏差赋予更高权重，可以进一步反映模型对较大误差的控制能力。

R^2 衡量模型对真实 SOH 变化的拟合程度，其值越接近 1，表明模型对整体退化趋势的拟合效果越好。

上述四项指标的数学定义如下：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (29)$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (30)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (31)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (32)$$

其中， y_i 和 $\hat{y}_i$ 分别表示第 i 个样本的真实 SOH 和预测 SOH， $\bar{y}$ 表示评价样本中真实 SOH 的平均值， n 表示评价样本总数。

4.2 健康指标构建与输入有效性分析

按照第 2.3 节所述方法，首先在各数据集的特征开发电池上标定 CCCT 电压窗口。不同数据集的初始搜索范围、最终窗口及组级稳健得分见 Table 4。

Table 4
Calibration results of the MS-CCCT window.

Dataset	Initial range (V)	MS-CCCT window (V)	$mPCC$	$mSCC$	S_i
Oxford	3.50–4.20	3.55–3.75	0.997322	0.994447	0.994447
CS2	3.50–4.20	3.80–4.00	0.990286	0.980124	0.980124
CX2	3.50–4.20	3.85–4.05	0.985921	0.990832	0.985921
MIT/Severson	2.120–3.550	2.970–3.170	0.995272	0.994419	0.994419

四个数据集最终确定的窗口并不相同，表明与退化密切相关的充电电压区间会随电池体系和运行条件发生变化。各窗口的组级稳健得分均超过 0.98，说明由相应窗口提取的 CCCT 在两节特征开发电池上均保持了较强的线性和单调关联。

在完成 CCCT 窗口标定后，利用统一的相关性阈值和冗余约束对 15 项候选指标进行筛选，所得健康指标组合见 Table 5。Oxford 和 CALCE CS2 均保留 HI1，其中 CS2 进一步保留 HI2；CALCE CX2 保留窗口放电容量 HI13，MIT/Severson 则保留 HI14 和能量效率 HI15。不同数据集获得的指标组合存在差异，说明模型输入需要结合相应数据中的退化特征进行确定。

Table 5
Selected HIs and their correlations.

Dataset	Selected HI	Feature-development cell	$ \gamma $	$ \rho $
Oxford	HI1	Cell1	0.998759	0.998710
		Cell2	0.997322	0.994447
CS2	HI1	CS2_36	0.990838	0.986319
		CS2_37	0.990286	0.980124
	HI2	CS2_36	0.940029	0.989905
		CS2_37	0.938326	0.988319
CX2	HI13	CX2_36	0.999080	0.998532
		CX2_37	0.997987	0.996442
MIT/Severson	HI14	b3c8	0.972972	0.995614
		b3c13	0.970917	0.997651
	HI15	b3c8	0.979188	0.988926
		b3c13	0.994096	0.995717

筛选阶段的相关性来自特征开发电池。为考察这种关联能否延续至同一数据集的其他电池，在保持指标定义及计算参数不变的条件下，进一步计算入选指标的 PCC 和 SCC，结果见 Table 6。Oxford Cell3–Cell8 上 HI1 的 $|\gamma|$ 和 $|\rho|$ 均高于 0.997，其余三个数据集中相应电池上的最低 $|\gamma|$ 和 $|\rho|$ 分别为 0.932937 和 0.974359。由此可见，筛选得到的指标在未参与筛选的电池上仍保持较强的线性和单调关联。

Table 6
Correlations of selected HIs on other cells.

Cell	Selected HI	$ \gamma $	$ \rho $
Cell3	HI1	0.999052	0.999672
Cell4	HI1	0.998933	0.999884
Cell5	HI1	0.997874	1.000000
Cell6	HI1	0.998257	0.999877
Cell7	HI1	0.999337	0.999606
Cell8	HI1	0.999259	0.999699
CS2_38	HI1	0.986076	0.974359
CS2_38	HI2	0.932937	0.986793
CX2_38	HI13	0.999576	0.999062
b3c29	HI14	0.973516	0.996569
b3c29	HI15	0.990303	0.992179

以能够获得逐电池文献结果的 Oxford 数据集为例，进一步将 HI1 与样本熵、DTV/IC 特征及充电电压曲线斜率进行比较，结果见 Table 7。HI1 在 Cell3–Cell8 上的 $|PCC|$ 为 0.997874–0.999337，均高于所列文献在相应电池上的已报道值。

上述结果从相关性角度反映了入选指标的退化表征能力，而不同指标作为模型输入时对估计结果的实际影响还需进一步比较。为此，在相同的 MS-AgentNet 结构、训练设置和电池划分下，分别采用 HI1、HI2、HI5 和 HI10 作为单一输入，以对应 MS-CCCT、IC、DTV 和 DTC 特征，并将四类指标同时输入模型的情况记为 Fusion。Oxford Cell2–Cell8 上的 SOH 估计误差见 Table 8。

Table 7

Absolute PCC comparison of different HIs on the Oxford dataset.

Cell	HI	Sample entropy [67]	PP_{DTV} [68]	P_{IC} [68]	DTV peak position FV_6 [69]	Voltage slope [70]
Cell3	0.999052	0.9876	0.9393	0.9729	0.964	0.9980
Cell4	0.998933	0.9885	0.9102	0.9817	0.972	—
Cell5	0.997874	0.9133	0.9574	0.9034	—	—
Cell6	0.998257	0.9848	0.9299	0.9788	—	—
Cell7	0.999337	0.9896	0.9676	0.9748	0.983	0.9982
Cell8	0.999259	0.9908	0.9654	0.9713	0.981	0.9979

Note: Voltage slope denotes the slope of the charging-voltage curve. An em dash indicates that the corresponding correlation coefficient was not reported in the cited study.

Table 8

SOH estimation errors of different health-indicator inputs on the Oxford dataset.

Cell	MAE					RMSE					MAPE				
	CCCT	IC	DTV	DTC	Fusion	CCCT	IC	DTV	DTC	Fusion	CCCT	IC	DTV	DTC	Fusion
Cell2	0.00429	0.00702	0.01705	0.04836	0.01607	0.00694	0.00984	0.02076	0.05624	0.01971	0.00524	0.00874	0.02014	0.05847	0.01910
Cell3	0.00280	0.00452	0.09846	0.11398	0.02282	0.00351	0.00523	0.10422	0.12860	0.02636	0.00333	0.00530	0.11324	0.13890	0.02657
Cell4	0.00814	0.00578	0.01257	0.02765	0.01281	0.00873	0.00738	0.01458	0.03731	0.01620	0.00960	0.00685	0.01443	0.03118	0.01440
Cell5	0.00302	0.00725	0.02608	0.09392	0.01820	0.00353	0.00787	0.03627	0.10072	0.02159	0.00343	0.00816	0.02864	0.10575	0.02044
Cell6	0.00593	0.00866	0.01272	0.07225	0.02217	0.00842	0.01158	0.01608	0.08643	0.02551	0.00705	0.00998	0.01430	0.07985	0.02519
Cell7	0.00802	0.01668	0.01250	0.06098	0.01906	0.00829	0.01713	0.01542	0.07415	0.02074	0.00923	0.01913	0.01413	0.06830	0.02176
Cell8	0.00389	0.01224	0.02046	0.07918	0.03383	0.00472	0.01321	0.02351	0.09076	0.03861	0.00444	0.01411	0.02413	0.08970	0.03868
Average	0.00516	0.00888	0.02855	0.07090	0.02071	0.00631	0.01032	0.03298	0.08203	0.02410	0.00605	0.01032	0.03271	0.08174	0.02373

Table 8显示, HI1 在 Cell2、Cell3 和 Cell5–Cell8 上均取得最低的 MAE、RMSE 和 MAPE, IC 特征则在 Cell4 上表现更优。同一指标在不同电池上的估计效果存在差异,与前述跨电池相关性分析所揭示的现象一致。从 Cell2–Cell8 的平均结果来看, HI1 的 MAE、RMSE 和 MAPE 分别为 0.00516、0.00631 和 0.00605, 均低于其余单一指标。Fusion 的三项平均误差分别为 0.02071、0.02410 和 0.02373, 同样未超过 HI1, 说明增加输入指标数量并不必然改善 SOH 估计结果, 候选指标的有效性及其冗余关系会共同影响模型输入质量。

基于上述标定、筛选和输入对比结果, 后续模型实验分别采用 HI1、HI1 与 HI2、HI13 以及 HI14 与 HI15 作为 Oxford、CALCE CS2、CALCE CX2 和 MIT/Severson 数据集的输入, 并在模型训练、配置和性能评价过程中保持不变。

4.3 模型训练鲁棒性与超参数分析

为进一步考察 MS-AgentNet 的训练稳定性及轻量化模型的参数设置, 本文对智能体矩阵的初始化策略、模型收敛表现和超参数配置进行分析。

4.3.1 智能体矩阵初始化与收敛性分析

为评估 MS-AgentNet 的训练稳定性, 本文利用训练日志中提取的定量指标, 分析智能体矩阵的初始化策略和模型的收敛行为。

初始化策略。RAA 将智能体表示为与输入无关的静态可学习矩阵 $\mathbf{A} \in \mathbb{R}^{n_a \times d}$, 该矩阵直接参与全局特征聚合, 智能体数量固定为 $n_a = 2$ 。矩阵参数采用均值为 0、标准差为 0.02 的普通正态分布初始化:

$$A_{ij} \sim \mathcal{N}(0, 0.02^2) \quad (33)$$

其中, A_{ij} 表示第 i 个智能体在第 j 个特征维度上的参数。该设置为不同智能体提供小尺度随机初值。

在 Oxford 数据集上比较普通正态、截断正态和 Xavier 均匀初始化, 具体结果见 Table 9。

三种策略在 Cell2 上获得了相近的估计结果, 平均 R^2 为 0.98527~0.98645, RMSE 为 0.00774~0.00805, MAE 为 0.00485~0.00499。因此, 本文沿用普通正态初始化作为默认设置。

收敛特性。为量化收敛速度, 定义相对收敛阈值, 即训练损失首次下降至首轮损失 10% 以下的训练轮次。最后 20 个训练轮次的损失均值和标准差用于表征后期收敛阶段的损失水平和波动。

Table 10显示, Oxford 和 MIT 数据集上的阈值轮次中位数分别为 26 和 7, 后期损失标准差中位数分别为

Table 9
Initialization strategy comparison on Oxford Cell2.

Initialization	R^2 mean $\pm$ SD	RMSE mean $\pm$ SD	MAE mean $\pm$ SD
Normal $\mathcal{N}(0, 0.02^2)$	0.98606 ± 0.00411	0.00784 ± 0.00116	0.00490 ± 0.00054
Truncated normal ($\pm 2\sigma$)	0.98645 ± 0.00371	0.00774 ± 0.00103	0.00485 ± 0.00048
Xavier uniform	0.98527 ± 0.00462	0.00805 ± 0.00126	0.00499 ± 0.00058

Table 10
Convergence characteristics of MS-AgentNet on the Oxford and MIT datasets.

Dataset	10% threshold epoch median [range]	Late loss mean median	Late loss SD median
Oxford	26 [18–35]	8.14×10^{-4}	2.38×10^{-4}
MIT	7 [6–8]	5.84×10^{-5}	4.84×10^{-6}

2.38×10^{-4} 和 4.84×10^{-6} ，各次训练均达到所定义的相对收敛阈值。

4.3.2 超参数分析

配置协议。为考察模型在不同电池上的适用性，每个数据集选取两节电池组成特征开发集合，共同用于健康指标筛选，其中一节用于模型训练，另一节用于模型配置（以 Oxford 数据集为例，分别为 Cell1 和 Cell2）。随后，将训练后的模型直接应用于相应数据集的其他电池（Cell3–Cell8）。

本文重点考察学习率、网络深度 L 和嵌入维度 d 等超参数，其取值范围见 Table 11。

Table 11
Hyperparameter search space of MS-AgentNet.

超参数	搜索空间
学习率	0.001, 0.01
网络深度 L	1, 2, 4, 8
嵌入维度 d	16, 32, 64, 128
全连接层维度	16, 32, 64, 128

后续实验均采用 $d = 16$ 、 $L = 1$ 的模型配置。

4.4 SOH 估计精度与跨电池泛化性能比较

4.4.1 Oxford 数据集上的估计精度分析

在上述固定的健康指标输入下，本文将 MS-AgentNet 与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种模型进行比较，五种模型的层配置如 Table 12 所示。

五种模型在 Oxford Cell2–Cell8 上的 SOH 估计结果如 Fig. 8 所示。

总体而言，五种模型均能够跟踪 Oxford Cell2–Cell8 的容量衰减趋势，但在局部变化区间和预测误差分布上存在差异。在 Cell3–Cell6 上，MS-AgentNet 的误差分布整体较为集中。

值得注意的是，Cell4 的局部偏离和 Cell6 后段的快速下降使不同模型表现出不同程度的跟踪偏差。局部放大结果显示，MS-AgentNet 在上述变化区间与真实 SOH 保持了较好的贴合。

对于退化轨迹相对平滑的 Cell3 和 Cell5，各模型均能够较好地跟踪总体变化。对于 Cell7 和 Cell8，各模型均能够跟踪整体容量衰减趋势，但预测偏差的方向有所不同。Cell7 中，各模型的预测曲线整体低于真实 SOH，表现出较为一致的低估偏差；Cell8 中，预测曲线在真实 SOH 两侧波动，未呈现固定的偏差方向。

Table 13 列出了五种模型在 Cell2–Cell8 上的 SOH 估计误差。

Table 13 的结果显示，MS-AgentNet 在 Cell2–Cell6 上的 R^2 、MAE、MAPE 和 RMSE 均为最优。其中，Cell4 的 MAE 和 RMSE 分别为 0.00814 和 0.00873，Cell6 分别为 0.00593 和 0.00842。




Fig. 8. SOH estimation results of different models on the Oxford dataset.

Table 12
Layer configurations of different deep learning models.

MS-AgentNet	CNN-Transformer	Transformer	CNN-LSTM	LSTM
Input	Input	Input	Input	Input
Embedding layer (16)	Embedding layer (16)	Embedding layer (16)	Conv1D + ReLU	Linear layer (16)
SLFA module	Positional encoder	Positional encoder	MaxPooling1D	5× LSTM layer (16)
DSConv-L module	Softmax attention	Softmax attention	3× Conv1D + ReLU	Linear layer
Add & Norm	2× Conv1D + ReLU	Add & Norm	3× LSTM layer (16)	
FFN	MLP	MLP	Linear layer	
Add & Norm	Transformer decoder	Add & Norm		
Linear layer	Linear layer	Transformer decoder		
		Linear layer		

从 Cell2–Cell8 的总体结果来看，MS-AgentNet 取得了 0.98413 的平均 R^2 ，其平均 MAE、MAPE 和 RMSE 分别为 0.00516、0.00605 和 0.00631，均在五种模型中排名第一。与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 相比，其平均 MAE 分别降低了 3.89%、10.26%、5.67% 和 13.97%，平均 MAPE 分别降低了 4.00%、10.07%、5.32% 和 14.01%，平均 RMSE 分别降低了 6.17%、12.44%、6.73% 和 16.81%。MS-AgentNet 在 Cell3–Cell8 上仍能较好地跟踪不同形态的容量衰减过程，体现出较好的跨电池估计能力。

4.4.2 CALCE 和 MIT 数据集上的跨电池泛化分析

在 Oxford 结果的基础上，将比较范围扩展至 CALCE CS2、CALCE CX2 和 MIT/Severson 数据集，五种模型的 SOH 估计结果如图 9 所示。

从整体结果来看，五种模型均能够跟踪不同电池的容量衰减趋势，但在非线性转折和寿命后段的预测表现上存在差异。CX2_38 在长期容量衰减过程中经历了多次阶段性转折，并在寿命后段表现出明显的加速衰减。局部放大结果显示，进入加速衰减阶段后，不同模型的预测偏差逐渐扩大，MS-AgentNet 仍能保持与真实 SOH 的较好贴合。

对于退化轨迹较为连续的 CS2_38 和 b3c29，五种模型均能够跟踪总体容量衰减趋势。MS-AgentNet 在 CS2_38 上的预测误差整体接近零值，在 b3c29 上也能够跟踪后段逐渐加快的容量衰减过程。

Table 14 列出了五种模型在 CS2_37、CS2_38、CX2_37、CX2_38、b3c13 和 b3c29 上的 SOH 估计误差。

具体来看，MS-AgentNet 在 CS2_37 和 CX2_37 上的四项评价指标均为最优；在 b3c13 上，其估计结果与 Transformer 接近。

Table 14 显示，MS-AgentNet 在 CX2_38 上的 R^2 、MAE、MAPE 和 RMSE 分别为 0.9947、0.0106、0.037673 和 0.0193。相较 CNN-Transformer，其 MAPE 降低了 59.75%；相较 Transformer，其 MAE、MAPE 和 RMSE 分别降低了 23.18%、51.80% 和 20.59%，表明该模型在非线性转折和寿命后段加速衰减过程中仍能保持较低的预测误差。

在 CS2_38 上，MS-AgentNet 的 R^2 、MAE、MAPE 和 RMSE 分别为 0.9798、0.0120、0.015984 和 0.0174。在 b3c29 上，该模型取得了 0.9972 的 R^2 ，其 MAE、MAPE 和 RMSE 分别为 0.0018、0.001960 和 0.0022。

综合 CX2_37 和 CX2_38 的结果，MS-AgentNet 的平均 MAPE 较 CNN-Transformer 降低了 52.69%。从上述六节电池的总体结果来看，MS-AgentNet 取得了 0.98956 的平均 R^2 ，其平均 MAE、MAPE 和 RMSE 分别为 0.00707、0.013335 和 0.01188，综合性能排名第一。与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 相比，其平均 MAE 分别降低了 13.50%、26.02%、9.11% 和 22.94%，平均 MAPE 分别降低了 42.19%、60.08%、34.49% 和 58.17%，平均 RMSE 分别降低了 12.04%、26.52%、7.97% 和 23.09%。MS-AgentNet 在 CS2_38、CX2_38 和 b3c29 上仍保持了较低的估计误差，表明模型能够适应同一数据集内不同电池的退化差异。

综合不同退化场景的实验结果，MS-AgentNet 在非线性加速衰减和平滑退化过程中均保持了较低的预测误差。该模型在 LCO 与 LFP 材料体系、常规 CC-CV 与多步快充协议以及不同容量衰减形态下均取得了较低的跨电池估计误差，体现出较好的模型适用性、预测鲁棒性和跨电池泛化能力。




Fig. 9. SOH estimation results of different models on the CALCE and MIT/Severson datasets.

Table 13

SOH estimation errors of different models on the Oxford dataset.

Cell	Method	R^2	MAE	MAPE	RMSE
Cell2*	MS-AgentNet	0.98928	0.00429	0.00524	0.00694
	CNN-Transformer	0.98532	0.00497	0.00609	0.00812
	CNN-LSTM	0.98341	0.00521	0.00635	0.00863
	Transformer	0.98571	0.00512	0.00622	0.00800
	LSTM	0.97880	0.00590	0.00725	0.00977
Cell3	MS-AgentNet	0.99668	0.00280	0.00333	0.00351
	CNN-Transformer	0.99523	0.00335	0.00396	0.00420
	CNN-LSTM	0.99501	0.00343	0.00404	0.00429
	Transformer	0.99472	0.00362	0.00423	0.00440
	LSTM	0.99529	0.00327	0.00390	0.00418
Cell4	MS-AgentNet	0.97217	0.00814	0.00960	0.00873
	CNN-Transformer	0.96942	0.00819	0.00969	0.00914
	CNN-LSTM	0.96712	0.00871	0.01026	0.00949
	Transformer	0.96931	0.00820	0.00966	0.00916
	LSTM	0.96267	0.00937	0.01103	0.01011
Cell5	MS-AgentNet	0.99291	0.00302	0.00343	0.00353
	CNN-Transformer	0.99002	0.00344	0.00389	0.00417
	CNN-LSTM	0.98912	0.00351	0.00397	0.00434
	Transformer	0.98727	0.00391	0.00437	0.00468
	LSTM	0.99036	0.00355	0.00400	0.00412
Cell6	MS-AgentNet	0.96968	0.00593	0.00705	0.00842
	CNN-Transformer	0.96442	0.00646	0.00764	0.00911
	CNN-LSTM	0.96226	0.00650	0.00771	0.00939
	Transformer	0.96402	0.00696	0.00815	0.00917
	LSTM	0.95868	0.00626	0.00747	0.00983
Cell7	MS-AgentNet	0.97412	0.00802	0.00923	0.00829
	CNN-Transformer	0.97781	0.00731	0.00841	0.00766
	CNN-LSTM	0.97081	0.00841	0.00964	0.00880
	Transformer	0.97750	0.00719	0.00830	0.00769
	LSTM	0.96768	0.00886	0.01016	0.00926
Cell8	MS-AgentNet	0.99407	0.00389	0.00444	0.00472
	CNN-Transformer	0.99434	0.00384	0.00442	0.00462
	CNN-LSTM	0.99207	0.00445	0.00508	0.00548
	Transformer	0.99528	0.00326	0.00377	0.00422
	LSTM	0.99115	0.00474	0.00539	0.00579
Average	MS-AgentNet	0.98413	0.00516	0.00605	0.00631
	CNN-Transformer	0.98237	0.00537	0.00630	0.00672
	CNN-LSTM	0.97997	0.00575	0.00672	0.00720
	Transformer	0.98197	0.00547	0.00639	0.00676
	LSTM	0.97780	0.00599	0.00703	0.00758

Note: Cell2* denotes the cell used for model configuration. Average values are equally weighted over all cells listed.

4.5 跨数据集迁移实验

当训练电池与评价电池来自不同数据集时，化学体系、运行协议和退化分布差异可能引起域偏移 [52,59]。为评价 MS-AgentNet 在不同电池数据域之间的迁移能力，本文设置源域直接测试和少样本适应两类实验。

源域直接测试 (source-only) 仅使用源域参考电池训练，冻结全部模型参数后直接在目标域评价电池上测试。少样本适应在此基础上冻结特征提取模块，并使用目标域参考电池前 30% 的循环数据微调读出层 [52,58]。

CALCE CS2、CALCE CX2 和 Oxford 分别作为独立数据域，其参考电池为 CS2_36、CX2_36 和 Oxford Cell11，用于源域训练或目标域少样本适应；CS2_38、CX2_38 和 Oxford Cell3 作为目标域评价电池，仅用于测

Table 14

SOH estimation errors of different models on the CALCE and MIT/Severson datasets.

Dataset	Method	R^2	MAE	MAPE	RMSE
CALCE CS2 (CS2_37*)	MS-AgentNet	0.9925	0.00733	0.009443	0.01172
	CNN-Transformer	0.9923	0.00742	0.009532	0.01182
	CNN-LSTM	0.9917	0.00800	0.010232	0.01229
	Transformer	0.9923	0.00737	0.009449	0.01182
	LSTM	0.9915	0.00795	0.010106	0.01246
CALCE CS2 (CS2_38)	MS-AgentNet	0.9798	0.01201	0.015984	0.01741
	CNN-Transformer	0.9779	0.01261	0.016928	0.01823
	CNN-LSTM	0.9778	0.01249	0.016680	0.01826
	Transformer	0.9787	0.01216	0.016434	0.01789
	LSTM	0.9776	0.01280	0.017085	0.01836
CALCE CX2 (CX2_37*)	MS-AgentNet	0.9765	0.00916	0.013328	0.01845
	CNN-Transformer	0.9753	0.00981	0.014209	0.01891
	CNN-LSTM	0.9759	0.00974	0.014147	0.01868
	Transformer	0.9748	0.01004	0.014510	0.01909
	LSTM	0.9752	0.00987	0.014322	0.01895
CALCE CX2 (CX2_38)	MS-AgentNet	0.9947	0.01059	0.037673	0.01928
	CNN-Transformer	0.9895	0.01536	0.093595	0.02693
	CNN-LSTM	0.9785	0.02072	0.152435	0.03866
	Transformer	0.9916	0.01378	0.078160	0.02428
	LSTM	0.9804	0.02008	0.145055	0.03704
MIT/Severson (b3c13*)	MS-AgentNet	0.9967	0.00148	0.001622	0.00229
	CNN-Transformer	0.9954	0.00167	0.001832	0.00262
	CNN-LSTM	0.9855	0.00284	0.003121	0.00476
	Transformer	0.9968	0.00146	0.001599	0.00220
	LSTM	0.9940	0.00184	0.002020	0.00309
MIT/Severson (b3c29)	MS-AgentNet	0.9972	0.00183	0.001960	0.00215
	CNN-Transformer	0.9960	0.00214	0.002302	0.00254
	CNN-LSTM	0.9879	0.00353	0.003808	0.00438
	Transformer	0.9971	0.00184	0.001976	0.00219
	LSTM	0.9952	0.00249	0.002667	0.00280
Average	MS-AgentNet	0.9896	0.00707	0.013335	0.01188
	CNN-Transformer	0.9877	0.00817	0.023066	0.01351
	CNN-LSTM	0.9829	0.00955	0.033404	0.01617
	Transformer	0.9885	0.00778	0.020355	0.01291
	LSTM	0.9856	0.00917	0.031876	0.01545

Note: CS2_37*, CX2_37*, and b3c13* denote the cells used for model configuration. Average values are equally weighted over all cells listed.

试。CALCE CS2 与 CALCE CX2 均属于 LCO 化学体系，Oxford 采用 NCO-LCO 混合化学体系，迁移方向同时覆盖同化学体系和跨化学体系任务。

为使源域模型能够直接接收目标域输入，各迁移方向均采用 $CCCT[3.8, 4.0]$ 和 $Q_{dch}[3.8, 3.4]/C_{rated}$ 两项输入健康指标。迁移实验结果为三次独立运行的平均值。

4.5.1 不同源域—目标域组合下的迁移结果

源域直接测试结果见 Table 15。

在源域直接测试条件下，CS2→CX2 和 CX2→CS2 的 R^2 分别为 0.8421 和 0.7847，MAE 分别为 0.0697

Table 15

Direct cross-dataset transfer results.

Source	Target	R^2	MAE	MAPE	RMSE
CS2	CX2	0.8421	0.0697	0.3974	0.1051
CS2	Oxford	-60.5701	0.4761	0.5573	0.4778
CX2	CS2	0.7847	0.0388	0.0557	0.0568
CX2	Oxford	-108.6169	0.6346	0.7423	0.6375
Oxford	CS2	-1.5309	0.1530	0.2196	0.1950
Oxford	CX2	-1.4786	0.3528	1.5040	0.4164

和 0.0388，表明模型在两个 CALCE 数据域之间保留了较好的退化趋势表征。涉及 Oxford 的四个迁移方向中，MAE 为 0.1530~0.6346， R^2 均低于 0，直接迁移结果表现出明显的的数据域组合与方向差异。

为考察目标域观测能否缩小上述跨域误差，进一步使用目标域参考电池前 30% 的循环数据适配读出层，结果见 Table 16。

Table 16

Transfer results after 30% target-domain adaptation.

Source	Target	R^2	MAE	MAPE	RMSE
CS2	CX2	0.9566	0.0377	0.1830	0.0533
CS2	Oxford	-0.2679	0.0590	0.0722	0.0685
CX2	CS2	0.8806	0.0303	0.0406	0.0422
CX2	Oxford	-1.6085	0.0835	0.1024	0.0982
Oxford	CS2	-1.1030	0.1327	0.1935	0.1777
Oxford	CX2	-0.4809	0.2427	1.2100	0.3218

适配后，六个迁移方向的 MAE、MAPE 和 RMSE 均有所降低。在两个 CALCE 数据域之间，CS2→CX2 和 CX2→CS2 的 MAE 分别由 0.0697 和 0.0388 降低至 0.0377 和 0.0303。涉及 Oxford 的四个方向也获得不同程度的改善，其中两个 CALCE→Oxford 方向的 MAE 分别由 0.4761 和 0.6346 降低至 0.0590 和 0.0835；以 Oxford 为源域迁移至两个 CALCE 数据域时，MAE 分别降低至 0.1327 和 0.2427。

R^2 结果进一步显示，四个涉及 Oxford 的迁移方向在 30% 适配条件下均低于 0，表明当前目标域观测尚不足以充分表征其退化变化。后续将 Oxford 固定为目标域，进一步比较不同适配比例下的迁移性能。

4.5.2 目标域适配数据比例对迁移性能的影响

分别以 CS2_36 和 CX2_36 作为源域，使用 Oxford Cell1 的前置循环数据进行读出层适配，并将适配比例依次设置为 10%、30%、50% 和 70%，结果见 Table 17。

Table 17

Transfer results with different amounts of target-domain data.

Transfer	Target data (%)	R^2	MAE	MAPE	RMSE
CS2 → Oxford	10	-1.3934	0.0831	0.1015	0.0942
CS2 → Oxford	30	-0.2679	0.0590	0.0722	0.0685
CS2 → Oxford	50	0.5094	0.0366	0.0445	0.0426
CS2 → Oxford	70	0.7650	0.0252	0.0305	0.0293
CX2 → Oxford	10	-3.2217	0.1095	0.1339	0.1251
CX2 → Oxford	30	-1.6085	0.0835	0.1024	0.0982
CX2 → Oxford	50	-0.3836	0.0614	0.0747	0.0716
CX2 → Oxford	70	-0.1268	0.0559	0.0677	0.0646

随着适配比例由 10% 增至 70%，两种源域设置下的 MAE、MAPE 和 RMSE 均持续下降。以 CS2 为源域时，MAE 由 0.0831 降至 0.0252， R^2 由 -1.3934 提高至 0.7650，并在 50% 适配比例下由负转正；以 CX2 为源域时，MAE 由 0.1095 降至 0.0559， R^2 由 -3.2217 提高至 70% 适配比例下的 -0.1268。四种适配比例下，CS2 源域的 R^2 均高于 CX2 源域的对应该结果。

进一步比较相邻适配比例，CS2 和 CX2 源域从 30% 增至 50% 时，MAE 分别降低 0.0224 和 0.0221；从 50% 增至 70% 时，降幅分别缩小至 0.0114 和 0.0055。目标域数据增加持续降低了估计误差，MAE 的改善幅度在较高适配比例下逐渐趋缓。两种源域设置表现出不同的 R^2 水平和转正情况，表明跨域适配结果同时受到目标域数据比例和源域选择的影响。

4.6 模块消融与模型复杂度分析

为进一步验证 MS-AgentNet 的有效性和效率，在主对比实验基础上开展消融研究与复杂度分析。消融研究通过移除或组合关键模块，考察各模块对预测性能的作用；复杂度分析则从计算量、参数量和存储占用等方面评估模型开销。

4.6.1 模块消融分析

高效注意力通过压缩信息交互降低标准注意力的计算开销 [39,40,43,44]，但这一过程可能削弱局部细粒度退化信息的表达 [31]；直接叠加标准卷积虽然能够增强局部特征建模，却会增加参数量和计算负担 [31,71]。为兼顾局部信息保留与计算效率，MS-AgentNet 结合多尺度 DSConv 与 RAA，分别完成局部特征提取和跨位置信息交互。为考察两类模块的单独作用及组合效果，消融实验设置 M1–M4 四种变体。其中，M1 仅保留基础骨干网络，M2 在 M1 基础上加入多尺度 DSConv，M3 在 M1 基础上加入 RAA，M4 则同时集成多尺度 DSConv 与 RAA。

Table 18
Ablation results on different datasets.

Dataset	Model	Backbone	Multi-scale DSConv	RAA	MAE	RMSE	MAPE	Average	Reduction
CS2	M1	✓	—	—	0.0123	0.0183	0.0166	0.0157	3.74%
	M2	✓	✓	—	0.0130	0.0184	0.0171	0.0162	6.49%
	M3	✓	—	✓	0.0119	0.0178	0.0161	0.0152	0.62%
	M4	✓	✓	✓	0.0120	0.0174	0.0160	0.0151	—
	(Proposed)								
CX2	M1	✓	—	—	0.0170	0.0294	0.1035	0.0500	54.94%
	M2	✓	✓	—	0.0164	0.0284	0.1033	0.0494	54.40%
	M3	✓	—	✓	0.0156	0.0270	0.0899	0.0442	49.05%
	M4	✓	✓	✓	0.0106	0.0193	0.0377	0.0225	—
	(Proposed)								
MIT	M1	✓	—	—	0.0019	0.0022	0.0020	0.0020	2.43%
	M2	✓	✓	—	0.0021	0.0025	0.0023	0.0023	14.16%
	M3	✓	—	✓	0.0024	0.0028	0.0026	0.0026	23.91%
	M4	✓	✓	✓	0.0018	0.0022	0.0020	0.0020	—
	(Proposed)								
Oxford	M1	✓	—	—	0.0063	0.0076	0.0073	0.0071	16.52%
	M2	✓	✓	—	0.0058	0.0070	0.0067	0.0065	9.50%
	M3	✓	—	✓	0.0054	0.0063	0.0062	0.0060	1.52%
	M4	✓	✓	✓	0.0053	0.0062	0.0062	0.0059	—
	(Proposed)								

如 Table 18 所示，与 M1 相比，加入多尺度 DSConv 后，M2 在 CX2 和 Oxford 数据集上的平均误差分别由 0.0500 和 0.0071 降低至 0.0494 和 0.0065，但在 CS2 和 MIT 数据集上未取得更低的平均误差。这表明，单独加入多尺度 DSConv 的效果因数据集而异。

加入 RAA 后，M3 在 CS2、CX2 和 Oxford 数据集上的平均误差分别由 0.0157、0.0500 和 0.0071 降低至 0.0152、0.0442 和 0.0060，但在 MIT 数据集上未优于 M1。与多尺度 DSConv 相似，单独加入 RAA 并未在所有数据集上取得一致改善。

当多尺度 DSConv 与 RAA 同时集成后，完整模型 M4 在四个数据集上的综合平均误差均达到最优水平。以 CX2 数据集为例，平均误差由 M1 的 0.0500 降低至 0.0225，相对降低 54.94%；在 Oxford 数据集上，平均误差由 0.0071 降低至 0.0059，相对降低 16.52%。在 CS2 和 MIT 数据集上，M4 相对 M1 的平均误差也分别降低 3.74% 和 2.43%。在 CS2 数据集上，M3 的 MAE 略低于 M4，M4 在 RMSE、MAPE 和综合平均误差上取得

更优结果。

总体来看，单独加入多尺度 DSConv 或 RAA 的效果具有一定的数据集差异，两类模块联合使用后取得了更优且更一致的综合结果，体现了二者在不同退化场景下的互补作用。

为进一步考察多尺度 DSConv 中两个卷积尺度的作用，在保持 RAA 启用的条件下设置 S0、S5、S31 和 SFull 四种尺度变体。其中，S0 仅保留 RAA，与Table 18中的 M3 对应；S5 在 S0 基础上加入核长度为 5 的 DSConv-S，S31 加入核长度为 31 的 DSConv-L；SFull 同时使用 DSConv-S、DSConv-L 与 RAA，与 M4 对应。各尺度变体采用相同的实验设置，结果如Table 19所示。

Table 19
Effects of different convolution scales.

Dataset	Model	$K = 5$	$K = 31$	RAA	MAE	RMSE	MAPE	Average
CS2	S0	—	—	✓	0.0119	0.0178	0.0161	0.0152
	S5	✓	—	✓	0.0128	0.0184	0.0170	0.0161
	S31	—	✓	✓	0.0124	0.0179	0.0166	0.0156
	SFull	✓	✓	✓	0.0120	0.0174	0.0160	0.0151
CX2	S0	—	—	✓	0.0156	0.0270	0.0899	0.0442
	S5	✓	—	✓	0.0162	0.0285	0.1036	0.0494
	S31	—	✓	✓	0.0135	0.0232	0.0677	0.0348
	SFull	✓	✓	✓	0.0106	0.0193	0.0377	0.0225
MIT	S0	—	—	✓	0.0024	0.0028	0.0026	0.0026
	S5	✓	—	✓	0.0023	0.0027	0.0025	0.0025
	S31	—	✓	✓	0.0025	0.0028	0.0026	0.0026
	SFull	✓	✓	✓	0.0018	0.0022	0.0020	0.0020
Oxford	S0	—	—	✓	0.0054	0.0063	0.0062	0.0060
	S5	✓	—	✓	0.0056	0.0066	0.0065	0.0062
	S31	—	✓	✓	0.0055	0.0065	0.0064	0.0061
	SFull	✓	✓	✓	0.0053	0.0062	0.0062	0.0059

如Table 19所示，不同卷积尺度在各数据集上的作用有所差异。在 CX2 数据集上，S31 的平均误差由 S0 的 0.0442 降低至 0.0348，而 S5 未优于 S0；在 MIT 数据集上，S5 的平均误差略低于 S0 和 S31。在 CS2 和 Oxford 数据集上，两个单尺度变体的平均误差均未低于 S0。

当两个卷积尺度与 RAA 同时使用时，SFull 在四个数据集上均取得最低综合平均误差。整体结果表明，在 RAA 启用的条件下，单一卷积尺度的效果随数据集而变化，双尺度结构取得了更优的综合结果。

4.6.2 模型复杂度分析

预测精度用于衡量 SOH 估计结果的可靠性，计算与存储开销则反映模型运行所需的资源条件 [77]。本文选取 MS-AgentNet、CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 五类代表性模型，从理论计算量、实际训练耗时、可训练参数量和权重存储占用四个方面评价 MS-AgentNet 的轻量化特性。其中，FLOPs 反映单次前向传播的计算需求，训练时间表表征统一实验环境下的训练效率，参数量与存储占用用于衡量模型规模及其存储负担。

FLOPs 通过 THOP 库的 `profile` 函数统计，训练时间采用 Python 的 `time` 模块记录，可训练参数量通过 `torchsummary` 库的 `summary` 函数计算，模型权重文件大小通过 `os.path.getsize` 函数获取。所有指标均在相同实验环境下测量。

为在相同输入数据和训练条件下比较不同模型结构的复杂度，本次统计统一设置训练轮次为 1000、学习率为 0.01、批次大小为 128、丢弃率为 0.1。基于 Transformer 的模型统一设置嵌入维度为 16、前馈维度为 16、注意力头数为 4，并采用单层编码器结构；基于 LSTM 的模型采用四层网络结构和隐藏维度 16。五类模型均使用 CS2 训练电池 CS2_36 中的 HI1 (3.80–4.00 V CCCT) 与 HI2 (IC 峰值)，输入序列长度为 5，单样本输入形状统一为 (1, 5, 2)。

在结构设置上，CNN-Transformer 的卷积模块位于多头自注意力模块之后，由两个一维卷积层和一个最大池化层组成，对应的核大小依次为 3、2 和 3，步长依次为 1、2 和 1，并采用 ReLU 激活函数 [31]。MS-AgentNet 采用多尺度深度可分离卷积。五类模型的复杂度统计结果如Table 20所示。

Table 20

Comprehensive performance of models under the same configuration.

Models	Training hyperparameters			Model hyperparameters			Performance indicators			
	e	lr	b	d_e	d_d	n	FLOPs (M)	Training time (s)	Parameters	Storage (KB)
MS-AgentNet	1000	0.01	128	16	16	4	0.045760	122.979	4643	26.18
Transformer	1000	0.01	128	16	16	4	0.049760	104.274	4673	27.84
CNN-Transformer	1000	0.01	128	16	16	4	0.053024	123.487	6241	34.94
CNN-LSTM	1000	0.01	128	—	16	4	0.067520	70.021	15912	67.59
LSTM	1000	0.01	128	—	16	4	0.092512	64.327	8769	39.17

如Table 20所示, MS-AgentNet 在 FLOPs、参数量和存储占用三个指标上均取得最低值, 其 FLOPs 为 0.045760 M, 参数量为 4,643, 权重文件存储占用为 26.18 KB。训练时间方面, LSTM、CNN-LSTM、Transformer、MS-AgentNet 和 CNN-Transformer 的实测训练时间分别为 64.327 s、70.021 s、104.274 s、122.979 s 和 123.487 s。尽管 LSTM、CNN-LSTM 和 Transformer 的训练时间均低于 MS-AgentNet, 但 MS-AgentNet 在 FLOPs、参数量和存储占用方面均取得更低值。与 LSTM 相比, 三项指标分别降低 50.5%、47.1% 和 33.2%; 与 CNN-LSTM 相比, 分别降低 32.2%、70.8% 和 61.3%; 与 Transformer 相比, 分别降低 8.0%、0.6% 和 6.0%。CNN-Transformer 的训练时间与 MS-AgentNet 基本相当; 相比该模型, MS-AgentNet 的 FLOPs、参数量和存储占用分别降低 13.7%、25.6% 和 25.1%。实际训练耗时不仅取决于理论计算量, 还会受到算子实现和硬件执行效率的影响。

为考察 MS-AgentNet 的存储优势是否依赖单一模型宽度, 进一步将 MS-AgentNet、CNN-Transformer、Transformer、CNN-LSTM 和 LSTM 的表示维度或隐藏维度分别设置为 16、32、64 和 128, 并保持Table 20中的其余模型设置不变。




Fig. 10. Storage sizes of five models at different model widths: (a) storage size at each width; (b) overall distribution across the tested widths.

如Fig. 10(a)所示, 五种模型的存储开销均随表示维度或隐藏维度增加而上升, MS-AgentNet 在四种测试维度下均保持最低的存储占用。当维度增加至 128 时, CNN-LSTM 和 LSTM 的存储大小分别增至 1900.34 KB 和 2070.98 KB, 而 MS-AgentNet 仅为 713.12 KB; 与该维度下存储开销最接近的 Transformer 相比, MS-AgentNet 仍降低了 32.2%。上述结果表明, 在所测试的模型宽度范围内, MS-AgentNet 始终保持相对紧凑的模型规模。

Fig. 10(b) 汇总了五种模型在四种测试宽度下的存储范围。MS-AgentNet 的存储范围整体低于其他四种模型, CNN-LSTM 和 LSTM 的存储占用则随隐藏维度增加表现出更明显的增长。该结果进一步说明, MS-AgentNet 的存储优势并不局限于单一表示维度。

上述结果表明, MS-AgentNet 在 SOH 估计性能与资源开销之间取得了良好平衡, 具备应用于资源受限电池管理系统的潜力。

5. 结论

本文提出了一种面向资源受限电池管理系统的轻量化锂离子电池 SOH 估计框架, 以缓解健康指标跨电池稳定性不足以及预测精度与计算效率难以兼顾的问题。研究从系统性健康指标构建和轻量化网络设计两个方面展开。所提出的组级健康指标选择算法基于特征开发电池集合的相关性结果, 利用 MS-CCCT 对恒流充电电压窗口进行多尺度自适应标定, 并通过 PCC/SCC 双阈值准入与冗余剔除确定模型输入。在保持特征定义与参数不变的条件下, 最终入选指标在同一数据集的其他电池上仍与 SOH 保持较强的线性和单调关联。在序列建模方面, MS-AgentNet 将 ReLU² 智能体注意力与小核和大核深度可分离卷积相结合, 以协同表征局部退化变化、跨位置全局信息和长尺度退化趋势。在智能体数量固定时, RAA 利用少量可学习静态智能体完成信息聚合与广播, 将注意力相关性交互的理论复杂度由 $O(N^2d)$ 降低至 $O(Nn_{ad})$ 。

在 Oxford、CALCE CS2、CALCE CX2 和 MIT/Severson 四个公开电池数据集上的实验结果表明, 与 CNN-Transformer、CNN-LSTM、Transformer 和 LSTM 四种基线模型相比, MS-AgentNet 总体上取得了更优的综合表现。具体而言, 在 CALCE CX2 数据集的两节电池平均结果中, MS-AgentNet 的 MAPE 相比 CNN-Transformer 降低了 52.69%。此外, MS-AgentNet 具有较低的参数数量和存储开销, 体现了其轻量化优势。消融实验与卷积尺度补充实验显示, 多尺度深度可分离卷积与 RAA 的互补融合能够提升模型在不同退化场景下的综合表现。总体来看, 所提框架在 SOH 估计精度与资源开销之间取得了良好平衡; 模型在同一数据集的其他电池上仍保持了较好的估计性能, 体现出一定的域内跨电池泛化能力, 并具备应用于资源受限电池管理系统的潜力。

尽管取得了上述结果, 所提框架仍依赖可辨识的充放电数据片段, 且其跨数据集适应能力会受到数据域差异、源域选择和目标域数据量的影响。未来将重点研究面向不完整充电和动态运行片段的健康指标构建方法及轻量化域适应策略, 并在更多电池体系、实际车辆运行数据和嵌入式硬件平台上开展验证, 以进一步提升该框架的工程适用性与部署可靠性。

参考文献

- [1] Scrosati B, Garche J. Lithium batteries: Status, prospects and future. *Journal of Power Sources* 2010;195(9):2419–2430. <https://doi.org/10.1016/j.jpowsour.2009.11.048>.
- [2] Kim T, Song W, Son D-Y, Ono LK, Qi Y. Lithium-ion batteries: Outlook on present, future, and hybridized technologies. *Journal of Materials Chemistry A* 2019;7(7):2942–2964. <https://doi.org/10.1039/C8TA10513H>.
- [3] Krause FC, Ruiz JP, Jones SC, Brandon EJ, Darcy EC, Iannello CJ, Bugga RV. Performance of commercial Li-ion cells for future NASA missions and aerospace applications. *Journal of The Electrochemical Society* 2021;168(4):040504. <https://doi.org/10.1149/1945-7111/abf05f>.
- [4] Xiong R, Kim J, Shen W, et al. Key technologies for electric vehicles. *Green Energy and Intelligent Transportation* 2022;1(2):100041. <https://doi.org/10.1016/j.geits.2022.100041>.
- [5] Barré A, Deguilhem B, Grolleau S, Gérard M, Suard F, Riu D. A review on lithium-ion battery ageing mechanisms and estimations for automotive applications. *Journal of Power Sources* 2013;241:680–689. <https://doi.org/10.1016/j.jpowsour.2013.05.040>.
- [6] Ma S, Jiang M, Tao P, Song C, Wu J, Wang J, Deng T, Shang W. Temperature effect and thermal impact in lithium-ion batteries: A review. *Progress in Natural Science: Materials International* 2018;28(6):653–666. <https://doi.org/10.1016/j.pnsc.2018.11.002>.
- [7] Wang C-J, Zhu Y-L, Gao F, Bu X-Y, Chen H-S, Quan T, Xu Y-B, Jiao Q-J. Internal short circuit and thermal runaway evolution mechanism of fresh and retired Li-ion batteries with LiFePO₄ cathode during overcharge. *Applied Energy* 2022;328:120224. <https://doi.org/10.1016/j.apenergy.2022.120224>.
- [8] Feng L, Jiang L, Liu J, Wang Z, Wei Z, Wang Q. Dynamic overcharge investigations of lithium ion batteries with different state of health. *Journal of Power Sources* 2021;507:230262. <https://doi.org/10.1016/j.jpowsour.2021.230262>.
- [9] Xia Y, Chen G, Zhou Q, Shi X, Shi F. Failure behaviours of 100% SOC lithium-ion battery modules under different impact loading conditions. *Engineering Failure Analysis* 2017;82:149–160. <https://doi.org/10.1016/j.engfailanal.2017.09.003>.
- [10] Che Y, Hu X, Lin X, Guo J, Teodorescu R. Health prognostics for lithium-ion batteries: Mechanisms, methods, and prospects. *Energy & Environmental Science* 2023;16:338–371. <https://doi.org/10.1039/D2EE03019E>.

- [11] Ge M-F, Liu Y, Jiang X, Liu J. A review on state of health estimations and remaining useful life prognostics of lithium-ion batteries. *Measurement* 2021;174:109057. <https://doi.org/10.1016/j.measurement.2021.109057>.
- [12] Tian H, Qin P, Li K, Zhao Z. A review of the state of health for lithium-ion batteries: Research status and suggestions. *Journal of Cleaner Production* 2020;261:120813. <https://doi.org/10.1016/j.jclepro.2020.120813>.
- [13] Lu J, Xiong R, Tian J, et al. Deep learning to estimate lithium-ion battery state of health without additional degradation experiments. *Nature Communications* 2023;14:2760. <https://doi.org/10.1038/s41467-023-38458-w>.
- [14] Luo K, Chen X, Zheng H, Shi Z. A review of deep learning approach to predicting the state of health and state of charge of lithium-ion batteries. *Journal of Energy Chemistry* 2022;74:159–173. <https://doi.org/10.1016/j.jechem.2022.06.049>.
- [15] Song K, Hu D, Tong Y, Yue X. Remaining life prediction of lithium-ion batteries based on health management: A review. *Journal of Energy Storage* 2023;57:106193. <https://doi.org/10.1016/j.est.2022.106193>.
- [16] Khaleghi S, Hosen M, Karimi D, et al. Developing an online data-driven approach for prognostics and health management of lithium-ion batteries. *Applied Energy* 2022;308:118348. <https://doi.org/10.1016/j.apenergy.2021.118348>.
- [17] Hu X, Xu L, Lin X, Pecht M. Battery lifetime prognostics. *Joule* 2020;4:310–346. <https://doi.org/10.1016/j.joule.2019.11.018>.
- [18] He W, Williard N, Osterman M, Pecht M. Prognostics of lithium-ion batteries based on Dempster–Shafer theory and the Bayesian Monte Carlo method. *Journal of Power Sources* 2011;196(23):10314–10321. <https://doi.org/10.1016/j.jpowsour.2011.08.040>.
- [19] Wang Y, Tian J, Sun Z, Wang L, Xu R, Li M, Chen Z. A comprehensive review of battery modeling and state estimation approaches for advanced battery management systems. *Renewable and Sustainable Energy Reviews* 2020;131:110015. <https://doi.org/10.1016/j.rser.2020.110015>.
- [20] Deng Z, Yang L, Deng H, Cai Y, Li D. Polynomial approximation pseudo-two-dimensional battery model for online application in embedded battery management system. *Energy* 2018;142:838–850. <https://doi.org/10.1016/j.energy.2017.10.097>.
- [21] Li J, Adewuyi K, Lotfi N, Landers RG, Park J. A single particle model with chemical/mechanical degradation physics for lithium ion battery state of health (SOH) estimation. *Applied Energy* 2018;212:1178–1190. <https://doi.org/10.1016/j.apenergy.2018.01.011>.
- [22] Wang D, Zhang Q, Huang H, Yang B, Dong H, Zhang J. An electrochemical–thermal model of lithium-ion battery and state of health estimation. *Journal of Energy Storage* 2022;47:103528. <https://doi.org/10.1016/j.est.2021.103528>.
- [23] Rechkemmer SK, Zang X, Zhang W, Sawodny O. Empirical Li-ion aging model derived from single particle model. *Journal of Energy Storage* 2019;21:773–786. <https://doi.org/10.1016/j.est.2019.01.005>.
- [24] Chen L, Lü Z, Lin W, Li J, Pan H. A new state-of-health estimation method for lithium-ion batteries through the intrinsic relationship between ohmic internal resistance and capacity. *Measurement* 2018;116:586–595. <https://doi.org/10.1016/j.measurement.2017.11.016>.
- [25] Roman D, Saxena S, Robu V, Flynn D, Pecht M. Machine learning pipeline for battery state of health estimation. *arXiv* 2021. <https://doi.org/10.48550/arXiv.2102.00837>.
- [26] Fei Z, Yang F, Tsui K-L, Li L, Zhang Z. Early prediction of battery lifetime via a machine learning based framework. *Energy* 2021;225:120205. <https://doi.org/10.1016/j.energy.2021.120205>.
- [27] Li Y, Zou C, Berecibar M, Nanini-Maury E, Chan JC-W, van den Bossche P, Van Mierlo J, Omar N. Random forest regression for online capacity estimation of lithium-ion batteries. *Applied Energy* 2018;232:197–210. <https://doi.org/10.1016/j.apenergy.2018.09.182>.
- [28] Richardson RR, Birkel CR, Osborne MA, Howey DA. Gaussian process regression for in situ capacity estimation of lithium-ion batteries. *IEEE Transactions on Industrial Informatics* 2018;15:127–138. <https://doi.org/10.1109/TII.2018.2794997>.
- [29] Qian C, Xu B, Chang L, Sun B, Feng Q, Yang D, Ren Y, Wang Z. Convolutional neural network based capacity estimation using random segments of the charging curves for lithium-ion batteries. *Energy* 2021;227:120333. <https://doi.org/10.1016/j.energy.2021.120333>.
- [30] Lee G, Kwon D, Lee C. A convolutional neural network model for SOH estimation of Li-ion batteries with physical interpretability. *Mechanical Systems and Signal Processing* 2023;188:110004. <https://doi.org/10.1016/j.ymssp.2022.110004>.
- [31] Li X, Zhao M, Zhong S, Li J, Fu S, Yan Z. BMSFormer: An efficient deep learning model for online state-of-health estimation of lithium-ion batteries under high-frequency early SOC data with strong correlated single health indicator. *Energy* 2024;313:134030. <https://doi.org/10.1016/j.energy.2024.134030>.

- [32] Jia C, Tian Y, Shi Y, Jia J, Wen J, Zeng J. State of health prediction of lithium-ion batteries based on bidirectional gated recurrent unit and transformer. *Energy* 2023;285:129401. <https://doi.org/10.1016/j.energy.2023.129401>.
- [33] Zheng Y, Hu J, Chen J, Deng H, Hu W. State of health estimation for lithium battery random charging process based on CNN-GRU method. *Energy Reports* 2023;9:1–10. <https://doi.org/10.1016/j.egy.2022.12.093>.
- [34] Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, Kaiser L, Polosukhin I. Attention Is All You Need. In: *Advances in Neural Information Processing Systems*, vol. 30; 2017. <https://doi.org/10.48550/arXiv.1706.03762>.
- [35] Gu X, See KW, Li P, Shan K, Wang Y, Zhao L, Lim KC, Zhang N. A novel state-of-health estimation for the lithium-ion battery using a convolutional neural network and transformer model. *Energy* 2023;262:125501. <https://doi.org/10.1016/j.energy.2022.125501>.
- [36] Bai T, Wang H. Convolutional transformer-based multiview information perception framework for lithium-ion battery state-of-health estimation. *IEEE Transactions on Instrumentation and Measurement* 2023;72:1–12. <https://doi.org/10.1109/TIM.2023.3300451>.
- [37] Chen L, Xie S, Lopes AM, Bao X. A vision transformer-based deep neural network for state of health estimation of lithium-ion batteries. *International Journal of Electrical Power & Energy Systems* 2023;152:109233. <https://doi.org/10.1016/j.ijepes.2023.109233>.
- [38] Park SH, Kim SH. Physics-Informed Transformer Using Degradation-Sensitive Indicators for Long-Term State-of-Health Estimation of Lithium-Ion Batteries. *Batteries* 2026;12(2):48.
- [39] Tay Y, Dehghani M, Bahri D, Metzler D. Efficient Transformers: A survey. *ACM Computing Surveys* 2022;55(6). <https://doi.org/10.1145/3530811>.
- [40] Katharopoulos A, Vyas A, Pappas N, Fleuret F. Transformers are RNNs: Fast autoregressive Transformers with linear attention. In: *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119; 2020. p. 5156–5165. <https://doi.org/10.48550/arXiv.2006.16236>.
- [41] Xu H, Wu L, Xiong S, Li W, Garg A, Gao L. An improved CNN-LSTM model-based state-of-health estimation approach for lithium-ion batteries. *Energy* 2023;276:127585. <https://doi.org/10.1016/j.energy.2023.127585>.
- [42] Tian Y, Wen J, Yang Y, Shi Y, Zeng J. State-of-Health Prediction of Lithium-Ion Batteries Based on CNN-BiLSTM-AM. *Batteries* 2022;8(10):155. <https://doi.org/10.3390/batteries8100155>.
- [43] Liu S, Yu H, Liao C, Li J, Lin W, Liu AX, Dustdar S. Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting. In: *Proceedings of the International Conference on Learning Representations*; 2022.
- [44] Zheng L, Wang C, Kong L. Linear complexity randomized self-attention mechanism. In: *Proceedings of the 39th International Conference on Machine Learning*, PMLR 162; 2022. p. 27011–27041.
- [45] Wang H, Li H, He Z, Chen X, Liu H, Chen C. A linear-complexity deep learning framework for efficient battery state of health estimation in resource-constrained systems. *Engineering Applications of Artificial Intelligence* 2026;181:115420. <https://doi.org/10.1016/j.engappai.2026.115420>.
- [46] Han D, Ye T, Han Y, Xia Z, Pan S, Wan P, Song S, Huang G. Agent Attention: On the integration of Softmax and linear attention. In: *Computer Vision—ECCV 2024, Lecture Notes in Computer Science*, vol. 15108, Springer, Cham; 2025. p. 124–140. https://doi.org/10.1007/978-3-031-72973-7_8.
- [47] Lin C, Xu J, Hou J, et al. A fast data-driven battery capacity estimation method under non-constant current charging and variable temperature. *Energy Storage Materials* 2023;63:102967. <https://doi.org/10.1016/j.ensm.2023.102967>.
- [48] Dai H, Wang J, Huang Y, Lai Y, Zhu L. Lightweight state-of-health estimation of lithium-ion batteries based on statistical feature optimization. *Renewable Energy* 2024;222:119907. <https://doi.org/10.1016/j.renene.2023.119907>.
- [49] Wu J, Liu Z, Zhang Y, Lei D, Zhang B, Cao W. Data-driven state of health estimation for lithium-ion battery based on voltage variation curves. *Journal of Energy Storage* 2023;73:109191. <https://doi.org/10.1016/j.est.2023.109191>.
- [50] Wen J, Chen X, Li X, Li Y. SOH prediction of lithium battery based on IC curve feature and BP neural network. *Energy* 2022;261:125234. <https://doi.org/10.1016/j.energy.2022.125234>.
- [51] Tian Y, Dong Q, Tian J, Li X, Li G, Mehran K. Capacity estimation of lithium-ion batteries based on optimized charging voltage section and virtual sample generation. *Applied Energy* 2023;332:120516. <https://doi.org/10.1016/j.apenergy.2022.120516>.
- [52] Li X, Zhao M, Zhong S, Li J, Cui Z, Fu S, Yan Z. Deep transfer learning enabled online state-of-health estimation of lithium-ion batteries under small samples across different cathode materials, ambient temperature and charge-discharge protocols. *Journal of Power Sources* 2025;650:237503. <https://doi.org/10.1016/j.jpowsour.2025.237503>.

- [53] Tang Q, He T, Huang J, Zhu W. A novel state of health estimation method for lithium-ion battery based on multi-feature extraction and fusion model with bidirectional feature extraction. *Journal of Energy Storage* 2026;141:119415.
- [54] Gong Y, Lu X, Su Z, Huang Z, Quan Y, Zhang Z, Ouyang T. Correlation-aware fusion model for robust SOH estimation in lithium-ion batteries. *Journal of Energy Storage* 2026;149:120018.
- [55] Lin M, Ke L, Wang W, Meng J, Guan Y, Wu J. Health prognosis via feature optimization and convolutional neural network for lithium-ion batteries. *Engineering Applications of Artificial Intelligence* 2024;133:108666. <https://doi.org/10.1016/j.engappai.2024.108666>.
- [56] Ambroise C, McLachlan GJ. Selection bias in gene extraction on the basis of microarray gene-expression data. *Proceedings of the National Academy of Sciences of the United States of America* 2002;99(10):6562–6566. <https://doi.org/10.1073/pnas.102102699>.
- [57] Kaufman S, Rosset S, Perlich C, Stitelman O. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data* 2012;6(4):15. <https://doi.org/10.1145/2382577.2382579>.
- [58] Huang K, Yao K, Guo Y, Lv Z. State of health estimation of lithium-ion batteries based on fine-tuning or rebuilding transfer learning strategies combined with new features mining. *Energy* 2023;282:128739. <https://doi.org/10.1016/j.energy.2023.128739>.
- [59] Wang R, Song C, Gao M, Zhao J, Xu Z. Model-data fusion domain adaptation for battery state of health estimation with fewer data and simplified feature extractor. *Journal of Energy Storage* 2023;60:106686. <https://doi.org/10.1016/j.est.2023.106686>.
- [60] Birkel CR, Roberts MR, McTurk E, Bruce PG, Howey DA. Degradation diagnostics for lithium-ion cells. *Journal of Power Sources* 2017;341:373–386. <https://doi.org/10.1016/j.jpowsour.2016.12.011>.
- [61] dos Reis G, Strange C, Yadav M, Li S. Lithium-ion battery data and where to find it. *Energy and AI* 2021;5:100081. <https://doi.org/10.1016/j.egyai.2021.100081>.
- [62] Severson KA, Attia PM, Jin N, et al. Data-driven prediction of battery cycle life before capacity degradation. *Nature Energy* 2019;4(5):383–391. <https://doi.org/10.1038/s41560-019-0356-8>.
- [63] Lin C, Xu J, Shi M, Mei X. Constant current charging time based fast state-of-health estimation for lithium-ion batteries. *Energy* 2022;247:123556. <https://doi.org/10.1016/j.energy.2022.123556>.
- [64] Li D, Xing Y, Li X. Joint state of health and remaining useful life assessment of lithium-ion batteries using a novel attention mechanism-based deep learning model and multi-source optimized health indicators. *Journal of Energy Storage* 2026;161:121823.
- [65] Wu B, Yufit V, Merla Y, Martinez-Botas RF, Brandon NP, Offer GJ. Differential thermal voltammetry for tracking of degradation in lithium-ion batteries. *Journal of Power Sources* 2015;273:495–501. <https://doi.org/10.1016/j.jpowsour.2014.09.127>.
- [66] Lin Z, Li D, Zou Y. Energy efficiency of lithium-ion batteries: Influential factors and long-term degradation. *Journal of Energy Storage* 2023;74:109386. <https://doi.org/10.1016/j.est.2023.109386>.
- [67] Bai J, Huang J, Luo K, Yang F, Xian Y. A feature reuse based multi-model fusion method for state of health estimation of lithium-ion batteries. *Journal of Energy Storage* 2023;70:107965. <https://doi.org/10.1016/j.est.2023.107965>.
- [68] Zhang Y, Zhang D, Wu T. Method for estimating the state of health of lithium-ion batteries based on differential thermal voltammetry and sparrow search algorithm-Elman neural network. *Energy Engineering* 2025;122(1):203–220. <https://doi.org/10.32604/ee.2024.056244>.
- [69] Zou B, Wang H, Zhang T, et al. A deep learning approach for state-of-health estimation of lithium-ion batteries based on differential thermal voltammetry and attention mechanism. *Frontiers in Energy Research* 2023;11:1178151. <https://doi.org/10.3389/fenrg.2023.1178151>.
- [70] Feng H, Zhang L. A heterogeneous learner fusion method with supplementary feature for lithium-ion batteries state of health estimation. *Journal of Energy Storage* 2024;92:111896. <https://doi.org/10.1016/j.est.2024.111896>.
- [71] Chollet F. Xception: Deep learning with depthwise separable convolutions. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*; 2017. p. 1800–1807. <https://doi.org/10.1109/CVPR.2017.195>.
- [72] Sandler M, Howard A, Zhu M, Zhmoginov A, Chen L-C. MobileNetV2: Inverted residuals and linear bottlenecks. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*; 2018. p. 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474>.
- [73] Zhang X, Zhou X, Lin M, Sun J. ShuffleNet: An extremely efficient convolutional neural network for mobile devices. *arXiv* 2017. <https://doi.org/10.48550/arXiv.1707.01083>.

- [74] Ma N, Zhang X, Zheng H-T, Sun J. ShuffleNet V2: Practical guidelines for efficient CNN architecture design. In: Computer Vision—ECCV 2018, Lecture Notes in Computer Science, vol. 11218, Springer, Cham; 2018. p. 116–131. https://doi.org/10.1007/978-3-030-01264-9_8.
- [75] Srivastava N, Hinton G, Krizhevsky A, Sutskever I, Salakhutdinov R. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research* 2014;15(56):1929–1958.
- [76] Chicco D, Warrens MJ, Jurman G. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science* 2021;7:e623. <https://doi.org/10.7717/peerj-cs.623>.
- [77] Li P, Zhang Z, Grosu R, Deng Z, Hou J, Rong Y, Wu R. An end-to-end neural network framework for state-of-health estimation and remaining useful life prediction of electric vehicle lithium batteries. *Renewable and Sustainable Energy Reviews* 2022;156:111843. <https://doi.org/10.1016/j.rser.2021.111843>.
- [78] Wang F, Zhai Z, Zhao Z, Di Y, Chen X. Physics-informed neural network for lithium-ion battery degradation stable modeling and prognosis. *Nature Communications* 2024;15:4332. <https://doi.org/10.1038/s41467-024-48779-z>.
- [79] Li Y, Abdel-Monem M, Gopalakrishnan R, Berecibar M, Nanini-Maury E, Omar N, van den Bossche P, Van Mierlo J. A quick on-line state of health estimation method for Li-ion battery with incremental capacity curves processed by Gaussian filter. *Journal of Power Sources* 2018;373:40–53. <https://doi.org/10.1016/j.jpowsour.2017.10.092>.
- [80] Li Z, Zhang X, Gao W. State of health estimation of lithium-ion battery during fast charging process based on BiLSTM-transformer. *Energy* 2024;311:133418. <https://doi.org/10.1016/j.energy.2024.133418>.
- [81] Peng S, Zhu J, Wu T, Tang A, Kan J, Pecht M. SOH early prediction of lithium-ion batteries based on voltage interval selection and features fusion. *Energy* 2024;308:132993. <https://doi.org/10.1016/j.energy.2024.132993>.
- [82] Li P, Zhang Z, Xiong Q, Ding B, Hou J, Luo D, Rong Y, Li S. State-of-health estimation and remaining useful life prediction for the lithium-ion battery based on a variant long short term memory neural network. *Journal of Power Sources* 2020;459:228069. <https://doi.org/10.1016/j.jpowsour.2020.228069>.
- [83] Lin M, Wu J, Meng J, Wang W, Wu J. State of health estimation with attentional long short-term memory network for lithium-ion batteries. *Energy* 2023;268:126706. <https://doi.org/10.1016/j.energy.2023.126706>.
- [84] Hou X, Guo X, Yuan Y, Zhao K, Tong L, Yuan C, Teng L. The state of health prediction of Li-ion batteries based on an improved extreme learning machine. *Journal of Energy Storage* 2023;70:108044. <https://doi.org/10.1016/j.est.2023.108044>.